

Studio di robustezza dei modelli di machine learning al rumore nei dati

Un'analisi sperimentale sul dataset MAGIC Gamma Telescope

Daniele Maccagnan Matias Bonoli Ashley Chudory

Anno accademico 2025/2026

Indice

- 1 Introduzione
- 2 Dataset ed esplorazione
- 3 Modelli e baseline
- 4 Metodologia del rumore
- 5 Risultati per tipo di rumore
- 6 Controllo multi-seed
- 7 Sintesi e confronto tra modelli
- 8 Analisi non supervisionata (K-Means)
- 9 Conclusioni

Perché studiare la robustezza al rumore

- Nei sistemi reali i dati non sono mai perfetti: misure imprecise, errori di annotazione, valori mancanti, anomalie, sensori guasti.
- La domanda non è quale modello sia più accurato sui dati puliti, ma quanto ciascuno resiste quando i dati si degradano.
- Obiettivo: capire come e perché le prestazioni peggiorano in funzione del tipo di disturbo introdotto.

Approccio sperimentale

Cosa facciamo

- Calcoliamo una *baseline* sui dati integri.
- Corrompiamo il **solo training set** con sette tipi di rumore.
- Tre livelli di intensità crescente: 10%, 25%, 40%.
- Riaddestriamo i modelli ad ogni livello.


Come valutiamo

- Metriche sempre su un **test set pulito** e inalterato.
- Quattro metriche: accuratezza, F1 macro, recall macro, AUC.
- Tre modelli con difese crescenti contro il rumore.
- Un esperimento non supervisionato.

Seme fissato (seed = 42) su tutte le componenti stocastiche per la riproducibilità.

Il dataset MAGIC Gamma Telescope

- Simulazioni Monte Carlo del telescopio Cherenkov MAGIC.
- Ogni record è una traccia luminosa di un evento atmosferico.
- Classificazione binaria: **gamma (1)** vs **adroni (0)**.
- 19 020 osservazioni, 10 feature continue + target.



Classi sbilanciate: 64,8% gamma, 35,2% adroni.

Le dieci feature continue

Feature	Descrizione
fLength	lunghezza dell'asse maggiore dell'ellisse
fWidth	lunghezza dell'asse minore dell'ellisse
fSize	logaritmo della somma delle intensità dei pixel
fConc	rapporto di concentrazione dei due pixel più intensi
fConc1	rapporto di concentrazione del pixel più intenso
fAsym	asimmetria della distribuzione lungo l'asse maggiore
fM3Long	momento terzo lungo l'asse maggiore
fM3Trans	momento terzo lungo l'asse minore
fAlpha	angolo tra asse maggiore e direzione del centro campo
fDist	distanza dal centro del campo all'origine dell'ellisse

*Le feature codificano **geometria** e **distribuzione di intensità** dell'immagine.*


Suddivisione dei dati

Split stratificato 60/20/20

- 11 412 train, 3 804 val, 3 804 test.
- Split *prima* di ogni analisi: niente **data leakage**.
- Stratificazione sul target: ogni partizione conserva il rapporto gamma/adroni.


EDA condotta solo sul training

EDA: Distribuzioni delle feature



Distribuzioni **asimmetriche**, code lunghe e scale eterogenee da unità a centinaia.


EDA: boxplot per classe



fAlpha è la più discriminante; seguono fLength, fWidth, fSize. Le restanti feature separano meno le classi.

EDA: Correlazioni

Matrice di Correlazione



- fConc/fConc1 quasi ridondanti (0,98).
- Anticorrelazione con fSize ($-0,85$).
- fLength/fWidth/fSize correlate (0,70–0,77).
- Vi è ridondanza di informazione: il disturbo su una feature è in parte compensato dalle altre.
- fAlpha quasi scorrelata: informazione unica e non sostituibile.

Preprocessing

Standardizzazione

- Normalizzazione del dataset: media 0, deviazione standard 1.
- Parametri stimati **solo sul training**, applicati a val/test: no data leakage.
- Essenziale per la convergenza delle reti neurali.

I tre modelli


- **NN Base** – Rete neurale semplice: Dense(32)→Dense(16)→ sigmoide. Nessuna regolarizzazione, Adam 10^{-3} , 75 epoche. Libero di andare in overfitting.
- **NN Pro** – stessa architettura + quattro difese:
 - regolarizzazione $L2$ (10^{-4});
 - *dropout* (0,2);
 - *class weight* bilanciato a favore degli adroni;
 - *early stopping* sulla validation loss con patience 15.
- **Random Forest** – 200 alberi, bagging e voto di maggioranza: la varianza degli errori individuali si cancella.

Quattro metriche di valutazione principali: accuratezza, F1 macro, recall macro, AUC. Le macro pesano ugualmente le due classi.

Baseline su dati puliti


	Acc	F1 _m	AUC
NN Base	0,8678	0,8517	0,9214
NN Pro	0,8601	0,8468	0,9238
RF	0,8785	0,8629	0,9300

- Modelli quasi equivalenti, tutti ben oltre la soglia banale del 65%.
- **RF** il migliore su tutte le metriche.
- NN Pro cede accuratezza (class weight) ma ha **AUC più alta** della rete Base.




fAlpha domina la *feature importance* ($\approx 0,24$), coerente con i boxplot.

Baseline: matrici di confusione e curve



NN Base, NN Pro, Random Forest.



Curva NN Base: convergenza regolare.

Tutti riconoscono bene i gamma; gli errori si concentrano sugli **adroni**. Gap train/validation contenuto: nessun overfitting marcato.


Come iniettiamo il rumore

- Il rumore altera **solo il training set**; validation e test restano puliti $\Rightarrow$ valutiamo la vera generalizzazione.
- Per ogni rumore: riaddestramento ai tre livelli (10%, 25%, 40%) e valutazione sullo stesso test set.
- Iniezione sul training *già standardizzato*: per perturbazioni additive o monotone equivale a corrompere i dati originali.

I sette meccanismi di rumore

- 1 **Feature noise**: rumore gaussiano $N(0, \sigma)$ aggiunto a tutte le feature con σ proporzionale al livello.
- 2 **Feature noise localizzato**: $\sigma = 0,35$ fisso, ma su un numero crescente di feature importanti (top-1 / top-3 / top-5).
- 3 **Label noise random**: etichette invertite a caso.
- 4 **Label noise borderline**: etichette invertite sui campioni ambigui vicini al centroidi tra le classi.
- 5 **Missing values**: celle mancanti (NaN) da imputare con media o mediana.
- 6 **Outlier**: righe a ± 5 deviazioni standard, segno casuale (strategie: nessuna / winsorizzazione / imputazione).
- 7 **Missing feature**: intere colonne azzerate, su tutti i set, per importanza decrescente.

L'effetto dei disturbi su una feature





fAlpha standardizzata: dati puliti e tre disturbi al 40%. Il rumore gaussiano allarga la distribuzione, gli outlier creano due picchi agli estremi, l'imputazione concentra molti campioni su un unico valore.

Feature noise: analisi

- Degrado **graduale**: al 40% tutti i modelli restano sopra l'83% (calo di 3–4 punti).
- Al 40% vince la **NN Pro** (0,8417): L2 + dropout impediscono di apprendere le fluttuazioni casuali.
- La NN Base, senza vincoli, si adatta al rumore e peggiora sui campioni nuovi.
- Degrado **asimmetrico**: la recall adroni della Base crolla $0,77 \rightarrow 0,59$, mentre quella dei gamma sale $0,92 \rightarrow 0,97$.
- Il class weight della Pro sostiene la recall degli adroni a 0,73.

Feature noise: evidenze grafiche




Feature noise localizzato – analisi

- Intensità fissa ($\sigma = 0,35$), ma colpisce solo le feature più importanti: top-1 (fAlpha) $\rightarrow$ top-3 $\rightarrow$ top-5.
- Degrado comunque **lieve**: al 40% tutti sopra l'83%.
- Stessa asimmetria: recall adroni Base a 0,67, Pro a 0,75.
- **Contrasto chiave con il missing feature:**
 - *disturbare* fAlpha $\Rightarrow$ NN Base a 0,8651;
 - *azzerarla* $\Rightarrow$ crollo a 0,8215.



*Il rumore **degrada** l'informazione ma non la cancella: un'informazione rumorosa ma presente resta utilizzabile.*

Feature noise localizzato – evidenze grafiche




Accuratezza: curve vicine e quasi piatte.

Confusion Matrix — NN base — Feature noise localizzato Rumore 40%



F1 macro: stesso andamento del rumore diffuso.

Confusion Matrix — RF — Feature noise localizzato Rumore 40%




Matrici di confusione al 40%: NN Base (sinistra) e Random Forest (destra).

Label noise random – analisi



- Fino al 25% le metriche reggono; al 40% il **crollo è netto**.
- Al 40%: NN Base $\rightarrow 0,7419$, RF $\rightarrow 0,7179$; la **NN Pro regge a 0,8044**.
- Causa nelle learning curves: la Base *memorizza* le etichette spurie (train $\approx 88\%$) mentre la validation pulita peggiora.
- L'**early stopping** della Pro ferma l'addestramento prima della memorizzazione del rumore $\Rightarrow$ validation $\approx 82\%$.
- Il RF memorizza le etichette errate nei nodi: errore distribuito su entrambe le classi.

Qui la regolarizzazione fa la differenza: monitorare i dati puliti protegge dal rumore sulle etichette.



Label noise random – evidenze grafiche




Al 40% la NN Pro si stacca verso l'alto.



NN Base al 40%: train sale, validation scende (memorizzazione).



NN Pro al 40%: l'early stopping mantiene alta la validation.






RF al 40%: errori su entrambe le classi.

Label noise borderline – analisi

- Il disturbo **più distruttivo**: cala già al 25%, al 40% tutti scendono attorno al 60%.
- Sotto la soglia del classificatore banale ($\sim 65\%$): i modelli diventano **attivamente fuorvianti**.
- Invertire i campioni vicini al confine **sposta il confine decisionale** appreso: è un errore sistematico, non varianza.
- Le learning curves della NN Pro non mostrano alcun vantaggio: regolarizzazione ed early stopping **non recuperano**.
- Danno **simmetrico** tra le classi: il ribilanciamento è vanificato.
- Log loss sul test al 40%: Base 1,06, Pro 0,61 $\Rightarrow$ l'early stopping contiene almeno il danno sulla **calibrazione**.

A parità di flip, falsificare le istanze ambigue è molto più dannoso del rumore casuale: corrompe la struttura, non solo i dati.


Label noise borderline – evidenze grafiche




Al 40% tutti convergono verso il 60%: collasso predittivo.

NN Pro al 40%: crolla anche la validation.

Confusion Matrix — NN pro — Label noise borderline Rumore 40%



Confusion Matrix — RF — Label noise borderline Rumore 40%





Matrici al 40%: NN Pro (sinistra) e RF (destra), errori diffusi in modo simmetrico.

Missing values – analisi

- Celle sostituite con NaN; i modelli non leggono dati incompleti $\Rightarrow$ serve **imputazione**.
- Con la mediana (variante canonica) le metriche restano 82–85%: degrado **lineare e gestibile**.
- Il **Random Forest** è il più resistente (0,8528 al 40%): opera per divisioni, isola meglio le celle imputate.
- **Media vs mediana**: divario marginale e senza direzione univoca.
 - mediana lievemente meglio sulla Base ad alta corruzione;
 - media leggermente meglio sulla Pro; pari sul RF.

La mediana resta riferimento per robustezza teorica alle code, ma sul piano empirico la scelta incide poco.


Missing values – evidenze grafiche




Imputazione mediana: RF in vantaggio costante.

Media vs mediana (RF): praticamente equivalenti.

Confusion Matrix — NN base — Missing values (mediana) Rumore 40%



Confusion Matrix — RF — Missing values (mediana) Rumore 40%





Matrici al 40%: NN Base (sinistra) e RF (destra); gli errori pesano sugli adroni.

Outlier – analisi

- Il disturbo **meno dannoso**: l'accuratezza resta 85–87%, quasi nessuna tendenza al degrado.
- Motivo **nella natura del disturbo**, non nel trattamento: i valori $\pm 5\sigma$ hanno segno casuale e scorrelato dall'etichetta $\Rightarrow$ il loro contributo al gradiente si media a zero.
- Tre strategie quasi equivalenti: nessun trattamento, winsorizzazione, imputazione.
- Ad alta corruzione la winsorizzazione al 5% è in gran parte **inefficace** (i percentili stessi sono saturati).


*La robustezza nasce dalla **natura poco dannosa del disturbo** più che dalla mitigazione; teniamo la winsorizzazione per prudenza.*

Outlier – evidenze grafiche




Winsorizzazione: curve pressoché piatte.

Confusion Matrix — NN base — Outlier (winsorizzazione) Rumore 40%



RF: le tre strategie sono sovrapponibili.

Confusion Matrix — RF — Outlier (winsorizzazione) Rumore 40%





Matrici al 40%: prestazioni indistinguibili dal caso pulito.

Missing feature (sensore guasto) – analisi

- Intere colonne azzerate su *tutti* i set, per importanza: top-1 (f_{Alpha}) $\rightarrow$ top-3 $\rightarrow$ top-5.
- Esito **molto grave**: già al 10% un calo di 4–5 punti; al 40% tutti attorno al 70%.
- Qui non c'è rumore da filtrare ma **informazione che non esiste più**: azzerare f_{Alpha} pesa più del feature noise massimo.
- **Controtendenza**: la NN Pro è la *meno* robusta (0,6995 al 40%): le difese contro l'overfitting irrigidiscono il modello quando manca informazione.


*f_{Alpha} è scorrelata dalle altre: la sua perdita è **insostituibile** e colpisce soprattutto gli adroni.*

Missing feature – evidenze grafiche




Rimuovere $f\alpha$: declino severo dal primo step.

Confusion Matrix — NN base — Missing feature Rumore 10%




RF al 40%: discriminazione adroni quasi azzerata.

Confusion Matrix — NN base — Missing feature Rumore 25%




Confusion Matrix — NN base — Missing feature Rumore 40%



NN Base, top-1/top-3/top-5: la capacità sugli adroni svanisce progressivamente.


Controllo multi-seed: il trend è reale?



- Feature noise ripetuto su **cinque** semi {42, 7, 123, 2024, 99}.
- Ogni seme governa rumore, split e inizializzazione.
- Deviazione standard sempre $< 0,007$ (max 0,0068).
- Un ordine di grandezza **sotto** il calo dovuto al rumore ($\sim 3,4$ punti per la NN Base).

*Le barre d'errore sono quasi impercettibili: il degrado è un **segnale reale**, non varianza procedurale.*


Multi-seed – F1 macro e gerarchia confermata



- Stesso ordinamento sulla metrica bilanciata.
- RF parte più in alto (0,8800) ma cede più rapidamente.
- La NN Pro ha il degrado **più graduale**.
- Le differenze sono coerenti tra i cinque semi.


L'ordinamento osservato non dipende dalle fluttuazioni del generatore stocastico.

Gerarchia di pericolosità dei rumori




outlier < feature noise $\approx$ missing values < label noise random $\approx$ missing feature < **label noise borderline.**

Degradazione e ranking complessivo



Barre piccole = maggiore tenuta al rumore.



Robustezza media (caso peggiore).

- NN Pro 0,785
- RF 0,780
- NN Base 0,778


Distanze trascurabili: **nessun vincitore netto.**

Chi vince su cosa

Scenario	Modello più robusto	Nota
Dati puliti	Random Forest	migliore su tutte le metriche
Feature noise	NN Pro	L2 + dropout filtrano il rumore
Label noise random	NN Pro	early stopping blocca la memorizzazione
Missing values	Random Forest	opera per divisioni
Outlier	tutti (pari)	disturbo quasi innocuo
Missing feature	Random Forest	NN Pro la <i>meno</i> robusta
Label borderline	nessuno	collasso generale ($\sim 60\%$)


*La scelta del modello dipende dal **tipo di errore atteso** nel dominio applicativo, non da una superiorità astratta.*

Curve ROC: il ranking resiste al feature noise




- Continue = dati puliti; tratteggiate = 40% feature noise.
- Lo scarto è limitato: il **potere di ranking** si riduce poco.
- Conferma che il feature noise degrada soprattutto la decisione a soglia fissa, non l'ordinamento probabilistico.

K-Means: perché e come




- Esperimento **senza etichette**: cosa trova un algoritmo basato solo sulla distanza?
- $k = 2$ scelto con *elbow* (inerzia) e *silhouette* (massima in $k = 2$).
- La silhouette tende a premiare k piccoli: indizio, non prova.

K-Means: i cluster non sono le classi




- $ARI \approx 0,006$, purezza $\approx 0,648$ (pari allo sbilanciamento nativo).
- I cluster dividono lo spazio lungo la **varianza dominante**, non la separazione fisica gamma/adrone.
- Le proprietà che distinguono le classi attraversano i cluster: nessun discriminante lineare.

K-Means sotto rumore



ARI e silhouette al crescere del rumore.



I confini dei cluster diventano meno netti all'aumentare di σ .

*Il **feature noise** degrada i cluster (silhouette 0,290 $\rightarrow$ 0,102). Il **label noise** non ha alcun effetto ($ARI = 1,000$): K-Means non usa le etichette.*

K-Means: la lezione trasversale

- La vulnerabilità a un rumore dipende strettamente dalle **informazioni che il modello sfrutta**.
- Il label noise – devastante per i modelli supervisionati – è **del tutto ininfluenza** per K-Means, che ignora le etichette.
- Il feature noise – gestibile nel supervisionato grazie alla ridondanza – **degrada** la struttura geometrica su cui K-Means si fonda.

*Ciò che è critico per un task può essere irrilevante per un altro: la robustezza è sempre **relativa al modo in cui si usano i dati**.*

Conclusioni – i rumori

- Esiste una chiara **gerarchia di pericolosità**:
 - *trascurabili*: outlier;
 - *gestibili*: feature noise, missing values (ridondanza e imputazione);
 - *critici*: missing feature e label noise.
- Missing feature e label noise sono gravi per ragioni **opposte**: il primo cancella informazione insostituibile, il secondo forza a memorizzare pattern errati.
- Il caso peggiore è il **label noise borderline**: falsifica direttamente il confine decisionale.
- Il degrado è spesso **asimmetrico**: a peggiorare è la classe minoritaria (adroni); il class weight della NN Pro la protegge.

Conclusioni – i modelli e il preprocessing

- **Nessun modello domina:** la NN Pro vince sul rumore delle etichette, il Random Forest su valori mancanti e outlier, la NN Base è la più esposta.
- La scelta del modello richiede un'analisi *a priori* sui tipi di errore attesi nel dominio reale.
- L'evidenza più forte: conta **più il preprocessing** della complessità algoritmica.
 - imputazione, winsorizzazione, early stopping recuperano gran parte del degrado.
- Ma nessun modello recupera un'informazione **cancellata** o **falsificata** nei punti più sensibili.

La robustezza si costruisce a monte (cura del dato) tanto quanto a valle (scelta dell'algoritmo).

Limiti e sviluppi futuri

- Il controllo multi-seed copre solo il feature noise: va esteso agli altri disturbi, in particolare al label noise.
- Soglia di decisione fissa a 0,5: ritrarla sul validation set potrebbe recuperare parte della recall sugli adroni.
- Iperparametri scelti sui dati puliti e mai ricalibrati sotto rumore.
- Alberi del Random Forest senza limite di profondità: limitarla dovrebbe ridurre la memorizzazione delle etichette invertite.
- Un solo dataset: la gerarchia osservata dipende anche dalla ridondanza tra le feature e dal ruolo di f_{Alpha} ; va confermata su dataset con struttura diversa.

Grazie per l'attenzione

Daniele Maccagnan Matias Bonoli Ashley Chudory

Studio di robustezza al rumore – MAGIC Gamma Telescope