

# Studio di robustezza dei modelli di machine learning al rumore nei dati

## Architettura Dati

Daniele Maccagnan   Matias Bonoli   Ashley Chudory

Anno accademico 2025/2026

# Indice

- 1 Introduzione
- 2 Dataset ed esplorazione
- 3 Modelli e baseline
- 4 Metodologia del rumore
- 5 Risultati per tipo di rumore
- 6 Controllo multi-seed
- 7 Sintesi e confronto tra modelli
- 8 Analisi non supervisionata (K-Means)
- 9 Conclusioni

# Perché studiare la robustezza al rumore

- Nei sistemi reali i dati non sono mai perfetti: misure imprecise, errori di annotazione, valori mancanti, anomalie, sensori guasti.
- La domanda non è quale modello sia più accurato sui dati puliti, ma quanto ciascuno resiste quando i dati si degradano.
- Obiettivo: capire come e perché le prestazioni peggiorano in funzione del tipo di disturbo introdotto.

# Approccio sperimentale

## Cosa facciamo

- Calcoliamo una baseline sui dati integri.
- Corrompiamo il solo training set con sette tipi di rumore.
- Tre livelli di intensità crescente: 10%, 25%, 40%.
- Riaddestriamo i modelli ad ogni livello.


## Come valutiamo

- Metriche sempre su un test set pulito e inalterato.
- Quattro metriche: accuratezza, F1 macro, recall macro, AUC.
- Tre modelli con difese crescenti contro il rumore.
- Un esperimento non supervisionato.

Seme fissato (seed = 42) su tutte le componenti stocastiche per la riproducibilità.

## Il dataset MAGIC Gamma Telescope

- Simulazioni Monte Carlo del telescopio Cherenkov MAGIC.
- Ogni record è una traccia luminosa di un evento atmosferico.
- Classificazione binaria: gamma (1) vs adroni (0).
- 19 020 osservazioni, 10 feature continue + target.



Classi sbilanciate: 64,8% gamma, 35,2% adroni.

# Le dieci feature continue

| Feature  | Descrizione                                            |
|----------|--------------------------------------------------------|
| fLength  | lunghezza dell'asse maggiore dell'ellisse              |
| fWidth   | lunghezza dell'asse minore dell'ellisse                |
| fSize    | logaritmo della somma delle intensità dei pixel        |
| fConc    | rapporto di concentrazione dei due pixel più intensi   |
| fConc1   | rapporto di concentrazione del pixel più intenso       |
| fAsym    | asimmetria della distribuzione lungo l'asse maggiore   |
| fM3Long  | momento terzo lungo l'asse maggiore                    |
| fM3Trans | momento terzo lungo l'asse minore                      |
| fAlpha   | angolo tra asse maggiore e direzione del centro campo  |
| fDist    | distanza dal centro del campo all'origine dell'ellisse |

*Le feature codificano geometria e distribuzione di intensità dell'immagine.*


# Suddivisione dei dati

## Split stratificato 60/20/20

- 11 412 train, 3 804 val, 3 804 test.
- Split prima di ogni analisi: niente data leakage.
- Stratificazione sul target: ogni partizione conserva il rapporto gamma/adroni.


EDA condotta solo sul training

# EDA: Distribuzioni delle feature



Distribuzioni asimmetriche, code lunghe e scale eterogenee da unità a centinaia.


# EDA: boxplot per classe



fAlpha è la più discriminante; seguono fLength, fWidth, fSize. Le restanti feature separano meno le classi.

# EDA: Correlazioni

Matrice di Correlazione



- fConc/fConc1 quasi ridondanti (0,98).
- Anticorrelazione con fSize ( $-0,85$ ).
- fLength/fWidth/fSize correlate (0,70–0,77).
- Vi è ridondanza di informazione: il disturbo su una feature è in parte compensato dalle altre.
- fAlpha quasi scorrelata: informazione unica e non sostituibile.

# Preprocessing

## Standardizzazione

- Normalizzazione del dataset: media 0, deviazione standard 1.
- Parametri stimati solo sul training, applicati a val/test: no data leakage.
- Essenziale per la convergenza delle reti neurali.

# I tre modelli


- **NN Base** – Rete neurale semplice: Dense(32)→Dense(16)→ sigmoide. Nessuna regolarizzazione, Adam  $10^{-3}$ , 75 epoche. Libero di andare in overfitting.
- **NN Pro** – stessa architettura + quattro difese:
  - regolarizzazione L2 ( $10^{-4}$ );
  - dropout (0,2);
  - class weight bilanciato a favore degli adroni;
  - early stopping sulla validation loss con patience 15.
- **Random Forest** – 200 alberi, bagging e voto di maggioranza: la varianza degli errori individuali si cancella.

Quattro metriche di valutazione principali: accuratezza, F1 macro, recall macro, AUC. Le macro pesano ugualmente le due classi.

# Baseline su dati puliti


|         | Acc           | F1 <sub>m</sub> | AUC           |
|---------|---------------|-----------------|---------------|
| NN Base | 0,8678        | 0,8517          | 0,9214        |
| NN Pro  | 0,8601        | 0,8468          | 0,9238        |
| RF      | <b>0,8785</b> | <b>0,8629</b>   | <b>0,9300</b> |

- Modelli quasi equivalenti, tutti ben oltre la soglia banale del 65%.
- RF il migliore su tutte le metriche.
- NN Pro cede accuratezza (class weight) ma ha AUC più alta della rete Base.



fAlpha domina la feature importance ( $\approx 0,24$ ), coerente con i boxplot.



# Baseline: matrici di confusione



NN Base, NN Pro, Random Forest.

Tutti riconoscono bene i gamma; gli errori si concentrano sugli adroni.

# Baseline: curva di addestramento



Curva NN Base: convergenza regolare, gap train / validation contenuto – nessun overfitting marcato.


# Come iniettiamo il rumore

- Il rumore altera solo il training set; validation e test restano puliti  $\Rightarrow$  valutiamo la vera generalizzazione.
- Per ogni rumore: riaddestramento ai tre livelli (10%, 25%, 40%) e valutazione sullo stesso test set.
- Iniezione sul training già standardizzato: permette di isolare ed evidenziare l'impatto delle perturbazioni sul modello

# I sette meccanismi di rumore

- 1 **Feature noise**: rumore gaussiano  $N(0, \sigma)$  aggiunto a tutte le feature con  $\sigma$  proporzionale al livello.
- 2 **Feature noise localizzato**:  $\sigma = 0,35$  fisso, ma su un numero crescente di feature importanti (top-1 / top-3 / top-5).
- 3 **Label noise random**: etichette invertite a caso.
- 4 **Label noise borderline**: etichette invertite sui campioni ambigui vicini al centroidi tra le classi.
- 5 **Missing values**: celle mancanti (NaN) da imputare con media o mediana.
- 6 **Outlier**: righe a  $\pm 5$  deviazioni standard, segno casuale (strategie: nessuna / winsorizzazione / imputazione).
- 7 **Missing feature**: intere colonne azzerate, su tutti i set, per importanza decrescente.

# L'effetto dei disturbi su una feature



fAlpha standardizzata: dati puliti e tre disturbi al 40%. Il rumore gaussiano allarga la distribuzione, gli outlier creano due picchi agli estremi, l'imputazione concentra molti campioni su un unico valore.


# Feature noise

- Degrado graduale: al 40% tutti i modelli restano sopra l'83% (calo di 3–4 punti).
- Al 40% vince la NN Pro (0,8417): L2 + dropout impediscono di apprendere le fluttuazioni casuali.
- La NN Base, senza vincoli, si adatta al rumore e peggiora sui campioni nuovi.
- Degrado asimmetrico: la recall adroni della Base crolla  $0,77 \rightarrow 0,59$ , mentre quella dei gamma sale  $0,92 \rightarrow 0,97$ .
- Il class weight della Pro sostiene la recall degli adroni a 0,73.


# Feature noise: metriche e matrici di confusione

| Rumore | NN Base |                 |        | NN Pro        |                 |        | Random Forest |                 |        |
|--------|---------|-----------------|--------|---------------|-----------------|--------|---------------|-----------------|--------|
|        | Acc     | F1 <sub>m</sub> | AUC    | Acc           | F1 <sub>m</sub> | AUC    | Acc           | F1 <sub>m</sub> | AUC    |
| Pulito | 0,8678  | 0,85            | 0,9214 | 0,8601        | 0,85            | 0,9238 | 0,8785        | 0,86            | 0,9300 |
| 10%    | 0,8657  | 0,85            | 0,9187 | 0,8636        | 0,85            | 0,9204 | 0,8646        | 0,84            | 0,9222 |
| 25%    | 0,8520  | 0,83            | 0,9074 | 0,8465        | 0,83            | 0,9071 | 0,8494        | 0,82            | 0,9041 |
| 40%    | 0,8328  | 0,80            | 0,8941 | <b>0,8417</b> | <b>0,82</b>     | 0,8940 | 0,8318        | 0,80            | 0,8913 |


Confusion Matrix — NN base — Feature noise Rumore 40%



Confusion Matrix — NN pro — Feature noise Rumore 40%




Confusion Matrix — RF — Feature noise Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest.

# Feature noise: curve di addestramento



# Feature noise: evidenze grafiche



# Feature noise localizzato


- Stesso  $\sigma = 0,35$  del rumore diffuso, ma concentrato solo sulle feature più informative: top-1 (fAlpha)  $\rightarrow$  top-3  $\rightarrow$  top-5.
- Degrado **ancora più lieve**: al 40% vince la **NN Base** (0,8452), sopra tutti i risultati del rumore diffuso.
- La ridondanza tra feature (vista in EDA) assorbe il colpo: poche feature corrotte non bastano a confondere il modello.
- Resta **asimmetria**, ma attenuata: recall adroni 0,67 in NN Base, 0,75 in NN Pro (contro 0,59 e 0,73 del rumore diffuso).

Colpire le feature più importanti non è peggio che colpirle tutte: l'informazione persa è compensata da quella ridondante rimasta pulita.


# Feature noise localizzato: metriche e matrici di confusione

| Rumore | NN Base       |                 |        | NN Pro |                 |        | Random Forest |                 |        |
|--------|---------------|-----------------|--------|--------|-----------------|--------|---------------|-----------------|--------|
|        | Acc           | F1 <sub>m</sub> | AUC    | Acc    | F1 <sub>m</sub> | AUC    | Acc           | F1 <sub>m</sub> | AUC    |
| Pulito | 0,8678        | 0,85            | 0,9214 | 0,8601 | 0,85            | 0,9238 | 0,8785        | 0,86            | 0,9300 |
| 10%    | 0,8651        | 0,85            | 0,9211 | 0,8651 | 0,85            | 0,9243 | 0,8743        | 0,86            | 0,9274 |
| 25%    | 0,8523        | 0,83            | 0,9043 | 0,8478 | 0,83            | 0,9058 | 0,8533        | 0,83            | 0,9056 |
| 40%    | <b>0,8452</b> | <b>0,82</b>     | 0,8991 | 0,8386 | 0,82            | 0,8973 | 0,8389        | 0,81            | 0,8931 |

Confusion Matrix — NN base — Feature noise localizzato Rumore 40%




Confusion Matrix — RF — Feature noise localizzato Rumore 40%




Matrici di confusione al 40%: NN Base (sinistra) e Random Forest (destra).

# Feature noise localizzato: curve di addestramento




Curve al 40%: NN Base (sinistra) vs NN Pro (destra).

# Feature noise localizzato: confronto tra modelli



Accuratezza: curve vicine e quasi piatte.



F1 macro: stesso andamento del rumore diffuso.

# Label noise random


- Fino al 25% le metriche reggono; al 40% il peggioramento è marcato.
- Al 40%: NN Base  $\rightarrow$  0,7419, RF  $\rightarrow$  0,7179; la NN Pro a 0,8044.
- La causa si vede nelle learning curves: la rete Base memorizza le etichette errate (train all' 88%) mentre la validation pulita peggiora.
- L'early stopping della Pro ferma l'addestramento prima della memorizzazione del rumore: validation all' 82%.
- Il RF memorizza le etichette errate nei nodi: errore distribuito su entrambe le classi.

Qui la regolarizzazione fa la differenza: monitorare i dati puliti protegge dal rumore sulle etichette.


# Label noise random: metriche e matrici di confusione

| Rumore | NN Base |                 |        | NN Pro        |                 |               | Random Forest |                 |        |
|--------|---------|-----------------|--------|---------------|-----------------|---------------|---------------|-----------------|--------|
|        | Acc     | F1 <sub>m</sub> | AUC    | Acc           | F1 <sub>m</sub> | AUC           | Acc           | F1 <sub>m</sub> | AUC    |
| Pulito | 0,8678  | 0,85            | 0,9214 | 0,8601        | 0,85            | 0,9238        | 0,8785        | 0,86            | 0,9300 |
| 10%    | 0,8623  | 0,84            | 0,9128 | 0,8570        | 0,84            | 0,9200        | 0,8767        | 0,86            | 0,9214 |
| 25%    | 0,8410  | 0,82            | 0,8882 | 0,8378        | 0,83            | 0,9081        | 0,8399        | 0,82            | 0,8884 |
| 40%    | 0,7419  | 0,69            | 0,7513 | <b>0,8044</b> | <b>0,79</b>     | <b>0,8677</b> | 0,7179        | 0,70            | 0,7673 |


Confusion Matrix — NN base — Label noise random Rumore 40%



Confusion Matrix — NN pro — Label noise random Rumore 40%




Confusion Matrix — RF — Label noise random Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest.

# Label noise random: curve di addestramento



# Label noise random: confronto tra modelli



# Label noise borderline


- Il disturbo più distruttivo: cala già al 25%, al 40% tutti scendono attorno al 60%.
- Sotto la soglia del classificatore banale ( $\sim 65\%$ ): i modelli diventano completamente errati.
- Invertire i campioni vicini al confine sposta il confine decisionale appreso.
- Le learning curves della NN Pro non mostrano alcun vantaggio: regolarizzazione ed early stopping non recuperano.
- Danno simmetrico tra le classi.

A parità di inversioni, falsificare le istanze ambigue è molto più dannoso del rumore casuale: corrompe la struttura, non solo i dati.


# Label noise borderline: metriche e matrici di confusione

| Rumore | NN Base |                 |        | NN Pro        |                 |               | Random Forest |                 |        |
|--------|---------|-----------------|--------|---------------|-----------------|---------------|---------------|-----------------|--------|
|        | Acc     | F1 <sub>m</sub> | AUC    | Acc           | F1 <sub>m</sub> | AUC           | Acc           | F1 <sub>m</sub> | AUC    |
| Pulito | 0,8678  | 0,85            | 0,9214 | 0,8601        | 0,85            | 0,9238        | 0,8785        | 0,86            | 0,9300 |
| 10%    | 0,8252  | 0,80            | 0,8680 | 0,8352        | 0,82            | 0,8915        | 0,8383        | 0,81            | 0,8886 |
| 25%    | 0,7326  | 0,71            | 0,7879 | 0,7403        | 0,72            | 0,8265        | 0,7387        | 0,72            | 0,8043 |
| 40%    | 0,6002  | 0,59            | 0,6656 | <b>0,6354</b> | <b>0,62</b>     | <b>0,7084</b> | 0,6094        | 0,60            | 0,6774 |


Confusion Matrix — NN base — Label noise borderline Rumore 40%



Confusion Matrix — NN pro — Label noise borderline Rumore 40%




Confusion Matrix — RF — Label noise borderline Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest – errori diffusi in modo simmetrico.

# Label noise borderline: curve di addestramento



# Label noise borderline: grafici e confronto tra modelli



Al 40% tutti convergono verso il 60%: collasso predittivo.

# Missing values


- Celle sostituite con NaN; i modelli non leggono dati incompleti quindi serve imputazione.
- Con la mediana le metriche restano 82–85%: degrado lineare e gestibile.
- Il Random Forest è il più resistente (0,8528 al 40%): opera per divisioni, isola meglio le celle imputate.
- **Media vs mediana**: divario marginale e senza direzione univoca.
  - mediana lievemente meglio sulla Base ad alta corruzione;
  - media leggermente meglio sulla Pro; pari sul RF.

La mediana resta riferimento per robustezza teorica alle code, ma sul piano empirico la scelta incide poco.


# Missing values: metriche e matrici di confusione

|        | NN Base |                 |        | NN Pro |                 |        | Random Forest |                 |               |
|--------|---------|-----------------|--------|--------|-----------------|--------|---------------|-----------------|---------------|
| Rumore | Acc     | F1 <sub>m</sub> | AUC    | Acc    | F1 <sub>m</sub> | AUC    | Acc           | F1 <sub>m</sub> | AUC           |
| Pulito | 0,8678  | 0,85            | 0,9214 | 0,8601 | 0,85            | 0,9238 | 0,8785        | 0,86            | 0,9300        |
| 10%    | 0,8617  | 0,84            | 0,9172 | 0,8570 | 0,84            | 0,9190 | 0,8720        | 0,85            | 0,9208        |
| 25%    | 0,8425  | 0,83            | 0,9057 | 0,8328 | 0,82            | 0,9046 | 0,8578        | 0,84            | 0,9129        |
| 40%    | 0,8328  | 0,81            | 0,8915 | 0,8226 | 0,81            | 0,8937 | <b>0,8528</b> | <b>0,83</b>     | <b>0,9039</b> |

Confusion Matrix — NN base — Missing values (mediana) Rumore 40%





Confusion Matrix — RF — Missing values (mediana) Rumore 40%





Matrici al 40%: NN Base (sinistra) e RF (destra); gli errori pesano sugli adroni.

# Missing values: curve di addestramento



NN Base al 40% di valori mancanti: convergenza regolare, nessun overfitting marcato.

# Missing values: grafici e confronto tra modelli



Imputazione mediana: RF in vantaggio costante.

# Outlier


- Il disturbo meno dannoso: l'accuratezza resta 85–87%, quasi nessuna tendenza al degrado.
- Motivo nella natura del disturbo, non nel trattamento: i valori  $\pm 5\sigma$  hanno segno casuale e scorrelato dall'etichetta quindi il loro contributo al gradiente si media a zero.
- Le metriche delle tre strategie quasi equivalenti: nessun trattamento, winsorizzazione, imputazione.
- Ad alta corruzione la winsorizzazione al 5% è in gran parte inefficace.

La robustezza nasce dalla natura poco dannosa del disturbo più che dalla mitigazione; teniamo comunque la winsorizzazione come baseline.


# Outlier: metriche e matrici di confusione

| Rumore | NN Base |        |        | NN Pro |        |        | Random Forest |             |               |
|--------|---------|--------|--------|--------|--------|--------|---------------|-------------|---------------|
|        | Acc     | $F1_m$ | AUC    | Acc    | $F1_m$ | AUC    | Acc           | $F1_m$      | AUC           |
| Pulito | 0,8678  | 0,85   | 0,9214 | 0,8601 | 0,85   | 0,9238 | 0,8785        | 0,86        | 0,9300        |
| 10%    | 0,8657  | 0,85   | 0,9196 | 0,8583 | 0,84   | 0,9220 | <b>0,8788</b> | <b>0,86</b> | <b>0,9295</b> |
| 25%    | 0,8628  | 0,84   | 0,9160 | 0,8441 | 0,83   | 0,9173 | 0,8751        | 0,86        | 0,9267        |
| 40%    | 0,8615  | 0,84   | 0,9116 | 0,8541 | 0,84   | 0,9201 | 0,8736        | 0,86        | 0,9250        |

Confusion Matrix — NN base — Outlier (winsorizzazione) Rumore 40%





Confusion Matrix — RF — Outlier (winsorizzazione) Rumore 40%





Matrici al 40%: prestazioni indistinguibili dal caso pulito.

# Outlier: curve di addestramento



NN Base al 40% di outlier: convergenza regolare, nessun impatto visibile sull'addestramento.

# Outlier: grafici e confronto tra modelli



Winsorizzazione: curve pressoché piatte.

# Missing feature


- Intere colonne azzerate su tutti i set, per importanza.
- Esito molto grave: già al 10% un calo di 4–5 punti; al 40% tutti attorno al 70%.
- Qui non c'è rumore da filtrare ma informazione che non esiste più: azzerare  $f_{\text{Alpha}}$  pesa più del feature noise massimo.
- La NN Pro è la meno robusta (0,6995 al 40%): le difese contro l'overfitting irrigidiscono il modello quando manca informazione.

$f_{\text{Alpha}}$  è scorrelata dalle altre: la sua perdita è insostituibile e colpisce soprattutto gli adroni.


# Missing feature: metriche e matrici di confusione

|        | NN Base |                 |        | NN Pro |                 |        | Random Forest |                 |               |
|--------|---------|-----------------|--------|--------|-----------------|--------|---------------|-----------------|---------------|
| Rumore | Acc     | F1 <sub>m</sub> | AUC    | Acc    | F1 <sub>m</sub> | AUC    | Acc           | F1 <sub>m</sub> | AUC           |
| Pulito | 0,8678  | 0,85            | 0,9214 | 0,8601 | 0,85            | 0,9238 | 0,8785        | 0,86            | 0,9300        |
| 10%    | 0,8215  | 0,79            | 0,8675 | 0,8052 | 0,79            | 0,8716 | <b>0,8294</b> | <b>0,80</b>     | <b>0,8788</b> |
| 25%    | 0,7773  | 0,74            | 0,8007 | 0,7574 | 0,73            | 0,7991 | 0,7836        | 0,75            | 0,8195        |
| 40%    | 0,7303  | 0,67            | 0,7413 | 0,6995 | 0,67            | 0,7347 | 0,7363        | 0,68            | 0,7494        |


Confusion Matrix — NN base — Missing feature Rumore 40%



Confusion Matrix — NN pro — Missing feature Rumore 40%




Confusion Matrix — RF — Missing feature Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest – discriminazione adroni quasi azzerata.

# Missing feature: curve di addestramento



# Missing feature: grafici e confronto tra modelli





Rimuovere  $f_{\alpha}$ : declino severo dal primo step.

# Controllo multi-seed

- Feature noise ripetuto su cinque semi  $\{42, 7, 123, 2024, 99\}$ .
- Ogni seme governa rumore, split e inizializzazione.
- Deviazione standard sempre  $< 0,007$  (max 0,0068).
- Un ordine di grandezza sotto il calo dovuto al rumore ( $\sim 3,4$  punti per la NN Base).


Le barre d'errore sono quasi impercettibili: il degrado è un segnale reale, non varianza dal seed.

# Multi-seed: grafici e confronti




L'ordinamento osservato non dipende dalle fluttuazioni del generatore stocastico.

# Gerarchia di pericolosità dei rumori




outlier < feature noise  $\approx$  missing values < label noise random  $\approx$  missing feature < label noise borderline.

# Degradazione e ranking complessivo



Barre piccole = maggiore tenuta al rumore.



Robustezza media (caso peggiore).


- NN Pro 0,785
- RF 0,780
- NN Base 0,778

Distanze trascurabili: nessun vincitore netto.

# Classificazione dei modelli per scenario


| Scenario                                                                                    | Modello più robusto | Nota                                    | La scelta del modello |
|---------------------------------------------------------------------------------------------|---------------------|-----------------------------------------|-----------------------|
| Dati puliti                                                                                 | Random Forest       | migliore su tutte le metriche           |                       |
| Feature noise                                                                               | NN Pro              | L2 + dropout filtrano il rumore         |                       |
| Label noise random                                                                          | NN Pro              | early stopping blocca la memorizzazione |                       |
| Missing values                                                                              | Random Forest       | opera per divisioni                     |                       |
| Outlier                                                                                     | tutti (pari)        | disturbo quasi innocuo                  |                       |
| Missing feature                                                                             | Random Forest       | NN Pro la meno robusta                  |                       |
| Label borderline                                                                            | nessuno             | collasso generale ( $\sim 60\%$ )       |                       |
| dipende dal tipo di errore atteso nel dominio applicativo, non da una superiorità astratta. |                     |                                         |                       |

# Curve ROC




- Continue: dati puliti; tratteggiate: 40% feature noise.
- Lo scarto è limitato: il potere di ranking si riduce poco.
- Conferma che il feature noise degrada soprattutto la decisione a soglia fissa, non l'ordinamento probabilistico.

# K-Means: selezione del numero di cluster




- Esperimento non supervisionato: cosa trova un algoritmo basato solo sulla distanza?
- $k = 2$  scelto con elbow e silhouette (massima in  $k = 2$ ).

# K-Means




- $ARI \approx 0,006$ , purezza  $\approx 0,648$  (pari allo sbilanciamento nativo).
- I cluster dividono lo spazio lungo la varianza dominante, non la separazione fisica gamma/adrone.
- Le proprietà che distinguono le classi attraversano i cluster: nessun discriminante lineare.

# K-Means: robustezza al feature noise



ARI e silhouette al crescere del rumore.



I confini dei cluster diventano meno netti all'aumentare di  $\sigma$ .

Il feature noise degrada i cluster: silhouette 0,290  $\rightarrow$  0,102.

# K-Means: robustezza

- La vulnerabilità a un rumore dipende strettamente dalle informazioni che il modello sfrutta.
- Il label noise (devastante per i modelli supervisionati) è del tutto influente per K-Means, che ignora le etichette.
- Il feature noise, gestibile nel supervisionato grazie alla ridondanza, degrada la struttura geometrica su cui K-Means si fonda.

Ciò che è critico per un task può essere irrilevante per un altro: la robustezza è sempre relativa al modo in cui si usano i dati.

# Conclusioni: i rumori

- Esiste una chiara gerarchia di pericolosità:
  - trascurabili: outlier;
  - gestibili: feature noise, missing values (ridondanza e imputazione);
  - critici: missing feature e label noise.
- Missing feature e label noise sono gravi per ragioni opposte: il primo cancella informazione insostituibile, il secondo forza a memorizzare pattern errati.
- Il caso peggiore è il label noise borderline: falsifica direttamente il confine decisionale.
- Il degrado è spesso asimmetrico: a peggiorare è la classe minoritaria (adroni); il class weight della NN Pro la protegge.

# Conclusioni: modelli e preprocessing

- Nessun modello domina: la NN Pro vince sul rumore delle etichette, il Random Forest su valori mancanti e outlier, la NN Base è la più vulnerabile.
- La scelta del modello richiede un'analisi a priori sui tipi di errore attesi nel dominio reale.
- L'evidenza più forte: conta più il preprocessing della complessità algoritmica.
  - imputazione, winsorizzazione, early stopping recuperano gran parte del degrado.
- Ma nessun modello recupera un'informazione cancellata o falsificata nei punti più sensibili.

La robustezza si costruisce tramite cura del dato tanto quanto dalla scelta dell'algoritmo.

# Limiti e sviluppi futuri

- Il controllo multi-seed copre solo il feature noise: va esteso agli altri disturbi, in particolare al label noise.
- Soglia di decisione fissa a 0,5: ritrarla sul validation set potrebbe recuperare parte della recall sugli adroni.
- Iperparametri scelti sui dati puliti e mai ricalibrati sotto rumore.
- Alberi del Random Forest senza limite di profondità: limitarla dovrebbe ridurre la memorizzazione delle etichette invertite.
- Un solo dataset: la gerarchia osservata dipende anche dalla ridondanza tra le feature e dal ruolo di  $f_{\text{Alpha}}$ ; va confermata su dataset con struttura diversa.

Grazie per l'attenzione

Daniele Maccagnan    Matias Bonoli    Ashley Chudory

Studio di robustezza al rumore – MAGIC Gamma Telescope