

Studio di robustezza dei modelli di machine learning al rumore nei dati

Un'analisi sperimentale sul dataset MAGIC Gamma Telescope

Daniele Maccagnan Matias Bonoli Ashley Chudory

Università degli Studi di Milano-Bicocca
Progetto di Architetture Dati

Anno accademico 2025/2026

Indice

- 1 Introduzione
- 2 Dataset ed esplorazione
- 3 Modelli e baseline
- 4 Metodologia del rumore
- 5 Risultati per tipo di rumore
- 6 Controllo multi-seed
- 7 Sintesi e confronto tra modelli
- 8 Analisi non supervisionata (K-Means)
- 9 Conclusioni

Perché studiare la robustezza al rumore

- In ogni pipeline reale i dati **non sono perfetti**: misure imprecise, errori di annotazione, valori mancanti, anomalie, sensori guasti.
- La domanda non è *quale modello sia più accurato sui dati puliti*, ma **quanto ciascuno resiste** quando i dati si degradano.
- Obiettivo: capire **come** e **perché** le prestazioni peggiorano in funzione del tipo di disturbo introdotto.

Non cerchiamo un vincitore assoluto, ma il profilo di robustezza di ogni modello rispetto a ogni tipo di corruzione.

L'approccio sperimentale

Cosa facciamo

- Calcoliamo una *baseline* sui dati integri (0%).
- Corrompiamo il **solo training set** con sette tipi di rumore.
- Tre livelli di intensità crescente: 10%, 25%, 40%.
- Riaddestriamo i modelli ad ogni livello.


Come valutiamo

- Metriche sempre su un **test set pulito** e inalterato.
- Quattro metriche: accuratezza, F1 macro, recall macro, AUC.
- Tre modelli con difese crescenti contro il rumore.
- Un esperimento non supervisionato (K-Means) chiude lo studio.

Seme fissato ($seed = 42$) su tutte le componenti stocastiche $\Rightarrow$ piena riproducibilità.

Il dataset MAGIC Gamma Telescope

- Simulazioni Monte Carlo del telescopio Cherenkov MAGIC.
- Ogni record = traccia luminosa (ellittica) di un evento atmosferico.
- Task: classificazione binaria con significato fisico **gamma (segnale) vs adroni (fondo)**.
- 19 020 osservazioni, 10 feature continue + target.
- Mappatura classi: $h \rightarrow 0$ (adroni), $g \rightarrow 1$ (gamma).



Classi sbilanciate: 64,8% gamma, 35,2% adroni.

Le dieci feature continue

Feature	Descrizione
fLength	lunghezza dell'asse maggiore dell'ellisse
fWidth	lunghezza dell'asse minore dell'ellisse
fSize	logaritmo della somma delle intensità dei pixel
fConc	rapporto di concentrazione dei due pixel più intensi
fConc1	rapporto di concentrazione del pixel più intenso
fAsym	asimmetria della distribuzione lungo l'asse maggiore
fM3Long	momento terzo lungo l'asse maggiore
fM3Trans	momento terzo lungo l'asse minore
fAlpha	angolo tra asse maggiore e direzione del centro campo
fDist	distanza dal centro del campo all'origine dell'ellisse

*Le feature codificano **geometria** e **distribuzione di intensità** dell'immagine.*

Suddivisione dei dati e preprocessing

Split stratificato 60/20/20


- 11 412 train, 3 804 val, 3 804 test.
- Split *prima* di ogni analisi: niente **data leakage**.
- Stratificazione sul target: ogni partizione conserva il rapporto gamma/adroni.

Standardizzazione

- Media 0, deviazione 1.
- Parametri stimati **solo sul training**, applicati a val/test.
- Essenziale per la convergenza delle reti neurali.
- Un livello di rumore significa la stessa cosa per ogni feature.


EDA condotta solo sul training; rimosse 41 righe duplicate (0,4%) ai soli fini descrittivi.

EDA – Distribuzioni delle feature




Distribuzioni **asimmetriche** (*right-skewed*), code lunghe e scale eterogenee (da unità a centinaia) $\Rightarrow$ serve normalizzazione.

EDA – Potere discriminante (boxplot per classe)



fAlpha è la più discriminante; seguono fLength, fWidth, fSize. I momenti trasversali separano poco le classi.

EDA – Correlazioni tra le feature



- fConc/fConc1 quasi ridondanti (0,98).
- Anticorrelazione con fSize ($-0,85$).
- Terna fLength/fWidth/fSize correlata (0,70–0,77).
- **Ridondanza** $\Rightarrow$ il disturbo su una feature è in parte compensato dalle altre.
- fAlpha quasi scorrelata: **informazione unica e non vicariabile**.

I tre modelli: difese crescenti al rumore


- **NN Base** – MLP *ingenuo*: Dense(32)→Dense(16)→ sigmoide. Nessuna regolarizzazione, Adam 10^{-3} , 75 epoche. Libero di adattarsi anche ai pattern spuri (overfitting).
- **NN Pro** – stessa architettura + quattro difese:
 - regolarizzazione $L2$ (10^{-4});
 - *dropout* (0,2);
 - *class weight* bilanciato (a favore degli adroni);
 - *early stopping* sulla validation loss (patience 15).
- **Random Forest** – 200 alberi, *bagging* e voto di maggioranza: la varianza degli errori individuali si cancella.

Quattro metriche di valutazione (soglia 0,5): accuratezza, F1 macro, recall macro, AUC. Le macro pesano ugualmente le due classi.

Baseline su dati puliti – metriche


	Acc	F1 _m	AUC
NN Base	0,8678	0,8517	0,9214
NN Pro	0,8601	0,8468	0,9238
RF	0,8785	0,8629	0,9300

- Modelli quasi equivalenti, tutti sopra il 65%.
- **RF** il migliore su tutte le metriche.
- NN Pro cede accuratezza (class weight) ma ha **AUC più alta** della Base.




fAlpha domina la *feature importance* ($\approx 0,24$), coerente con i boxplot.

Baseline – matrici di confusione e curve



NN Base, NN Pro, Random Forest.



Curva NN Base: convergenza regolare.

*Tutti riconoscono bene i gamma; gli errori si concentrano sugli **adroni**. Gap train/validation contenuto: nessun overfitting marcato.*

Come iniettiamo il rumore

- Il rumore altera **solo il training set**; validation e test restano puliti $\Rightarrow$ valutiamo la vera generalizzazione.
- Per ogni rumore: riaddestramento ai tre livelli (10%, 25%, 40%) e valutazione sullo stesso test set.
- Iniezione sul training *già standardizzato*: per perturbazioni additive o monotone equivale a corrompere i dati originali.

Ogni corruzione è deliberata e quantificabile: il dataset di partenza è integro (nessun valore nullo nativo).

I sette meccanismi di rumore




- 1 **Feature noise** – rumore gaussiano $N(0, \sigma)$ aggiunto a tutte le feature (σ proporzionale al livello).
- 2 **Feature noise localizzato** – $\sigma = 0,35$ fisso, ma su un numero crescente di feature *importanti* (top-1 / top-3 / top-5).
- 3 **Label noise random** – etichette invertite a caso.
- 4 **Label noise borderline** – etichette invertite sui campioni *ambigui* (vicini al confine tra le classi).
- 5 **Missing values** – celle mancanti (NaN) da imputare (media vs mediana).
- 6 **Outlier** – righe a ± 5 deviazioni standard, segno casuale (strategie: nessuna / winsorizzazione / imputazione).
- 7 **Missing feature** – intere colonne azzerate (sensore guasto), su *tutti* i set, per importanza decrescente.

Feature noise – analisi

- Degrado **morbido e progressivo**: al 40% tutti i modelli restano sopra l'83% (calo di 3–4 punti).
- Al 40% vince la **NN Pro** (0,8417): L2 + dropout fanno da filtro contro le fluttuazioni stocastiche.
- La NN Base, senza vincoli, asseconda il rumore $\Rightarrow$ peggiora sui campioni ignoti.
- Decadimento **asimmetrico**: la recall adroni della Base crolla $0,77 \rightarrow 0,59$, mentre i gamma salgono $0,92 \rightarrow 0,97$.
- Il class weight della Pro sostiene la recall adroni a 0,73.




*La **ridondanza** tra feature attenua l'impatto: l'informazione corrotta è in parte dedotta dalle variabili correlate.*

Feature noise – evidenze grafiche



Accuratezza: pendenza lieve e omogenea.

NN Pro al 40%: train e validation appaiate.




NN Base, matrici di confusione a 10/25/40%: gli adroni scivolano verso i gamma.

Feature noise localizzato – analisi

- Intensità fissa ($\sigma = 0,35$), ma colpisce solo le feature più importanti: top-1 (fAlpha) $\rightarrow$ top-3 $\rightarrow$ top-5.
- Degrado comunque **lieve**: al 40% tutti sopra l'83%.
- Stessa asimmetria: recall adroni Base a 0,67, Pro a 0,75.
- **Contrasto chiave con il missing feature**:
 - *disturbare* fAlpha $\Rightarrow$ NN Base a 0,8651;
 - *azzerarla* $\Rightarrow$ crollo a 0,8215.



*Il rumore **degrada** l'informazione ma non la cancella: la rete attinge ancora alla geometria originale dei dati.*

Feature noise localizzato – evidenze grafiche




Accuratezza: curve vicine e quasi piatte.

Confusion Matrix — NN base — Feature noise localizzato Rumore 40%



F1 macro: stesso andamento del rumore diffuso.

Confusion Matrix — RF — Feature noise localizzato Rumore 40%




Matrici di confusione al 40%: NN Base (sinistra) e Random Forest (destra).

Label noise random – analisi


- Fino al 25% le metriche reggono; al 40% **cedimento drammatico**.
- Al 40%: NN Base $\rightarrow 0,7419$, RF $\rightarrow 0,7179$; la **NN Pro regge a 0,8044**.
- Causa nelle learning curves: la Base *memorizza* le etichette spurie (train $\approx 88\%$) mentre la validation pulita peggiora.
- L'**early stopping** della Pro ferma l'addestramento prima della memorizzazione di massa $\Rightarrow$ validation $\approx 82\%$.
- Il RF assimila i falsi target nei nodi: errore distribuito su entrambe le classi.

Qui la regolarizzazione fa la differenza: monitorare i dati puliti protegge dal rumore sulle etichette.


Label noise random – evidenze grafiche




Al 40% la NN Pro si stacca verso l'alto.



NN Pro al 40%: l'early stopping mantiene alta la validation.



NN Base al 40%: train sale, validation scende (memorizzazione).






RF al 40%: errori su entrambe le classi.

Label noise borderline – analisi

- Il disturbo **più distruttivo**: cala già al 25%, al 40% tutti scendono attorno al 60%.
- Sotto la soglia del classificatore banale ($\sim 65\%$): i modelli diventano **attivamente fuorvianti**.
- Invertire i campioni vicini al confine **sposta il confine decisionale** stesso $\Rightarrow$ letalità geometrica.
- Le learning curves della NN Pro non mostrano alcun vantaggio: regolarizzazione ed early stopping **non recuperano**.
- Danno **simmetrico** tra le classi: il ribilanciamento è vanificato.

A parità di flip, falsificare le istanze ambigue è molto più dannoso del rumore casuale: corrompe la struttura, non solo i dati.


Label noise borderline – evidenze grafiche




Al 40% tutti convergono verso il 60%: collasso predittivo.

NN Pro al 40%: crolla anche la validation.

Confusion Matrix — NN pro — Label noise borderline Rumore 40%



Confusion Matrix — RF — Label noise borderline Rumore 40%





Matrici al 40%: NN Pro (sinistra) e RF (destra), errori diffusi in modo simmetrico.

Missing values – analisi

- Celle sostituite con NaN; i modelli non leggono dati incompleti $\Rightarrow$ serve **imputazione**.
- Con la mediana (variante canonica) le metriche restano 82–85%: degrado **lineare e gestibile**.
- Il **Random Forest** è il più resistente (0,8528 al 40%): opera per divisioni, isola meglio le celle imputate.
- **Media vs mediana**: divario marginale e senza direzione univoca.
 - mediana lievemente meglio sulla Base ad alta corruzione;
 - media leggermente meglio sulla Pro; pari sul RF.

La mediana resta riferimento per robustezza teorica alle code, ma sul piano empirico la scelta incide poco.


Missing values – evidenze grafiche




Imputazione mediana: RF in vantaggio costante.

Media vs mediana (RF): praticamente equivalenti.

Confusion Matrix — NN base — Missing values (mediana) Rumore 40%



Confusion Matrix — RF — Missing values (mediana) Rumore 40%





Matrici al 40%: NN Base (sinistra) e RF (destra); gli errori pesano sugli adroni.

Outlier – analisi

- Il disturbo **meno dannoso**: l'accuratezza resta 85–87%, quasi nessuna tendenza al degrado.
- Motivo **nella natura del disturbo**, non nel trattamento: i valori $\pm 5\sigma$ hanno segno casuale e scorrelato dall'etichetta $\Rightarrow$ il loro contributo al gradiente si media a zero.
- Tre strategie quasi equivalenti: nessun trattamento, winsorizzazione, imputazione.
- Ad alta corruzione la winsorizzazione al 5% è in gran parte **inefficace** (i percentili stessi sono saturati).


*La robustezza nasce dall'**innocuità del disturbo** più che dalla mitigazione; teniamo la winsorizzazione per prudenza.*

Outlier – evidenze grafiche




Winsorizzazione: curve pressoché piatte.

Confusion Matrix — NN base — Outlier (winsorizzazione) Rumore 40%



RF: le tre strategie sono sovrapponibili.

Confusion Matrix — RF — Outlier (winsorizzazione) Rumore 40%





Matrici al 40%: prestazioni indistinguibili dal caso pulito.

Missing feature (sensore guasto) – analisi

- Intere colonne azzerate su *tutti* i set, per importanza: top-1 (f_{Alpha}) $\rightarrow$ top-3 $\rightarrow$ top-5.
- Esito **catastrofico**: già al 10% caduta di 4–5 punti; al 40% tutti tra il 70% e il 74%.
- Qui non c'è rumore da filtrare ma **informazione che non esiste più**: azzerare f_{Alpha} pesa più del feature noise massimo.
- **Controtendenza**: la NN Pro è la *meno* robusta (0,6995 al 40%): le difese contro l'overfitting irrigidiscono il modello quando manca informazione.


*f_{Alpha} è scorrelata dalle altre: la sua perdita è **insostituibile** e colpisce soprattutto gli adroni.*

Missing feature – evidenze grafiche




Rimuovere $f\alpha$: declino severo dal primo step.

Confusion Matrix — NN base — Missing feature Rumore 10%




RF al 40%: discriminazione adroni quasi azzerata.

Confusion Matrix — NN base — Missing feature Rumore 25%




Confusion Matrix — NN base — Missing feature Rumore 40%



NN Base, top-1/top-3/top-5: la capacità sugli adroni svanisce progressivamente.


Controllo multi-seed: il trend è reale?



- Feature noise ripetuto su **cinque** semi {42, 7, 123, 2024, 99}.
- Ogni seme governa rumore, split e inizializzazione.
- Deviazione standard sempre $< 0,007$ (max 0,0068).
- Un ordine di grandezza **sotto** il calo dovuto al rumore ($\sim 3,4$ punti per la NN Base).

*Le barre d'errore sono quasi impercettibili: il degrado è un **segnale reale**, non varianza procedurale.*


Multi-seed – F1 macro e gerarchia confermata



- Stesso ordinamento sulla metrica bilanciata.
- RF parte più in alto (0,8800) ma cede più rapidamente.
- La NN Pro ha il degrado **più graduale**.
- Le differenze sono coerenti tra i cinque semi.


L'ordinamento osservato non dipende dalle fluttuazioni del generatore stocastico.

Gerarchia di pericolosità dei rumori




outlier < feature noise $\approx$ missing values < label noise random $\approx$ missing feature < **label noise borderline.**

Degradazione e ranking complessivo



Barre piccole = maggiore tenuta al rumore.



Robustezza media (caso peggiore).

- NN Pro 0,785
- RF 0,780
- NN Base 0,778


Distanze trascurabili: **nessun vincitore netto.**

Chi vince su cosa

Scenario	Modello più robusto	Nota
Dati puliti	Random Forest	migliore su tutte le metriche
Feature noise	NN Pro	L2 + dropout filtrano il rumore
Label noise random	NN Pro	early stopping blocca la memorizzazione
Missing values	Random Forest	opera per divisioni
Outlier	tutti (pari)	disturbo quasi innocuo
Missing feature	Random Forest	NN Pro la <i>meno</i> robusta
Label borderline	nessuno	collasso generale ($\sim 60\%$)


*La scelta del modello dipende dal **tipo di errore atteso** nel dominio applicativo, non da una superiorità astratta.*

Curve ROC: il ranking resiste al feature noise




- Continue = dati puliti; tratteggiate = 40% feature noise.
- Lo scarto è limitato: il **potere di ranking** si erode poco.
- Conferma che il feature noise degrada soprattutto la decisione a soglia fissa, non l'ordinamento probabilistico.

K-Means: perché e come




- Esperimento **senza etichette**: cosa trova un algoritmo basato solo sulla distanza?
- $k = 2$ scelto con *elbow* (inerzia) e *silhouette* (massima in $k = 2$).
- La silhouette tende a premiare k piccoli: indizio, non prova.

K-Means: i cluster non sono le classi




- $ARI \approx 0,006$, purezza $\approx 0,648$ (pari allo sbilanciamento nativo).
- I cluster dividono lo spazio lungo la **varianza dominante**, non la separazione fisica gamma/adrone.
- Le proprietà che distinguono le classi attraversano i cluster: nessun discriminante lineare.

K-Means sotto rumore



ARI e silhouette al crescere del rumore.



I cluster si liquefanno all'aumentare di σ .

*Il **feature noise** sfuma i cluster (silhouette 0,290 $\rightarrow$ 0,102). Il **label noise** non li tocca ($ARI = 1,000$): K-Means non usa le etichette.*

K-Means: la lezione trasversale

- La vulnerabilità a un rumore dipende strettamente dalle **informazioni che il modello sfrutta**.
- Il label noise – devastante per i modelli supervisionati – è **del tutto ininfluenza** per K-Means, che ignora le etichette.
- Il feature noise – gestibile nel supervisionato grazie alla ridondanza – **degrada** la struttura geometrica su cui K-Means si fonda.

*Ciò che è critico per un task può essere irrilevante per un altro: la robustezza è sempre **relativa al modo in cui si usano i dati**.*

Conclusioni – i rumori

- Esiste una chiara **gerarchia di pericolosità**:
 - *trascurabili*: outlier;
 - *gestibili*: feature noise, missing values (ridondanza e imputazione);
 - *critici*: missing feature e label noise.
- Missing feature e label noise sono gravi per ragioni **opposte**: il primo cancella informazione insostituibile, il secondo forza a memorizzare pattern errati.
- Il caso peggiore è il **label noise borderline**: falsifica direttamente il confine decisionale.
- Il degrado è spesso **asimmetrico**: a peggiorare è la classe minoritaria (adroni); il class weight della NN Pro la protegge.

Conclusioni – i modelli e il preprocessing

- **Nessun modello domina:** la NN Pro vince sul rumore delle etichette, il Random Forest su valori mancanti e outlier, la NN Base è la più esposta.
- La scelta del modello richiede un'analisi *a priori* sui tipi di errore attesi nel dominio reale.
- L'evidenza più forte: conta **più il preprocessing** della complessità algoritmica.
 - imputazione, winsorizzazione, early stopping recuperano gran parte del degrado.
- Ma nessun modello recupera un'informazione **cancellata** o **falsificata** nei punti più sensibili.

La robustezza si costruisce a monte (cura del dato) tanto quanto a valle (scelta dell'algoritmo).

Grazie per l'attenzione

Daniele Maccagnan Matias Bonoli Ashley Chudory

Studio di robustezza al rumore – MAGIC Gamma Telescope