

Studio di robustezza dei modelli di machine learning al rumore nei dati

Un'analisi sperimentale sul dataset MAGIC Gamma Telescope

Daniele Maccagnan Matias Bonoli Ashley Chudory

Università degli Studi di Milano-Bicocca
Progetto di Architetture Dati

Anno accademico 2025/2026

Indice

- 1 Introduzione
- 2 Dataset ed esplorazione
- 3 Modelli e baseline
- 4 Metodologia del rumore
- 5 Risultati per tipo di rumore
- 6 Sintesi trasversale
- 7 Analisi non supervisionata
- 8 Conclusioni

Introduzione


In ogni pipeline reale i dati non sono perfetti: misure imprecise, errori di annotazione, valori mancanti, anomalie.

- Non chiediamo quale modello sia più accurato sui dati puliti, ma quanto ciascuno resiste quando i dati si degradano.
- Corrompiamo il training set in modo progressivo con sei tipi di rumore, a tre livelli: 10%, 25%, 40%.
- Tre modelli a confronto: rete neurale semplice (NN Base), rete regolarizzata (NN Pro), Random Forest.
- Metriche sempre sul test set pulito: accuratezza, F1 macro, AUC.
- Un esperimento non supervisionato (K-Means) chiude lo studio.

Seme fissato (seed = 42) su tutte le componenti stocastiche.

Il dataset MAGIC Gamma Telescope


- Simulazioni Monte Carlo del telescopio Cherenkov MAGIC.
- Classificazione binaria: gamma (segnale) vs adroni (fondo).
- 19 020 osservazioni, 10 feature continue.
- Classi sbilanciate: 64,8% gamma, 35,2% adroni.
- Riferimento: un classificatore banale arriva già al $\sim 65\%$.



Suddivisione e preprocessing

- Split stratificato 60/20/20: 11 412 train, 3 804 val, 3 804 test.
- Analisi esplorativa e statistiche di preprocessing solo sul training set (niente *data leakage*).
- Rimosse 41 righe duplicate dal training.
- Standardizzazione (media 0, deviazione 1): un livello di rumore significa la stessa cosa per ogni feature.


Analisi esplorativa: separabilità



fAlpha è la più discriminante; i momenti trasversali separano poco.

Analisi esplorativa: correlazioni

Matrice di Correlazione



- fConc/fConc1 quasi ridondanti (0,98).
- Terna fLength/fWidth/fSize correlata.
- Ridondanza $\Rightarrow$ il disturbo su una feature è in parte compensato dalle altre.
- fAlpha quasi scorrelata: informazione unica.

I tre modelli


- **NN Base:** Dense(32)→Dense(16)→sigmoide, nessuna regolarizzazione. Il modello ingenuo.
- **NN Pro:** stessa architettura + L2, dropout 0,2, class weight bilanciato, early stopping.
- **Random Forest:** 200 alberi, aggregazione per voto.

Difese crescenti contro il rumore: ci aspettiamo NN Base la più esposta.

Baseline su dati puliti

	Acc	F1 _m	AUC
NN Base	0,8678	0,8517	0,9214
NN Pro	0,8601	0,8468	0,9238
RF	0,8785	0,8629	0,9300

Modelli quasi equivalenti, tutti sopra il 65%. La NN Pro cede accuratezza ma ha già AUC più alta.






fAlpha domina la feature importance.

I sei meccanismi di rumore

- **Feature noise**: rumore gaussiano sulle feature.
- **Label noise random**: etichette invertite a caso.
- **Label noise borderline**: etichette invertite sui campioni ambigui.
- **Missing values**: celle mancanti (NaN) da imputare.
- **Outlier**: valori estremi da trattare.
- **Missing feature**: sensori guasti, feature azzerate.

Il rumore colpisce solo il training; validation e test restano puliti. Per ogni rumore riaddestriamo i tre modelli ai quattro livelli.

Feature noise






Degrado lieve (al 40% sopra l'83%). La NN Pro è la più stabile: L2 e dropout evitano l'adattamento al rumore.

Feature noise localizzato




- Rumore a intensità fissa ($\sigma = 0,35$) solo sulle feature più importanti (le stesse del missing feature).
- Degrado lieve: al 40% (cinque feature, tra cui f_{Alpha}) tutti sopra l'83%.
- Contrasto chiave con il missing feature: disturbare f_{Alpha} lascia la NN Base a 0,8651, azzerarla la fa crollare a 0,8215.
- Il rumore degrada l'informazione, non la cancella: la ridondanza la recupera.

Label noise random





Al 40% NN Base e RF crollano ($\sim 0,72$); la NN Pro regge (0,8044): l'early stopping blocca la memorizzazione delle etichette sbagliate.

Label noise borderline





Il disturbo più dannoso: al 40% tutti i modelli scendono attorno al 60%. Invertire i campioni ambigui sposta il confine decisionale; nemmeno l'early stopping recupera.

Missing values




Con l'imputazione il degrado è moderato (al 40% tra 82 e 85%). Il Random Forest è il più resistente (0,8528); la mediana batte di poco la media.

Outlier




Il disturbo meno dannoso: con la winsorizzazione le curve sono quasi piatte. Outlier solo nel training + dati standardizzati $\Rightarrow$ effetto limitato.

Missing feature (sensore guasto)




Confusion Matrix — RF — Missing feature Rumore 40%





Calo severo già al 10% (sola $f\alpha$). Qui non c'è rumore da filtrare ma informazione che non esiste più: la NN Pro è la meno robusta.

Gerarchia di pericolosità




outlier < feature noise $\approx$ missing values < label noise random $\approx$ missing feature < label noise borderline.

Degradazione e ranking




Robustezza media (caso peggiore): NN Pro 0,785, RF 0,780, NN Base 0,778. Nessun vincitore netto.

Curve ROC e controllo multi-seed





- ROC: il feature noise erode poco il potere di ranking.
- Controllo su cinque semi (feature noise): medie in linea col seme singolo.
- Deviazione standard sempre sotto 0,007: il calo è un segnale reale, non rumore da seme.

K-Means: i cluster non sono le classi



- $k = 2$ scelto e verificato con elbow e silhouette.
- $ARI \approx 0,006$, purezza 0,648.
- I cluster dividono lo spazio lungo la varianza dominante, non la separazione fisica gamma/adrone.

K-Means sotto rumore



Il feature noise sfuma i cluster (silhouette 0,290 $\rightarrow$ 0,102). Il label noise non li tocca (ARI = 1,000): K-Means non usa le etichette.

Conclusioni

- I rumori hanno gravità diversa: outlier trascurabili, feature noise e valori mancanti gestibili, missing feature e label noise i più gravi.
- Il caso peggiore è il label noise borderline: falsifica il confine decisionale.
- Nessun modello domina: la NN Pro vince sul rumore delle etichette, il Random Forest su valori mancanti e outlier.
- Conta più il preprocessing del modello: imputare con la mediana, winsorizzare, fermare l'addestramento sulla validation recuperano molto.
- Nessun modello recupera un'informazione cancellata o falsificata nel punto più sensibile.

Grazie per l'attenzione

Daniele Maccagnan Matias Bonoli Ashley Chudory