

Studio di robustezza dei modelli di machine learning al rumore nei dati

Un'analisi sperimentale sul dataset MAGIC Gamma Telescope

Daniele Maccagnan Matias Bonoli Ashley Chudory

Anno accademico 2025/2026

Indice

- 1 Introduzione
- 2 Dataset ed esplorazione
- 3 Modelli e baseline
- 4 Metodologia del rumore
- 5 Risultati per tipo di rumore
- 6 Controllo multi-seed
- 7 Sintesi e confronto tra modelli
- 8 Analisi non supervisionata (K-Means)
- 9 Conclusioni

Perché studiare la robustezza al rumore

- Nei sistemi reali i dati non sono mai perfetti: misure imprecise, errori di annotazione, valori mancanti, anomalie, sensori guasti.
- La domanda non è quale modello sia più accurato sui dati puliti, ma quanto ciascuno resiste quando i dati si degradano.
- Obiettivo: capire come e perché le prestazioni peggiorano in funzione del tipo di disturbo introdotto.

Approccio sperimentale

Cosa facciamo

- Calcoliamo una baseline sui dati integri.
- Corrompiamo il solo training set con sette tipi di rumore.
- Tre livelli di intensità crescente: 10%, 25%, 40%.
- Riaddestriamo i modelli ad ogni livello.


Come valutiamo

- Metriche sempre su un test set pulito e inalterato.
- Quattro metriche: accuratezza, F1 macro, recall macro, AUC.
- Tre modelli con difese crescenti contro il rumore.
- Un esperimento non supervisionato.

Seme fissato (seed = 42) su tutte le componenti stocastiche per la riproducibilità.

Il dataset MAGIC Gamma Telescope

- Simulazioni Monte Carlo del telescopio Cherenkov MAGIC.
- Ogni record è una traccia luminosa di un evento atmosferico.
- Classificazione binaria: gamma (1) vs adroni (0).
- 19 020 osservazioni, 10 feature continue + target.



Classi sbilanciate: 64,8% gamma, 35,2% adroni.

Le dieci feature continue

Feature	Descrizione
fLength	lunghezza dell'asse maggiore dell'ellisse
fWidth	lunghezza dell'asse minore dell'ellisse
fSize	logaritmo della somma delle intensità dei pixel
fConc	rapporto di concentrazione dei due pixel più intensi
fConc1	rapporto di concentrazione del pixel più intenso
fAsym	asimmetria della distribuzione lungo l'asse maggiore
fM3Long	momento terzo lungo l'asse maggiore
fM3Trans	momento terzo lungo l'asse minore
fAlpha	angolo tra asse maggiore e direzione del centro campo
fDist	distanza dal centro del campo all'origine dell'ellisse

Le feature codificano geometria e distribuzione di intensità dell'immagine.


Suddivisione dei dati

Split stratificato 60/20/20

- 11 412 train, 3 804 val, 3 804 test.
- Split prima di ogni analisi: niente data leakage.
- Stratificazione sul target: ogni partizione conserva il rapporto gamma/adroni.


EDA condotta solo sul training

EDA: Distribuzioni delle feature



Distribuzioni asimmetriche, code lunghe e scale eterogenee da unità a centinaia.


EDA: boxplot per classe



fAlpha è la più discriminante; seguono fLength, fWidth, fSize. Le restanti feature separano meno le classi.

EDA: Correlazioni

Matrice di Correlazione



- fConc/fConc1 quasi ridondanti (0,98).
- Anticorrelazione con fSize ($-0,85$).
- fLength/fWidth/fSize correlate (0,70–0,77).
- Vi è ridondanza di informazione: il disturbo su una feature è in parte compensato dalle altre.
- fAlpha quasi scorrelata: informazione unica e non sostituibile.

Preprocessing

Standardizzazione

- Normalizzazione del dataset: media 0, deviazione standard 1.
- Parametri stimati solo sul training, applicati a val/test: no data leakage.
- Essenziale per la convergenza delle reti neurali.

I tre modelli


- **NN Base** – Rete neurale semplice: Dense(32)→Dense(16)→ sigmoide. Nessuna regolarizzazione, Adam 10^{-3} , 75 epoche. Libero di andare in overfitting.
- **NN Pro** – stessa architettura + quattro difese:
 - regolarizzazione L2 (10^{-4});
 - dropout (0,2);
 - class weight bilanciato a favore degli adroni;
 - early stopping sulla validation loss con patience 15.
- **Random Forest** – 200 alberi, bagging e voto di maggioranza: la varianza degli errori individuali si cancella.

Quattro metriche di valutazione principali: accuratezza, F1 macro, recall macro, AUC. Le macro pesano ugualmente le due classi.

Baseline su dati puliti




	Acc	F1 _m	AUC
NN Base	0,8678	0,8517	0,9214
NN Pro	0,8601	0,8468	0,9238
RF	0,8785	0,8629	0,9300

- Modelli quasi equivalenti, tutti ben oltre la soglia banale del 65%.
- RF il migliore su tutte le metriche.
- NN Pro cede accuratezza (class weight) ma ha AUC più alta della rete Base.



fAlpha domina la feature importance ($\approx 0,24$), coerente con i boxplot.



Baseline: matrici di confusione



NN Base, NN Pro, Random Forest.

Tutti riconoscono bene i gamma; gli errori si concentrano sugli adroni.

Baseline: curva di addestramento



Curva NN Base: convergenza regolare, gap train / validation contenuto – nessun overfitting marcato.


Come iniettiamo il rumore

- Il rumore altera solo il training set; validation e test restano puliti $\Rightarrow$ valutiamo la vera generalizzazione.
- Per ogni rumore: riaddestramento ai tre livelli (10%, 25%, 40%) e valutazione sullo stesso test set.
- Iniezione sul training già standardizzato: per perturbazioni additive o monotone equivale a corrompere i dati originali.

I sette meccanismi di rumore

- 1 **Feature noise**: rumore gaussiano $N(0, \sigma)$ aggiunto a tutte le feature con σ proporzionale al livello.
- 2 **Feature noise localizzato**: $\sigma = 0,35$ fisso, ma su un numero crescente di feature importanti (top-1 / top-3 / top-5).
- 3 **Label noise random**: etichette invertite a caso.
- 4 **Label noise borderline**: etichette invertite sui campioni ambigui vicini al centroidi tra le classi.
- 5 **Missing values**: celle mancanti (NaN) da imputare con media o mediana.
- 6 **Outlier**: righe a ± 5 deviazioni standard, segno casuale (strategie: nessuna / winsorizzazione / imputazione).
- 7 **Missing feature**: intere colonne azzerate, su tutti i set, per importanza decrescente.

L'effetto dei disturbi su una feature



fAlpha standardizzata: dati puliti e tre disturbi al 40%. Il rumore gaussiano allarga la distribuzione, gli outlier creano due picchi agli estremi, l'imputazione concentra molti campioni su un unico valore.


Feature noise

- Degrado graduale: al 40% tutti i modelli restano sopra l'83% (calo di 3–4 punti).
- Al 40% vince la NN Pro (0,8417): L2 + dropout impediscono di apprendere le fluttuazioni casuali.
- La NN Base, senza vincoli, si adatta al rumore e peggiora sui campioni nuovi.
- Degrado asimmetrico: la recall adroni della Base crolla $0,77 \rightarrow 0,59$, mentre quella dei gamma sale $0,92 \rightarrow 0,97$.
- Il class weight della Pro sostiene la recall degli adroni a 0,73.


Feature noise: metriche e matrici di confusione

Rumore	NN Base			NN Pro			Random Forest		
	Acc	F1 _m	AUC	Acc	F1 _m	AUC	Acc	F1 _m	AUC
Pulito	0,8678	0,85	0,9214	0,8601	0,85	0,9238	0,8785	0,86	0,9300
10%	0,8657	0,85	0,9187	0,8636	0,85	0,9204	0,8646	0,84	0,9222
25%	0,8520	0,83	0,9074	0,8465	0,83	0,9071	0,8494	0,82	0,9041
40%	0,8328	0,80	0,8941	0,8417	0,82	0,8940	0,8318	0,80	0,8913


Confusion Matrix — NN base — Feature noise Rumore 40%



Confusion Matrix — NN pro — Feature noise Rumore 40%




Confusion Matrix — RF — Feature noise Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest.

Feature noise: curve di addestramento



Feature noise: evidenze grafiche



Feature noise localizzato


- Stesso $\sigma = 0,35$ del rumore diffuso, ma concentrato solo sulle feature più informative: top-1 (fAlpha) $\rightarrow$ top-3 $\rightarrow$ top-5.
- Degrado **ancora più lieve**: al 40% vince la **NN Base** (0,8452), sopra tutti i risultati del rumore diffuso.
- La ridondanza tra feature (vista in EDA) assorbe il colpo: poche feature corrotte non bastano a confondere il modello.
- Resta **asimmetria**, ma attenuata: recall adroni 0,67 in NN Base, 0,75 in NN Pro (contro 0,59 e 0,73 del rumore diffuso).

Colpire le feature più importanti non è peggio che colpirle tutte: l'informazione persa è compensata da quella ridondante rimasta pulita.


Feature noise localizzato: metriche e matrici di confusione

Rumore	NN Base			NN Pro			Random Forest		
	Acc	F1 _m	AUC	Acc	F1 _m	AUC	Acc	F1 _m	AUC
Pulito	0,8678	0,85	0,9214	0,8601	0,85	0,9238	0,8785	0,86	0,9300
10%	0,8651	0,85	0,9211	0,8651	0,85	0,9243	0,8743	0,86	0,9274
25%	0,8523	0,83	0,9043	0,8478	0,83	0,9058	0,8533	0,83	0,9056
40%	0,8452	0,82	0,8991	0,8386	0,82	0,8973	0,8389	0,81	0,8931

Confusion Matrix — NN base — Feature noise localizzato Rumore 40%




Confusion Matrix — RF — Feature noise localizzato Rumore 40%




Matrici di confusione al 40%: NN Base (sinistra) e Random Forest (destra).

Feature noise localizzato: curve di addestramento




Curve al 40%: NN Base (sinistra) vs NN Pro (destra).

Feature noise localizzato: confronto tra modelli



Accuratezza: curve vicine e quasi piatte.



F1 macro: stesso andamento del rumore diffuso.

Label noise random


- Fino al 25% le metriche reggono; al 40% il peggioramento è marcato.
- Al 40%: NN Base $\rightarrow$ 0,7419, RF $\rightarrow$ 0,7179; la NN Pro a 0,8044.
- La causa si vede nelle learning curves: la rete Base memorizza le etichette errate (train all' 88%) mentre la validation pulita peggiora.
- L'early stopping della Pro ferma l'addestramento prima della memorizzazione del rumore: validation all' 82%.
- Il RF memorizza le etichette errate nei nodi: errore distribuito su entrambe le classi.

Qui la regolarizzazione fa la differenza: monitorare i dati puliti protegge dal rumore sulle etichette.


Label noise random: metriche e matrici di confusione

Rumore	NN Base			NN Pro			Random Forest		
	Acc	F1 _m	AUC	Acc	F1 _m	AUC	Acc	F1 _m	AUC
Pulito	0,8678	0,85	0,9214	0,8601	0,85	0,9238	0,8785	0,86	0,9300
10%	0,8623	0,84	0,9128	0,8570	0,84	0,9200	0,8767	0,86	0,9214
25%	0,8410	0,82	0,8882	0,8378	0,83	0,9081	0,8399	0,82	0,8884
40%	0,7419	0,69	0,7513	0,8044	0,79	0,8677	0,7179	0,70	0,7673


Confusion Matrix — NN base — Label noise random Rumore 40%



Confusion Matrix — NN pro — Label noise random Rumore 40%




Confusion Matrix — RF — Label noise random Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest.

Label noise random: curve di addestramento



Label noise random: confronto tra modelli



Label noise borderline


- Il disturbo più distruttivo: cala già al 25%, al 40% tutti scendono attorno al 60%.
- Sotto la soglia del classificatore banale ($\sim 65\%$): i modelli diventano completamente errati.
- Invertire i campioni vicini al confine sposta il confine decisionale appreso.
- Le learning curves della NN Pro non mostrano alcun vantaggio: regolarizzazione ed early stopping non recuperano.
- Danno simmetrico tra le classi.

A parità di inversioni, falsificare le istanze ambigue è molto più dannoso del rumore casuale: corrompe la struttura, non solo i dati.


Label noise borderline: metriche e matrici di confusione

	NN Base			NN Pro			Random Forest		
Rumore	Acc	F1 _m	AUC	Acc	F1 _m	AUC	Acc	F1 _m	AUC
Pulito	0,8678	0,85	0,9214	0,8601	0,85	0,9238	0,8785	0,86	0,9300
10%	0,8252	0,80	0,8680	0,8352	0,82	0,8915	0,8383	0,81	0,8886
25%	0,7326	0,71	0,7879	0,7403	0,72	0,8265	0,7387	0,72	0,8043
40%	0,6002	0,59	0,6656	0,6354	0,62	0,7084	0,6094	0,60	0,6774


Confusion Matrix — NN base — Label noise borderline Rumore 40%



Confusion Matrix — NN pro — Label noise borderline Rumore 40%




Confusion Matrix — RF — Label noise borderline Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest – errori diffusi in modo simmetrico.

Label noise borderline: curve di addestramento



Label noise borderline: grafici e confronto tra modelli



Al 40% tutti convergono verso il 60%: collasso predittivo.

Missing values


- Celle sostituite con NaN; i modelli non leggono dati incompleti quindi serve imputazione.
- Con la mediana le metriche restano 82–85%: degrado lineare e gestibile.
- Il Random Forest è il più resistente (0,8528 al 40%): opera per divisioni, isola meglio le celle imputate.
- **Media vs mediana**: divario marginale e senza direzione univoca.
 - mediana lievemente meglio sulla Base ad alta corruzione;
 - media leggermente meglio sulla Pro; pari sul RF.

La mediana resta riferimento per robustezza teorica alle code, ma sul piano empirico la scelta incide poco.


Missing values: metriche e matrici di confusione

Rumore	NN Base			NN Pro			Random Forest		
	Acc	F1 _m	AUC	Acc	F1 _m	AUC	Acc	F1 _m	AUC
Pulito	0,8678	0,85	0,9214	0,8601	0,85	0,9238	0,8785	0,86	0,9300
10%	0,8617	0,84	0,9172	0,8570	0,84	0,9190	0,8720	0,85	0,9208
25%	0,8425	0,83	0,9057	0,8328	0,82	0,9046	0,8578	0,84	0,9129
40%	0,8328	0,81	0,8915	0,8226	0,81	0,8937	0,8528	0,83	0,9039

Confusion Matrix — NN base — Missing values (mediana) Rumore 40%





Confusion Matrix — RF — Missing values (mediana) Rumore 40%




Matrici al 40%: NN Base (sinistra) e RF (destra); gli errori pesano sugli adroni.

Missing values: curve di addestramento



NN Base al 40% di valori mancanti: convergenza regolare, nessun overfitting marcato.

Missing values: grafici e confronto tra modelli



Imputazione mediana: RF in vantaggio costante.

Outlier


- Il disturbo meno dannoso: l'accuratezza resta 85–87%, quasi nessuna tendenza al degrado.
- Motivo nella natura del disturbo, non nel trattamento: i valori $\pm 5\sigma$ hanno segno casuale e scorrelato dall'etichetta quindi il loro contributo al gradiente si media a zero.
- Le metriche delle tre strategie quasi equivalenti: nessun trattamento, winsorizzazione, imputazione.
- Ad alta corruzione la winsorizzazione al 5% è in gran parte inefficace.

La robustezza nasce dalla natura poco dannosa del disturbo più che dalla mitigazione; teniamo comunque la winsorizzazione come baseline.


Outlier: metriche e matrici di confusione

	NN Base			NN Pro			Random Forest		
Rumore	Acc	$F1_m$	AUC	Acc	$F1_m$	AUC	Acc	$F1_m$	AUC
Pulito	0,8678	0,85	0,9214	0,8601	0,85	0,9238	0,8785	0,86	0,9300
10%	0,8657	0,85	0,9196	0,8583	0,84	0,9220	0,8788	0,86	0,9295
25%	0,8628	0,84	0,9160	0,8441	0,83	0,9173	0,8751	0,86	0,9267
40%	0,8615	0,84	0,9116	0,8541	0,84	0,9201	0,8736	0,86	0,9250

Confusion Matrix — NN base — Outlier (winsorizzazione) Rumore 40%





Confusion Matrix — RF — Outlier (winsorizzazione) Rumore 40%





Matrici al 40%: prestazioni indistinguibili dal caso pulito.

Outlier: curve di addestramento



NN Base al 40% di outlier: convergenza regolare, nessun impatto visibile sull'addestramento.

Outlier: grafici e confronto tra modelli



Winsorizzazione: curve pressoché piatte.

Missing feature


- Intere colonne azzerate su tutti i set, per importanza.
- Esito molto grave: già al 10% un calo di 4–5 punti; al 40% tutti attorno al 70%.
- Qui non c'è rumore da filtrare ma informazione che non esiste più: azzerare f_{Alpha} pesa più del feature noise massimo.
- La NN Pro è la meno robusta (0,6995 al 40%): le difese contro l'overfitting irrigidiscono il modello quando manca informazione.

f_{Alpha} è scorrelata dalle altre: la sua perdita è insostituibile e colpisce soprattutto gli adroni.


Missing feature: metriche e matrici di confusione

Rumore	NN Base			NN Pro			Random Forest		
	Acc	$F1_m$	AUC	Acc	$F1_m$	AUC	Acc	$F1_m$	AUC
Pulito	0,8678	0,85	0,9214	0,8601	0,85	0,9238	0,8785	0,86	0,9300
10%	0,8215	0,79	0,8675	0,8052	0,79	0,8716	0,8294	0,80	0,8788
25%	0,7773	0,74	0,8007	0,7574	0,73	0,7991	0,7836	0,75	0,8195
40%	0,7303	0,67	0,7413	0,6995	0,67	0,7347	0,7363	0,68	0,7494


Confusion Matrix — NN base — Missing feature Rumore 40%



Confusion Matrix — NN pro — Missing feature Rumore 40%




Confusion Matrix — RF — Missing feature Rumore 40%





Matrici di confusione al 40%: NN Base, NN Pro, Random Forest – discriminazione adroni quasi azzerata.

Missing feature: curve di addestramento



Missing feature: grafici e confronto tra modelli





Rimuovere f_{α} : declino severo dal primo step.

Controllo multi-seed

- Feature noise ripetuto su cinque semi $\{42, 7, 123, 2024, 99\}$.
- Ogni seme governa rumore, split e inizializzazione.
- Deviazione standard sempre $< 0,007$ (max 0,0068).
- Un ordine di grandezza sotto il calo dovuto al rumore ($\sim 3,4$ punti per la NN Base).


Le barre d'errore sono quasi impercettibili: il degrado è un segnale reale, non varianza dal seed.

Multi-seed: grafici e confronti




L'ordinamento osservato non dipende dalle fluttuazioni del generatore stocastico.

Gerarchia di pericolosità dei rumori




outlier < feature noise $\approx$ missing values < label noise random $\approx$ missing feature < label noise borderline.

Degradazione e ranking complessivo



Barre piccole = maggiore tenuta al rumore.



Robustezza media (caso peggiore).


- NN Pro 0,785
- RF 0,780
- NN Base 0,778

Distanze trascurabili: nessun vincitore netto.

Classificazione dei modelli per scenario


Scenario	Modello più robusto	Nota	La scelta del modello
Dati puliti	Random Forest	migliore su tutte le metriche	
Feature noise	NN Pro	L2 + dropout filtrano il rumore	
Label noise random	NN Pro	early stopping blocca la memorizzazione	
Missing values	Random Forest	opera per divisioni	
Outlier	tutti (pari)	disturbo quasi innocuo	
Missing feature	Random Forest	NN Pro la meno robusta	
Label borderline	nessuno	collasso generale ($\sim 60\%$)	
dipende dal tipo di errore atteso nel dominio applicativo, non da una superiorità astratta.			

Curve ROC




- Continue: dati puliti; tratteggiate: 40% feature noise.
- Lo scarto è limitato: il potere di ranking si riduce poco.
- Conferma che il feature noise degrada soprattutto la decisione a soglia fissa, non l'ordinamento probabilistico.

K-Means: selezione del numero di cluster




- Esperimento non supervisionato: cosa trova un algoritmo basato solo sulla distanza?
- $k = 2$ scelto con elbow e silhouette (massima in $k = 2$).

K-Means




- $ARI \approx 0,006$, purezza $\approx 0,648$ (pari allo sbilanciamento nativo).
- I cluster dividono lo spazio lungo la varianza dominante, non la separazione fisica gamma/adrone.
- Le proprietà che distinguono le classi attraversano i cluster: nessun discriminante lineare.

K-Means: robustezza al feature noise



ARI e silhouette al crescere del rumore.



I confini dei cluster diventano meno netti all'aumentare di σ .

Il feature noise degrada i cluster: silhouette 0,290 $\rightarrow$ 0,102.

K-Means: robustezza

- La vulnerabilità a un rumore dipende strettamente dalle informazioni che il modello sfrutta.
- Il label noise (devastante per i modelli supervisionati) è del tutto influente per K-Means, che ignora le etichette.
- Il feature noise, gestibile nel supervisionato grazie alla ridondanza, degrada la struttura geometrica su cui K-Means si fonda.

Ciò che è critico per un task può essere irrilevante per un altro: la robustezza è sempre relativa al modo in cui si usano i dati.

Conclusioni: i rumori

- Esiste una chiara gerarchia di pericolosità:
 - trascurabili: outlier;
 - gestibili: feature noise, missing values (ridondanza e imputazione);
 - critici: missing feature e label noise.
- Missing feature e label noise sono gravi per ragioni opposte: il primo cancella informazione insostituibile, il secondo forza a memorizzare pattern errati.
- Il caso peggiore è il label noise borderline: falsifica direttamente il confine decisionale.
- Il degrado è spesso asimmetrico: a peggiorare è la classe minoritaria (adroni); il class weight della NN Pro la protegge.

Conclusioni: modelli e preprocessing

- Nessun modello domina: la NN Pro vince sul rumore delle etichette, il Random Forest su valori mancanti e outlier, la NN Base è la più vulnerabile.
- La scelta del modello richiede un'analisi a priori sui tipi di errore attesi nel dominio reale.
- L'evidenza più forte: conta più il preprocessing della complessità algoritmica.
 - imputazione, winsorizzazione, early stopping recuperano gran parte del degrado.
- Ma nessun modello recupera un'informazione cancellata o falsificata nei punti più sensibili.

La robustezza si costruisce tramite cura del dato tanto quanto dalla scelta dell'algoritmo.

Limiti e sviluppi futuri

- Il controllo multi-seed copre solo il feature noise: va esteso agli altri disturbi, in particolare al label noise.
- Soglia di decisione fissa a 0,5: ritarla sul validation set potrebbe recuperare parte della recall sugli adroni.
- Iperparametri scelti sui dati puliti e mai ricalibrati sotto rumore.
- Alberi del Random Forest senza limite di profondità: limitarla dovrebbe ridurre la memorizzazione delle etichette invertite.
- Un solo dataset: la gerarchia osservata dipende anche dalla ridondanza tra le feature e dal ruolo di f_{Alpha} ; va confermata su dataset con struttura diversa.

Grazie per l'attenzione

Daniele Maccagnan Matias Bonoli Ashley Chudory

Studio di robustezza al rumore – MAGIC Gamma Telescope