

UNIVERSITÀ DEGLI STUDI DI MILANO - BICOCCA

Dipartimento di Informatica, Sistemistica e Comunicazione (DISCo)

Corso di laurea in Data Science

Studio di robustezza dei modelli di machine learning al rumore nei dati

Progetto di *Architetture Dati*

Un'analisi sperimentale sul dataset MAGIC Gamma Telescope

Autori

Daniele Maccagnan – matricola [matricola]

Matias Bonoli – matricola [matricola]

Ashley Chudory – matricola [matricola]

Anno accademico 2025/2026

Indice

1	Introduzione	2
2	Il dataset	2
3	Suddivisione in training, validation e test	3
4	Analisi esplorativa dei dati	3
5	Preprocessing: standardizzazione	7
6	Modelli	7
7	Baseline su dati puliti	9
8	Metodologia di iniezione del rumore	11
8.1	I sette tipi di rumore	11
9	Risultati per tipo di rumore	12
9.1	Feature noise	12
9.2	Feature noise localizzato	15
9.3	Label noise random	17
9.4	Label noise borderline	20
9.5	Missing values	23
9.6	Outlier	25
9.7	Missing feature (sensore guasto)	27
10	Sintesi trasversale	29
10.1	Controllo multi-seed	32
11	Analisi non supervisionata (K-Means)	34
12	Conclusioni	36

1 Introduzione

Nelle pipeline applicative reali, la presenza di imperfezioni nei dati — come misurazioni imprecise, errori di annotazione, valori mancanti e anomalie — rappresenta la norma. L’obiettivo di questa analisi non è identificare il modello in grado di raggiungere l’accuratezza massima sui dati ideali, bensì quantificare la resilienza di ciascun algoritmo al progressivo degrado delle informazioni. A tale scopo, viene misurata la robustezza di tre modelli supervisionati corrompendo il training set in modo controllato, attraverso sette diverse tipologie di rumore.

Il fine ultimo non è decretare un singolo modello vincitore, ma comprendere le dinamiche e le cause del degrado prestazionale in funzione del tipo di disturbo. Il protocollo sperimentale prevede la definizione di una baseline sui dati integri; successivamente, i modelli vengono riaddestrati su versioni del training set alterate a tre livelli di intensità crescente: 10%, 25% e 40%. Le metriche di valutazione vengono sempre calcolate su un test set mantenuto pulito e inalterato. I tre modelli analizzati sono una rete neurale standard (*NN Base*), una variante dotata di meccanismi di regolarizzazione (*NN Pro*) e un *Random Forest*. I sette disturbi introdotti agiscono su feature, etichette, valori mancanti, outlier e disponibilità stessa delle variabili. Viene inoltre integrato un esperimento non supervisionato (K-Means) per osservare l’impatto del rumore quando il modello non ha accesso alle etichette.

Per garantire la completa riproducibilità degli esperimenti, è stato fissato un seme casuale globale (`seed = 42`) su tutte le componenti stocastiche, comprendendo lo split dei dati, l’inizializzazione dei pesi delle reti, l’iniezione del rumore e i processi di campionamento del Random Forest e del K-Means.

2 Il dataset

Il dataset utilizzato è il MAGIC Gamma Telescope, generato tramite simulazioni Monte Carlo del telescopio Cherenkov MAGIC. Ogni osservazione descrive la traccia luminosa, di forma approssimativamente ellittica, lasciata da un evento atmosferico sul piano del rivelatore. Il task consiste in una classificazione binaria con un preciso significato fisico: distinguere i segnali utili, prodotti da raggi gamma, dal rumore di fondo generato da adroni (raggi cosmici). Un adrone classificato erroneamente come gamma (falso positivo) contamina il segnale, mentre un gamma scartato (falso negativo) riduce la statistica utile per le analisi fisiche. Questa forte asimmetria nei costi degli errori rende la semplice accuratezza una metrica insufficiente per valutare adeguatamente un modello.

Il dataset originario comprende 19 020 osservazioni e 11 attributi: dieci feature continue e una variabile target. Le feature codificano la geometria e la distribuzione di intensità dell’immagine dell’evento sul rivelatore. In fase di preparazione, è stata effettuata una mappatura numerica delle due classi: $\mathbf{h} \rightarrow 0$ per gli adroni (fondo) e $\mathbf{g} \rightarrow 1$ per i gamma (segnale). La Tabella 1 riporta la descrizione dettagliata delle feature.

Tabella 1: Le dieci feature continue del dataset MAGIC e il loro significato.

Feature	Descrizione
fLength	lunghezza dell'asse maggiore dell'ellisse dell'immagine
fWidth	lunghezza dell'asse minore dell'ellisse
fSize	logaritmo della somma delle intensità di tutti i pixel
fConc	rapporto di concentrazione dei due pixel più intensi
fConc1	rapporto di concentrazione del pixel più intenso
fAsym	asimmetria della distribuzione lungo l'asse maggiore
fM3Long	momento terzo (asimmetria) lungo l'asse maggiore
fM3Trans	momento terzo lungo l'asse minore
fAlpha	angolo tra l'asse maggiore e la direzione del centro del campo
fDist	distanza dal centro del campo all'origine dell'ellisse
class	target: 1 = gamma (segnale), 0 = adrone (fondo)

3 Suddivisione in training, validation e test

Il dataset è stato suddiviso in tre partizioni prima di procedere a qualsiasi altra operazione, inclusa l'analisi esplorativa. Questa separazione preventiva è fondamentale per evitare che le statistiche calcolate sull'intero campione possano influenzare le scelte modellistiche, causando *data leakage*. Limitando l'analisi esplorativa e il calcolo dei parametri di preprocessing al solo training set, validation e test set si mantengono come stime rigorose e imparziali della capacità di generalizzazione.

Lo split è stato eseguito seguendo le proporzioni 60% / 20% / 20% rispettivamente per training, validation e test. La suddivisione è stratificata rispetto alla variabile target: ogni sottoinsieme preserva la medesima proporzione tra gamma e adroni presente nel dataset originale. Questa accortezza si rende necessaria a causa dello sbilanciamento delle classi; un campionamento puramente casuale rischierebbe di produrre insiemi con una rappresentanza insufficiente della classe minoritaria. Si ottengono così 11 412 campioni di training, 3 804 di validation e 3 804 di test. Il validation set viene utilizzato per monitorare l'addestramento, mentre il test set rimane isolato per la valutazione finale.

4 Analisi esplorativa dei dati

L'analisi esplorativa viene condotta esclusivamente sul training set per garantire il corretto isolamento delle altre partizioni. Il dataset originale non presenta valori nulli, fornendo una base di partenza integra; in questo modo lo studio rimane rigorosamente controllato, poiché ogni successiva corruzione viene introdotta in maniera deliberata e quantificabile. In fase esplorativa sono stati inoltre individuati 41 record duplicati nel training set: data la loro incidenza trascurabile (circa lo 0,4% dei campioni), essi vengono rimossi unicamente ai fini delle statistiche e dei grafici descrittivi presentati in questa sezione, portando il conteggio da 11 412 a 11 371 osservazioni; l'addestramento dei modelli viene invece condotto sull'intero training set, dato che l'effetto numerico dei duplicati sulle metriche finali è in ogni caso irrilevante.

La Figura 1 illustra la distribuzione della variabile target, evidenziando un netto sbilanciamento. La classe gamma costituisce il 64,8% delle osservazioni, mentre gli adroni

rappresentano il restante 35,2%, configurando un rapporto di quasi due a uno. Questo squilibrio fissa una linea di base operativa: un classificatore *dummy* che prevedesse sistematicamente la classe maggioritaria otterrebbe un'accuratezza prossima al 65%. Di conseguenza, qualsiasi modello predittivo deve necessariamente superare questa soglia per dimostrare un effettivo apprendimento.




Figura 1: Distribuzione delle due classi nel training set: i gamma (segnale) sono quasi il doppio degli adroni (fondo).

Le distribuzioni delle variabili continue (Figura 2) risultano prevalentemente asimmetriche (*right-skewed*), con densità concentrate sui valori inferiori e lunghe code verso destra. Questa marcata asimmetria rende la mediana uno stimatore di tendenza centrale più robusto alle code rispetto alla media, pur senza garantire *a priori* un'imputazione empiricamente migliore. Si osserva inoltre una notevole eterogeneità nelle scale numeriche, che spaziano da unità singole a centinaia, rendendo necessaria una successiva normalizzazione.




Figura 2: Istogrammi delle dieci feature continue (training set): distribuzioni asimmetriche, con code lunghe e scale eterogenee.

I boxplot suddivisi per classe (Figura 3) permettono di valutare il potere discriminante intrinseco delle singole feature. La variabile **fAlpha** mostra la capacità di separazione più netta: i valori associati ai gamma si concentrano in un range ristretto e basso, mentre quelli degli adroni presentano un'elevata dispersione. Seguono **fLength**, **fWidth** e **fSize**, che offrono un buon contributo informativo. Al contrario, feature come **fM3Trans** e **fAsym** esibiscono distribuzioni ampiamente sovrapposte tra le due classi, fornendo un apporto discriminante marginale. L'informazione utile alla classificazione risulta pertanto concentrata in un sottoinsieme limitato di variabili.




Figura 3: Boxplot di ogni feature per classe (training set): **fAlpha** è la più discriminante, i momenti trasversali separano poco le classi.

L'analisi della matrice di correlazione di Pearson (Figura 4) evidenzia forti interdipendenze lineari tra alcune feature. Le variabili **fConc** e **fConc1** risultano pressoché colineari (correlazione di 0,98) e presentano una marcata anticorrelazione con **fSize** ($-0,85$ e $-0,81$). Anche il gruppo formato da **fLength**, **fWidth** e **fSize** mostra correlazioni significative, comprese tra 0,70 e 0,77. Questa elevata ridondanza informativa implica che il degrado o l'assenza di una di queste feature possa essere parzialmente compensato dall'informazione contenuta nelle altre. In netto contrasto, **fAlpha** si conferma la variabile più discriminante ma risulta quasi del tutto scorrelata dal resto del dataset; di conseguenza, la sua informazione risulta unica e non vicariabile in caso di corruzione.




Figura 4: Matrice di correlazione tra le feature (training set). Spiccano la quasi-ridondanza `fConc`/`fConc1` e l'anticorrelazione di `fSize` con le concentrazioni; `fAlpha` è quasi scorrelata da tutte.

5 Preprocessing: standardizzazione

La notevole eterogeneità delle scale numeriche osservata durante l'analisi esplorativa rende indispensabile la standardizzazione delle feature (traslazione a media nulla e varianza unitaria). Questo passaggio è particolarmente critico per la stabilità e la convergenza delle reti neurali. In assenza di standardizzazione, le feature caratterizzate da magnitudo elevate dominerebbero l'aggiornamento dei gradienti esclusivamente in virtù della loro scala, e non per il loro effettivo potere predittivo.

Per garantire la rigore metodologica ed evitare il *data leakage*, i parametri di scalatura (media e deviazione standard) sono stati estratti esclusivamente dal training set. Tali parametri sono stati successivamente applicati in modo immutato per trasformare il validation e il test set.

6 Modelli

Lo studio confronta tre modelli supervisionati, selezionati per rappresentare architetture dotate di livelli crescenti di tolleranza intrinseca al rumore. La Tabella 2 ne riassume i parametri strutturali e gli iperparametri.

La **rete neurale Base** è un *Multi-Layer Perceptron* (MLP) volutamente semplificato. L'architettura prevede in ingresso le dieci feature standardizzate, elaborate tramite

due strati densi nascosti (rispettivamente da 32 e 16 neuroni, entrambi con funzione di attivazione ReLU). L'ultimo strato è costituito da un singolo neurone con attivazione sigmoide per la stima della probabilità di classe. L'addestramento sfrutta l'ottimizzatore Adam (tasso di apprendimento 10^{-3}) e la funzione di costo *binary cross-entropy*, per 75 epoche con un batch size di 32. Privo di alcun meccanismo di regolarizzazione, questo modello rappresenta la baseline "ingenua", in quanto è strutturalmente libero di adattarsi anche ai pattern spuri introdotti dal rumore (*overfitting*).

La **rete neurale Pro** mantiene l'esatta architettura della rete Base ma integra quattro meccanismi specifici per contrastare l'overfitting. La regolarizzazione *L2* (coefficiente 10^{-4} sui pesi degli strati nascosti) penalizza la magnitudo dei pesi, disincentivando confini decisionali eccessivamente complessi. Il *dropout* (probabilità 0,2) inibisce iterativamente frazioni casuali di neuroni, costringendo la rete a distribuire l'apprendimento ed evitare la dipendenza da singole unità. Il *class weight* bilanciato incrementa la penalizzazione per gli errori commessi sulla classe minoritaria (adroni), bilanciando l'aggiornamento dei pesi. Infine, l'*early stopping* monitora la funzione di costo sul validation set e interrompe l'addestramento in caso di assenza di miglioramenti per 15 epoche consecutive (entro un limite massimo di 150), ripristinando i pesi ottimali.

Il **Random Forest** è un *ensemble* composto da 200 alberi decisionali. La sua robustezza deriva dal principio del *bagging*: le previsioni dei singoli alberi, ciascuno addestrato su sottoinsiemi casuali di dati e feature, vengono aggregate tramite voto maggioritario. Questo meccanismo tende a cancellare la varianza degli errori individuali. Poiché l'algoritmo non opera tramite ottimizzazione iterativa, non sono disponibili curve di apprendimento; le performance sono valutate unicamente tramite le metriche e la matrice di confusione finali.

Tabella 2: Parametri principali dei tre modelli confrontati.

Modello	Architettura	Regolarizzazione / iperparametri		
NN Base	Dense(32) → Dense(16) → sigmoide	nessuna; Adam 10^{-3} , 75 epoche, batch 32		
NN Pro	Dense(32) → Dense(16) → sigmoide	L2 10^{-4} , dropout 0,2, class weight bilanciato, early stopping (patience 15), max 150 epoche		
Random Forest	200 alberi decisionali	aggregazione	per	voto, <code>random_state=42</code>

Per la valutazione complessiva vengono utilizzate quattro metriche, calcolate sul test set pulito applicando una soglia decisionale di 0,5. L'Accuratezza globale fornisce un'indicazione di massima, ma risulta limitata a causa dello sbilanciamento delle classi. Per compensare, vengono introdotte l'F1 macro e la Recall macro, che mediano le prestazioni attribuendo pari importanza a entrambe le classi, penalizzando severamente i modelli che tendono a ignorare gli adroni. Infine, l'AUC (*Area Under the ROC Curve*) valuta la qualità intrinseca del *ranking* probabilistico indipendentemente dalla soglia scelta.

7 Baseline su dati puliti

L'addestramento preliminare sui dati originali stabilisce il riferimento di prestazioni a livello 0% di corruzione. Le metriche estratte fungono da standard di paragone per misurare quantitativamente i futuri degradi prestazionali. La Tabella 3 riassume i risultati sul test set.

Tabella 3: Metriche di test dei tre modelli sui dati puliti (riferimento a 0% di rumore).

Modello	Accuratezza	F1 macro	AUC
NN Base	0,8678	0,8517	0,9214
NN Pro	0,8601	0,8468	0,9238
Random Forest	0,8785	0,8629	0,9300

I modelli presentano prestazioni iniziali comparabili, con valori di accuratezza compresi tra l'86% e l'88% e AUC tra 0,92 e 0,93. Il Random Forest emerge come l'algoritmo più performante su tutte le metriche. L'accuratezza della rete Pro risulta marginalmente inferiore a quella della rete Base; questa flessione, però, non è imputabile principalmente a L2 e dropout, bensì al *class weight* bilanciato applicato con soglia decisionale fissa a 0,5: ribilanciando l'obiettivo a favore della classe minoritaria, la rete Pro aumenta la recall sugli adroni (da 0,77 a 0,80) a scapito di una quota di recall sui gamma, riducendo l'accuratezza globale senza intaccare la qualità del *ranking* probabilistico. Coerentemente, la rete Pro registra un'AUC lievemente superiore rispetto alla Base — metrica indipendente dalla soglia — a conferma di una maggiore solidità nell'ordinamento delle probabilità prodotte.

Le matrici di confusione (Figura 5) illustrano il comportamento predittivo in presenza di classi sbilanciate. Tutti i classificatori isolano con efficacia il segnale (gamma), ma concentrano la maggioranza degli errori sull'identificazione degli adroni. Le *learning curves* delle due reti (Figura 6) indicano una convergenza regolare. Il divario limitato tra le metriche di training e validation conferma l'assenza di un marcato *overfitting* sui dati non alterati per entrambe le architetture.




Figura 5: Matrici di confusione sui dati puliti: rete Base, rete Pro e Random Forest (da sinistra a destra). Tutti riconoscono bene i gamma, gli errori si concentrano sugli adroni.




Figura 6: Curve di accuratezza e loss (train vs validation) sui dati puliti: rete Base (in alto) e rete Pro (in basso).

L'estrazione della *feature importance* tramite Random Forest (Figura 7) conferma quantitativamente le ipotesi formulate nell'analisi esplorativa. La feature **fAlpha** domina lo spazio predittivo con un valore di importanza prossimo a 0,24, circa una volta e mezza il secondo parametro più rilevante (**fLength**, $\approx 0,15$). Seguono in ordine decrescente **fLength**, **fWidth** e **fSize**.




Figura 7: Importanza delle feature secondo il Random Forest sui dati puliti. **fAlpha** domina, coerentemente con la separabilità osservata nei boxplot.

8 Metodologia di iniezione del rumore

Il rumore altera esclusivamente il training set, mantenendo intatti validation e test set. Questo approccio garantisce di valutare in modo corretto la generalizzazione di un modello addestrato su dati imperfetti. Per ogni rumore, i modelli sono riaddestrati iterativamente su tre livelli di intensità (10%, 25%, 40%), valutando poi le performance sempre sul medesimo test set. L'iniezione del rumore avviene sul training set già standardizzato: essendo le perturbazioni additive o monotone, l'operazione equivale matematicamente a corrompere i dati originali e standardizzarli in un secondo momento.

Si definiscono sette meccanismi di corruzione:

8.1 I sette tipi di rumore

Feature noise (rumore gaussiano). A ogni singola feature del training set viene sommato un rumore bianco gaussiano, caratterizzato da media nulla e deviazione standard proporzionale al livello percentuale scelto. Poiché le variabili sono state preventivamente standardizzate, l'applicazione di un rumore al livello 40% equivale a introdurre fluttuazioni pari al 40% della deviazione standard nativa di ciascuna feature.

Feature noise localizzato. In questo scenario, l'intensità del rumore viene mantenuta costante a $\sigma = 0,35$, variando invece il numero di feature perturbate. La selezione avviene in base alla gerarchia di importanza stabilita. Al livello 10% il disturbo altera unicamente `fAlpha`; al 25% coinvolge le prime tre variabili discriminanti; al 40% l'iniezione si estende alle prime cinque.

Label noise random. Una percentuale di osservazioni del training set pari al livello selezionato subisce l'inversione della variabile target (da 0 a 1 e viceversa). Il campionamento avviene in maniera puramente casuale, simulando errori di annotazione distribuiti uniformemente.

Label noise borderline. L'inversione delle etichette si concentra sulle istanze topologicamente più ambigue. Dopo aver calcolato i centroidi delle due classi nello spazio multidimensionale standardizzato, si misura la distanza di ogni campione dal centroide della classe opposta. L'inversione colpisce esclusivamente i campioni caratterizzati da distanza minima, ovvero quelli posizionati in stretta prossimità del confine decisionale ottimale.

Missing values. Singole misurazioni vengono eliminate e sostituite con un valore nullo (NaN), trattando ogni cella della matrice come evento indipendente con probabilità pari al livello di corruzione. Non potendo i modelli elaborare dati incompleti, si impone l'uso di un'imputazione: in questa sede vengono confrontate l'imputazione per media e per mediana della rispettiva feature.

Outlier. Un numero di campioni proporzionale al livello selezionato subisce una corruzione massiva: tutti i valori delle feature per la riga scelta vengono sostituiti da parametri estremi (fissati a ± 5 deviazioni standard, con attribuzione casuale del segno). Le strategie di mitigazione esplorate sono tre: lasciare le istanze inalterate; applicare la

winsorizzazione (troncamento dei valori limite in corrispondenza dei percentili al 5% e 95%) per contenere la magnitudo estrema; imputare i dati, marcando come mancanti le istanze con z-score assoluto maggiore di 4 e sostituendole con la mediana. Come riferimento primario verrà utilizzata la winsorizzazione, in virtù del suo bilanciamento tra robustezza e conservazione dei dati.

Missing feature (sensore guasto). Intere colonne di feature vengono azzerate su tutti i sottoinsiemi (training, validation e test), simulando il totale fallimento sistemico di un sensore. Anche in questo caso la rimozione procede seguendo la gerarchia di importanza decrescente. Al 10% viene inibita l’elaborazione di **fAlpha**, al 25% si azzerano le prime tre variabili predittive, fino alle prime cinque al 40%. Questo approccio impone condizioni volutamente pessimistiche, sopprimendo le fonti informative primarie.

9 Risultati per tipo di rumore

L’impatto dei sette disturbi viene analizzato singolarmente, quantificando il degrado prestazionale al crescere della corruzione. Per ciascun test vengono forniti i prospetti delle metriche misurate sui vari step e le comparazioni grafiche sull’andamento dell’accuratezza globale e dell’F1 macro. L’analisi è integrata, dove necessario, dallo studio delle learning curves e dalle matrici di confusione inerenti allo scenario estremo.

9.1 Feature noise

L’aggiunta di rumore bianco gaussiano sulle feature produce un degrado morbido e progressivo. Come riportato nella Tabella 4, anche al massimo livello di corruzione (40%) l’accuratezza di tutti i modelli si preserva al di sopra dell’83%, registrando una flessione limitata a tre o quattro punti percentuali rispetto alla baseline. I grafici prestazionali (Figura 8) restituiscono curve con pendenza lieve e omogenea sia in termini di accuratezza sia per quanto riguarda l’F1 macro.

Tabella 4: Feature noise: metriche al variare del livello di rumore (test set). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8657	0.84	0.85	0.9187	0.8636	0.85	0.85	0.9204	0.8646	0.83	0.84	0.9222
25%	0.8520	0.81	0.83	0.9074	0.8465	0.83	0.83	0.9071	0.8494	0.81	0.82	0.9041
40%	0.8328	0.78	0.80	0.8941	0.8417	0.82	0.82	0.8940	0.8318	0.78	0.80	0.8913




Figura 8: Feature noise: accuratezza (in alto) e F1 macro (in basso) dei tre modelli al crescere del rumore.

Al livello 40%, la rete Pro raggiunge il primato assoluto (0,8417), distaccando sia la rete Base (0,8328) sia il Random Forest (0,8318). Questo risultato conferma l'efficacia dei sistemi di regolarizzazione di fronte a input instabili: la sinergia tra penalizzazione L2 e dropout funge da filtro, impedendo all'architettura di modellare e apprendere le fluttuazioni stocastiche introdotte. La rete Base, al contrario, mancando di vincoli strutturali, tende ad assecondare il rumore, peggiorando le proprie capacità di classificazione su campioni ignoti. Nelle curve di apprendimento relative allo scenario estremo (Figura 9) si nota come la rete Base conservi un costante, seppur ridotto, gap tra training e validation loss; la rete Pro, di contro, mantiene le curve di training e validation costantemente appaiate. A livello generale, la marcata ridondanza interna tra le feature attenua fortemente l'impatto distruttivo, consentendo all'algoritmo di dedurre parzialmente le informazioni corrotte dalle variabili adiacenti correlate.




Figura 9: Feature noise al 40%: curve di addestramento della rete Base (in alto) e della rete Pro (in basso). Nella rete Pro train e validation restano sovrapposte: la regolarizzazione evita l'adattamento al rumore.

Il decadimento delle performance risulta, tuttavia, asimmetrico. In presenza di uno sbilanciamento di classe, i modelli tendono a preservare un'accuratezza globale elevata sacrificando il potere predittivo sulla classe rara. Al 40% di rumore, la *recall* per la classe minoritaria (adroni) della rete Base precipita da 0,77 a 0,59, in netto contrasto con la *recall* dei gamma che si incrementa da 0,92 a 0,97. Questa discrepanza evidenzia la tendenza dell'algoritmo a declassificare i campioni adronici incerti e ad assorbirli erroneamente nella classe maggioritaria. L'implementazione del *class weight* all'interno della rete Pro argina tale fenomeno, sostenendo la recall adronica a 0,73. Le matrici di confusione generate dalla rete Base (Figura 10) quantificano inequivocabilmente tale scivolamento.




Figura 10: Feature noise, rete Base: matrici di confusione al 10%, 25% e 40% (da sinistra a destra). Gli adroni (riga 0) vengono classificati come gamma con frequenza crescente.

9.2 Feature noise localizzato

Selezionando con precisione le fonti di corruzione invece di spalmare il rumore globalmente, l'impatto predittivo non subisce drammatici stravolgimenti (Tabella 5). L'intensità della perturbazione rimane costante a $\sigma = 0,35$.

Tabella 5: Feature noise localizzato ($\sigma = 0,35$) sulle sole feature più importanti: il livello indica quante feature sono colpite (10%→top-1, 25%→top-3, 40%→top-5). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8651	0.84	0.85	0.9211	0.8651	0.85	0.85	0.9243	0.8743	0.85	0.86	0.9274
25%	0.8523	0.82	0.83	0.9043	0.8478	0.83	0.83	0.9058	0.8533	0.82	0.83	0.9056
40%	0.8452	0.81	0.82	0.8991	0.8386	0.82	0.82	0.8973	0.8389	0.79	0.81	0.8931




Figura 11: Feature noise localizzato: accuratezza (in alto) e F1 macro (in basso). Le curve restano vicine e quasi piatte.

Il decadimento si conferma lieve anche a fronte della perturbazione mirata sulle cinque feature fondamentali. Al livello 40%, tutti i classificatori si preservano sopra la soglia dell'83% in termini di accuratezza. L'analisi di classe (Figura 13) rimarca le dinamiche asimmetriche indagate precedentemente: al livello apicale, la recall adronica della rete Base staziona a 0,67, mentre l'applicazione dei pesi sbilanciati nella rete Pro la sostiene al 0,75.

L'andamento delle *learning curves* non discosta da quanto evidenziato nel rumore diffuso (Figura 12). Il confronto concettuale più significativo emerge mettendolo in relazione con la completa omissione delle feature (missing feature): inficiare l'integrità di **fAlpha** riduce l'accuratezza della rete Base a 0,8651, laddove la sua completa soppressione ne cagionerà il crollo a 0,8215. La perturbazione degrada la qualità informativa ma non l'annulla, consentendo alla rete di attingere, mediante sistemi complessi di compensazione, a porzioni della geometria originale dei dati.




Figura 12: Feature noise localizzato al 40%: curve di addestramento. L'andamento ricalca il feature noise globale, senza overfitting.




Figura 13: Feature noise localizzato al 40%: matrici di confusione della rete Base (sinistra) e del Random Forest (destra).

9.3 Label noise random

L'alterazione stocastica della variabile target innesca dinamiche prestazionali nettamente dissimili da quelle viste sulle alterazioni continue. Fino alla soglia del 25%, i classificatori riescono a preservare metriche adeguate, ma subiscono un cedimento drammatico raggiunto il 40%. Come evincibile dalla Tabella 6, l'accuratezza della rete Base crolla a 0,7419, seguita dal declino del Random Forest a 0,7179. La rete Pro manifesta un'elevata resilienza strutturale, mantenendo l'accuratezza al 0,8044 (Figura 14).

Tabella 6: Label noise random: metriche al variare del livello di rumore (test set). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8623	0.83	0.84	0.9128	0.8570	0.84	0.84	0.9200	0.8767	0.85	0.86	0.9214
25%	0.8410	0.82	0.82	0.8882	0.8378	0.83	0.83	0.9081	0.8399	0.81	0.82	0.8884
40%	0.7419	0.68	0.69	0.7513	0.8044	0.79	0.79	0.8677	0.7179	0.70	0.70	0.7673




Figura 14: Label noise random: accuratezza e F1 macro. Al 40% la rete Pro si stacca verso l'alto, mentre Base e Random Forest crollano.

La causa scatenante di questa severa divergenza si manifesta chiaramente nelle *learning curves* (Figura 15). Il processo di ottimizzazione della rete Base interiorizza le annotazioni spurie, portando la curva di training a sfiorare un inverosimile 88%, affiancata da un costante deterioramento della validation loss misurata sulle label originarie

e pulite. In contrapposizione, l'*early stopping* inserito nella rete Pro, monitorando i gradienti estratti dai dati non corrotti (validation test), interrompe tempestivamente l'iterazione. L'arresto preventivo blocca i pesi del percettore a uno stadio prematuro ma ottimale, proteggendo il modello dalla fase critica di memorizzazione di massa del rumore, conservando una validation accuracy vicina all'82%.




Figura 15: Label noise random al 40%: la Base memorizza le etichette corrotte (train sale, validation scende); la Pro, fermata dall'early stopping, mantiene alta la validation.

Essendo sprovvisto di meccanismi iterativi vincolati a set di validazione puri, il Random Forest assimila i falsi target all'interno dei nodi divisionali. La distribuzione indifferenziata dell'errore (Figura 16) corrobora questa ipotesi, portando a decrementi paritari sulle metriche associate alle singole classi.




Figura 16: Label noise random al 40%: matrice di confusione del Random Forest. Gli errori aumentano su entrambe le classi.

9.4 Label noise borderline

La corruzione selettiva delle istanze collocate ai margini dei confini decisionali costituisce l'anomalia maggiormente distruttiva per i modelli predittivi testati. Le metriche palesano un calo marcato già a fronte di variazioni contenute (25%). Al raggiungimento del livello estremo (40%), le misurazioni collassano verso una quota di accuratezza approssimabile al 60%, che scende perfino al di sotto della soglia di un classificatore inerte che prevede sempre la classe maggioritaria ($\approx 65\%$): il rumore borderline rende dunque i modelli attivamente fuorvianti (Tabella 7 e Figura 17).

Tabella 7: Label noise borderline: metriche al variare del livello di rumore (test set). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8252	0.79	0.80	0.8680	0.8352	0.82	0.82	0.8915	0.8383	0.80	0.81	0.8886
25%	0.7326	0.71	0.71	0.7879	0.7403	0.73	0.72	0.8265	0.7387	0.72	0.72	0.8043
40%	0.6002	0.61	0.59	0.6656	0.6354	0.63	0.62	0.7084	0.6094	0.62	0.60	0.6774




Figura 17: Label noise borderline: al 40% tutti i modelli convergono attorno al 60%, indicando il collasso predittivo.

A parità di intensità numerica rispetto all'alterazione stocastica, l'intervento borderline possiede una letalità geometrica intrinseca maggiore. L'inversione sistematica delle istanze vicine all'equatore spaziale che divide le classi induce lo spostamento macroscopico del confine decisionale. Le *learning curves* della rete Pro (Figura 18) non registrano alcun vantaggio apportato dalle regolarizzazioni né dagli arresti preventivi: di fronte a un'alterazione massiva della regione liminare di apprendimento, l'estrazione logica degli iperpiani non si dimostra recuperabile.




Figura 18: Label noise borderline al 40%: anche la validation della rete Pro crolla, a causa della falsificazione strutturale del confine decisionale.

A differenza delle fluttuazioni riscontrate sulle feature in continuo, il danno inflitto alla classificazione si distribuisce in questo scenario in modo sostanzialmente bilanciato tra le due classi: pur essendo i flip iniettati più numerosi sulla classe maggioritaria (gamma), l'effetto sul test comporta un incremento delle predizioni spurie su entrambe le variabili fisiche analizzate (Figura 19).




Figura 19: Label noise borderline al 40%: matrici di confusione della rete Pro (sinistra) e del Random Forest (destra). Errori diffusi in modo simmetrico.

9.5 Missing values

La sostituzione iterativa di singoli attributi con il valore nullo determina peggioramenti lineari e proporzionali a patto dell'inclusione logica di tecniche di ripristino. Sfruttando la mediana (variante definita canonica), le metriche globali conservano la fascia 82%–85% (Tabella 8). In questa particolare casistica, l'algoritmo Random Forest assicura il minor cedimento, registrando un picco di accuratezza pari a 0,8528 (Figura 20).

Tabella 8: Missing values (imputazione con mediana): metriche al variare del tasso di valori mancanti. R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8617	0.83	0.84	0.9172	0.8570	0.84	0.84	0.9190	0.8720	0.84	0.85	0.9208
25%	0.8425	0.82	0.83	0.9057	0.8328	0.83	0.82	0.9046	0.8578	0.83	0.84	0.9129
40%	0.8328	0.79	0.81	0.8915	0.8226	0.81	0.81	0.8937	0.8528	0.82	0.83	0.9039




Figura 20: Missing values con imputazione mediana. Il Random Forest mantiene un vantaggio costante a tutti i livelli.

Il paragone strumentale tra l'impiego della media e l'impiego della mediana (Figura 21) ridimensiona tuttavia le aspettative riposte nello studio sulle asimmetrie distributive: il divario tra le due strategie resta marginale e privo di una direzione univoca. Indifferente ai campioni posizionati sulle code lunghe, la mediana acquisisce un lieve vantaggio soltanto sulla rete Base ai livelli di corruzione più elevati; sulla rete Pro è invece la media a risultare leggermente preferibile, mentre sul Random Forest le due imputazioni si equivalgono. La mediana viene mantenuta come riferimento canonico per la sua maggiore robustezza teorica alle code, ma sul piano empirico la scelta tra le due strategie incide in misura trascurabile sulle prestazioni finali. Nel contesto strutturale, l'algoritmo a foresta isola con maggiore flessibilità le istanze falsificate in quanto i suoi operatori si basano su divisioni del campione e non su pesi distribuiti lungo flussi di nodi.




Figura 21: Missing values: confronto tra imputazione con media e con mediana per i tre modelli. Le due strategie producono prestazioni pressoché equivalenti; la mediana prevale lievemente solo sulla rete Base ad alta corruzione, mentre sulla rete Pro è la media a risultare marginalmente migliore.




Figura 22: Missing values (mediana) al 40%: curve della rete Base e matrici di confusione. L'addestramento è regolare; gli errori pesano sugli adroni.

9.6 Outlier

A dispetto delle proiezioni preliminari, le infiltrazioni di valori massimali estranei configurano l'anomalia di minore impatto sul comportamento diagnostico (Tabella 9). L'accuratezza staziona attorno alla quota originaria dell'85%–87%, non delineando significative tendenze degradative (Figura 23). La ragione di fondo non risiede tanto nel trattamento applicato quanto nella natura stessa del disturbo: le righe corrotte assumono valori a ± 5 deviazioni standard con segno casuale e del tutto scorrelato dall'etichetta, per cui il loro contributo al gradiente si media verso lo zero e i modelli, addestrati su un test set pulito, ne risentono poco.

Tabella 9: Outlier (winsorizzazione): metriche al variare della frazione di campioni anomali. R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8657	0.84	0.85	0.9196	0.8583	0.85	0.84	0.9220	0.8788	0.85	0.86	0.9295
25%	0.8628	0.84	0.84	0.9160	0.8441	0.84	0.83	0.9173	0.8751	0.85	0.86	0.9267
40%	0.8615	0.84	0.84	0.9116	0.8541	0.84	0.84	0.9201	0.8736	0.85	0.86	0.9250




Figura 23: Outlier con winsorizzazione. Curve prestazionali pressoché inalterate.

Le disparità originate dai tre approcci in competizione (Figura 24) rimangono esigue: lasciare gli outlier inalterati, winsorizzare o imputare produce risultati pressoché sovrapponibili. Questa equivalenza conferma che, a tassi di corruzione elevati, la winsorizzazione al 5% è in larga parte inefficace — quando una frazione consistente di valori è collassata su ± 5 , i percentili stessi risultano saturati e il troncamento non rimuove gli

estremi — e che la robustezza osservata va attribuita all'intrinseca innocuità del disturbo più che alla strategia di mitigazione. La winsorizzazione viene comunque mantenuta come variante canonica per prudenza, in quanto assetto precauzionale ragionevole senza controindicazioni (Figura 25).




Figura 24: Outlier: confronto tra le strategie. Le differenze sono minimali, supportate in buona parte dal preprocessing di standardizzazione.




Figura 25: Outlier (winsorizzazione) al 40%: matrici di confusione. Prestazioni indistinguibili dal caso pulito.

9.7 Missing feature (sensore guasto)

Il blocco iterativo delle acquisizioni strutturali del telescopio restituisce, parimenti al label noise, esiti catastrofici in virtù della privazione totale e incondizionata dei punti di riferimento spaziale. Estromettendo le informazioni generate dal canale **fAlpha** (Tabella 10), si registra una caduta immediata di 4 o 5 punti netti; arrivando a coprire la cinquina maggiore, tutte le piattaforme testate franano sulla linea di confidenza marginale tra il 70% e il 74% (Figura 26).

Tabella 10: Missing feature: metriche rimuovendo le feature più importanti (10%→top-1, 25%→top-3, 40%→top-5). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8215	0.78	0.79	0.8675	0.8052	0.79	0.79	0.8716	0.8294	0.79	0.80	0.8788
25%	0.7773	0.72	0.74	0.8007	0.7574	0.73	0.73	0.7991	0.7836	0.74	0.75	0.8195
40%	0.7303	0.66	0.67	0.7413	0.6995	0.67	0.67	0.7347	0.7363	0.67	0.68	0.7494




Figura 26: Missing feature: accuratezza (in alto) e F1 macro (in basso). Rimuovere **fAlpha** genera il declino più severo registrato fin dalla prima istanza.

Quest'ultima simulazione rimarca l'effettivo coefficiente di importanza detenuto dal vettore diagnostico **fAlpha**. A fronte della scarsissima affiliazione di correlazione stabilita con le altre componenti in analisi, il suo decadimento comporta un depauperamento insostituibile. In controtendenza allo scenario con rumore, la totale assenza di nozioni informative paralizza le routine di regolarizzazione, spingendo la rete neurale Pro in coda al gruppo valutativo (0,6995 al 40%), in virtù delle rigidità intrinseche ai meccanismi di profilassi dall'overfitting. L'asportazione chirurgica dei dati compromette prioritariamente i canali minoritari, annientando il potere di deduzione della categoria adroni (Figura 27 e 28).




Figura 27: Missing feature al 40%. Senza le feature più informative i modelli perdono potere discriminante intrinseco, pur mantenendo learning curves stabili e vicine.




Figura 28: Missing feature, rete Base: matrici di confusione. Rimuovendo le feature, la capacità di discriminazione sugli adroni svanisce progressivamente.

10 Sintesi trasversale

Una volta delineato il comportamento nei singoli scenari, l'analisi congiunta (Figura 29) riassume graficamente, su un unico parametro di scala, i livelli di degrado subiti. Le oscillazioni tra accuratezza globale e ponderazioni F1 tratteggiano il profilo immunitario di ciascun classificatore.




Figura 29: Robustezza per tipo di rumore. Emerge costantemente l’outlier come disturbo innocuo e il label noise borderline come criticità massima.

L’evidenza stabilisce una gerarchia di vulnerabilità condivisa. Gli outlier si distinguono come i fattori meno disturbanti, affiancati a stretto raggio dal feature noise e dalle celle deficitarie, limitati da cali moderati e gestibili. Al capo diametralmente opposto, la variazione topologica delle classi di confine costituisce la perturbazione estrema, portando alla compromissione assoluta. La heatmap (Figura 30) cristallizza questi trend nel picco negativo (40% di corruzione), indicando cromaticamente l’annullamento della validità del labeling borderline rispetto al verde tenue delle proiezioni per outlier.




Figura 30: Accuratezza estrema nel caso peggiore (40%) per ogni combinazione. Il rosso intenso sul label noise borderline indica l’annullamento dei gradienti logici.

In ottica di contenimento (Figura 31), emerge innegabilmente la forte tolleranza ai mutamenti continui posseduta dalla rete regolarizzata (NN Pro), bilanciata tuttavia dalla sensibilità mostrata a fronte delle alterazioni ad impatto soppressivo, frangente in cui le foreste di alberi dominano su ogni scenario per flessibilità strutturale.




Figura 31: Calo di accuratezza. Barre contenute indicano maggiore tenuta ai gradienti spuri e al data leakage.

Estrapolando una media complessiva (Figura 32), le distanze globali si assottigliano fino alla sovrapposizione concettuale. Il vertice occupato dalla rete strutturata (0,785), e tallonato da Random Forest (0,780) e NN base (0,778), impone valutazioni contestuali alla messa in opera reale: la scelta non obbedisce al modello astratto, ma al background specifico da cui verranno generati gli input.




Figura 32: Robustezza complessiva (accuratezza media). I tre modelli convergono in uno spazio di deviazione trascurabile.

La proiezione ROC incrociata sulla perturbazione gaussiana (Figura 33) valida inoltre le capacità analitiche di ranking del test, assicurando che lo scarto si traduca essenzialmente in un incremento adattativo della rete naive (NN base) ed in un posizionamento coerente della controparte regolare.




Figura 33: Curve ROC dei tre modelli su dati puliti (continue) e con 40% di feature noise (tratteggiate). Il feature noise erode limitatamente la classificazione ordinale.

10.1 Controllo multi-seed

Tutti i risultati discussi finora derivano da un singolo seme casuale (`seed = 42`). Per escludere che il degrado osservato sia un artefatto dovuto a una particolare partizione dei dati o a una specifica inizializzazione dei pesi, l'esperimento di *feature noise* è stato ripetuto in modo identico su cinque semi distinti $\{42, 7, 123, 2024, 99\}$. Ogni seme governa contemporaneamente la realizzazione del rumore gaussiano, lo split train/validation/test e l'inizializzazione dei tre modelli; per ciascun livello di corruzione si riportano media e deviazione standard delle metriche (Tabella 11).

Tabella 11: Controllo multi-seed sul feature noise: media $\pm$ deviazione standard delle metriche sui cinque semi $\{42, 7, 123, 2024, 99\}$. Le deviazioni standard restano dell'ordine del millesimo, ampiamente inferiori al divario tra livelli di rumore.

Modello	Rumore	Accuracy	F1 _m	AUC
NN Base	Pulito	0.8685 ± 0.0027	0.8514 ± 0.0029	0.9220 ± 0.0015
	10%	0.8672 ± 0.0018	0.8487 ± 0.0025	0.9198 ± 0.0014
	25%	0.8526 ± 0.0020	0.8270 ± 0.0024	0.9068 ± 0.0016
	40%	0.8342 ± 0.0031	0.7997 ± 0.0040	0.8924 ± 0.0027
NN Pro	Pulito	0.8638 ± 0.0035	0.8497 ± 0.0032	0.9241 ± 0.0010
	10%	0.8631 ± 0.0036	0.8479 ± 0.0030	0.9204 ± 0.0012
	25%	0.8464 ± 0.0045	0.8293 ± 0.0036	0.9056 ± 0.0016
	40%	0.8328 ± 0.0068	0.8130 ± 0.0070	0.8924 ± 0.0012
Random Forest	Pulito	0.8800 ± 0.0013	0.8645 ± 0.0014	0.9308 ± 0.0009
	10%	0.8646 ± 0.0024	0.8442 ± 0.0026	0.9198 ± 0.0015
	25%	0.8492 ± 0.0016	0.8228 ± 0.0016	0.9042 ± 0.0018
	40%	0.8285 ± 0.0037	0.7934 ± 0.0055	0.8881 ± 0.0028

L'esito è netto: le deviazioni standard restano contenute nell'ordine del millesimo per ogni combinazione modello–livello, con un valore massimo di appena 0,0068 (rete Pro al 40%). Questa dispersione è di un ordine di grandezza inferiore al calo prodotto dal rumore — la sola NN Base perde circa 3,4 punti percentuali di accuratezza passando dai dati puliti al 40% —, il che dimostra che la traiettoria di decadimento è un segnale reale indotto dai dati e non semplice varianza procedurale. Le barre d'errore nelle Figure 34 e 35, appena percepibili attorno ai marcatori, rendono visivamente questa stabilità: le curve dei tre modelli sono nettamente separate dalla propria incertezza statistica a ogni livello.




Figura 34: Controllo multi-seed (feature noise): accuratezza media sui cinque semi al variare del livello di rumore. Le barre d'errore (± 1 deviazione standard) sono quasi impercettibili, a conferma della riproducibilità del trend.




Figura 35: Controllo multi-seed (feature noise): F1 macro media sui cinque semi. Anche sulla metrica bilanciata l’ordinamento dei modelli e l’entità del degrado restano stabili tra i semi.

La verifica conferma inoltre la gerarchia di robustezza emersa dall’analisi a seme singolo: il Random Forest parte dal livello più alto sui dati puliti (0,8800) ma cede terreno più rapidamente, fino ad allinearsi alle reti neurali al 40%; la rete Pro, grazie alla regolarizzazione, esibisce il degrado più graduale pur partendo da una base leggermente inferiore. Tali differenze, pienamente coerenti tra i cinque semi, escludono che l’ordinamento osservato dipenda da fluttuazioni del generatore stocastico.

11 Analisi non supervisionata (K-Means)

Il ciclo valutativo ingloba un’ultima integrazione fondata sul raggruppamento in assenza di variabili dipendenti. Stabilito un raggio aggregativo pari a due conglomerati macroscopici, basato sull’interpolazione visiva dell’inerzia (metodo del gomito) e sul valore della silhouette, massimo proprio in corrispondenza di $k = 2$ (Figura 36) — pur tenendo presente che la silhouette tende strutturalmente a premiare valori di k contenuti, per cui costituisce un indizio più che una prova decisiva — l’architettura conferma e restituisce riscontri duali ai precedenti attestati supervisionati. L’anomalia sulle etichette risulta del tutto influente ai fini dell’orientamento dei centroidi, in quanto i raggruppamenti geometrici nascono da un processo basato interamente sullo scarto euclideo, astruendo per necessità costruttive le impronte classificate in archivio.




Figura 36: Scelta del numero di cluster. Inerzia e silhouette indicano in $k = 2$ la configurazione spaziale ottimale per la densità esplorata.

Le distanze geometriche generate falliscono nel mappare fedelmente i legami sostanziali tra sorgenti (adroniche contro fotoniche). L'assegnazione spaziale origina un valore Adjusted Rand Index pari a 0,006 (quasi nullo) accoppiato ad un indice di purezza equiparabile con lo scompenso probabilistico nativo dei dati. In sintesi, pur seguendo il profilo di varianza, l'algoritmo separa masse numeriche prive di connessione intima col fine di ricerca (Figura 37). Le proprietà fisiche che demarcano i gruppi non risiedono sulla spaccatura dei pesi ma attraversano i conglomerati senza offrire discriminanti lineari o raggruppabili allo spazio.




Figura 37: Proiezione PCA: i cluster geometrici non si allineano con la natura fisica e asimmetrica delle collisioni ($ARI \approx 0$).

Intromettendo crescenti interferenze nel flusso dei parametri originali (Figura 38 e Figura 39), l'evanescenza qualitativa subisce un drastico rialzo proporzionale. Mentre l'alterazione del labeling transita invisibile mantenendo gli scarti in stallo, le dispersioni standard espandono caoticamente le nuvole proiettate: le sagome dei grappoli si liquefanno in transizioni piatte causando riduzioni crescenti della compattezza (la silhouette cede fin oltre il traguardo dello 0,10). La resilienza o vulnerabilità predittiva ad un determinato stress test è indissolubilmente legata al flusso dei vettori attivi immessi all'interno delle iterazioni prescelte dal progettista.




Figura 38: K-Means sotto feature noise: ARI e silhouette dei cluster. La silhouette cala, mentre l'ARI resta vicino a zero.




Figura 39: Cluster K-Means ($k=2$) proiettati sulle prime due componenti (PCA). Al crescere del rumore (σ) la densità spaziale viene a mancare e le istanze sfumano i propri confini.

12 Conclusioni

Questo studio sposta l'attenzione dalla ricerca del modello migliore in assoluto alla valutazione di quale algoritmo resista meglio a specifiche tipologie di corruzione dei dati. I risultati delineano un quadro coerente, in cui nessuna soluzione è priva di compromessi.

Tra i disturbi analizzati emerge una chiara gerarchia di pericolosità. Gli outlier risultano i meno dannosi, poiché il loro impatto è quasi trascurabile anche con trattamenti

minimi. Feature noise e valori mancanti generano un calo prestazionale moderato e gestibile, mitigato rispettivamente dalla ridondanza informativa tra le feature e dalle strategie di imputazione. Al contrario, la rimozione delle feature e il label noise si rivelano le anomalie più critiche, seppur per ragioni opposte. La rimozione di una feature elimina informazione predittiva insostituibile: l'azzeramento della sola f_{Alpha} risulta più impattante del livello massimo di feature noise. Il label noise, invece, forza le reti a memorizzare pattern errati. Il caso più estremo è rappresentato dal label noise borderline, che corrompe le istanze prossime al confine decisionale e riduce le prestazioni dei modelli a valori prossimi a quelli di un classificatore basato sulla classe maggioritaria.

Confrontando i modelli, nessuno prevale in ogni scenario. La rete Pro dimostra l'efficacia della regolarizzazione: l'*early stopping* la rende particolarmente resistente al label noise random, bloccando la memorizzazione del rumore che penalizza la rete Base. Tuttavia, questa stessa propensione a non adattarsi troppo ai dati la penalizza leggermente quando una feature viene a mancare del tutto. Il Random Forest si conferma l'algoritmo più solido sui dati puliti, sui valori mancanti e sugli outlier, ma rivela una notevole fragilità di fronte all'inversione casuale delle etichette. La rete Base, pur essendo competitiva sui dati puliti, risulta la più esposta all'aumentare del rumore. La scelta del modello, pertanto, non può prescindere da un'analisi a priori sulle tipologie di errore attese nel dominio applicativo reale.

L'analisi separata per classe aggiunge un'ulteriore chiave di lettura. Sotto la maggior parte dei disturbi, il degrado non colpisce le classi in modo simmetrico: a peggiorare è quasi esclusivamente il riconoscimento della classe minoritaria (adroni), mentre il segnale (gamma) continua a essere identificato correttamente. L'utilizzo della sola accuratezza globale avrebbe mascherato questa dinamica. Per questo motivo, l'impiego dei *class weight* nella rete Pro si rivela fondamentale per preservare la capacità di individuare la classe rara. Fa eccezione il label noise borderline, che degrada le metriche in modo uniforme su entrambe le classi poiché ne distorce direttamente il confine spaziale, vanificando il ribilanciamento.

L'evidenza più significativa riguarda tuttavia l'importanza del preprocessing rispetto alla complessità algoritmica. Strategie mirate, come l'imputazione dei valori mancanti, la winsorizzazione degli outlier e l'interruzione dell'addestramento basata sulla validation loss, permettono di arginare gran parte del degrado prestazionale. Nessun modello, per quanto sofisticato, può recuperare un'informazione definitivamente cancellata o logicamente falsificata nei punti più sensibili. La robustezza di un sistema predittivo si costruisce a monte, nella cura del dato, tanto quanto a valle nella scelta dell'algoritmo. L'esperimento non supervisionato lo conferma ulteriormente: la vulnerabilità a uno specifico rumore dipende strettamente dalle informazioni che il modello sfrutta; ciò che risulta critico per un task supervisionato può rivelarsi del tutto ininfluenza per un approccio basato puramente sulla distanza spaziale.