

UNIVERSITÀ DEGLI STUDI DI MILANO - BICOCCA

Dipartimento di Informatica, Sistemistica e Comunicazione (DISCo)
Corso di laurea Magistrale in Informatica

Studio di robustezza dei modelli di machine learning al rumore nei dati

Progetto di Architetture Dati

Un'analisi sperimentale sul dataset MAGIC Gamma Telescope

Autori

Matias Bonoli – matricola [matricola]

Ashley Chudory – matricola [matricola]

Anno accademico 2025/2026

Indice

1	Introduzione	2
2	Il dataset	2
3	Suddivisione in training, validation e test	3
4	Analisi esplorativa dei dati	3
5	Preprocessing: standardizzazione	7
6	Modelli	7
7	Baseline su dati puliti	9
8	Metodologia di iniezione del rumore	11
8.1	I sette tipi di rumore	11
9	Risultati per tipo di rumore	12
9.1	Feature noise	12
9.2	Feature noise localizzato	15
9.3	Label noise random	18
9.4	Label noise borderline	21
9.5	Missing values	25
9.6	Outlier	28
9.7	Missing feature (sensore guasto)	31
10	Sintesi trasversale	34
10.1	Controllo multi-seed	38
11	Analisi non supervisionata (K-Means)	40
12	Conclusioni	43
12.1	Limiti e sviluppi futuri	44

1 Introduzione

Nei sistemi reali i dati non sono mai perfetti. Si incontrano misurazioni imprecise, errori di annotazione, valori mancanti e anomalie di ogni tipo. L'obiettivo di questa analisi non è trovare il modello più accurato su dati ideali, ma capire quanto ciascun algoritmo regge quando la qualità dei dati peggiora progressivamente. Per farlo, abbiamo misurato la robustezza di tre modelli supervisionati corrompendo il training set in modo controllato, attraverso sette tipi diversi di rumore.

Non cerchiamo un singolo modello vincitore, ma vogliamo capire le dinamiche del degrado in funzione del tipo di disturbo. L'approccio prevede di definire una baseline sui dati puliti per poi riaddestrare i modelli su versioni del training set progressivamente alterate, con intensità pari al 10%, 25% e 40%. Le metriche di valutazione vengono sempre calcolate su un test set pulito e mai toccato. I tre modelli analizzati sono una rete neurale standard (NN Base), una variante con meccanismi di regolarizzazione (NN Pro) e un Random Forest. I sette disturbi agiscono su feature, etichette, valori mancanti, outlier e disponibilità delle variabili. È incluso anche un esperimento non supervisionato con K-Means per osservare come il rumore si comporta quando il modello non ha accesso alle etichette.

Per garantire la piena riproducibilità degli esperimenti è stato fissato un seme casuale globale (`seed = 42`) su tutte le componenti stocastiche, che includono lo split dei dati, l'inizializzazione dei pesi delle reti, l'iniezione del rumore e i processi di campionamento del Random Forest e del K-Means. Gli esperimenti sono stati eseguiti in Python 3.12, con TensorFlow 2.21 per le reti neurali e scikit-learn per il Random Forest, il preprocessing e le metriche.

2 Il dataset

Il dataset usato è il MAGIC Gamma Telescope, generato tramite simulazioni Monte Carlo del telescopio Cherenkov MAGIC. Ogni osservazione descrive la traccia luminosa lasciata da un evento atmosferico. Il compito è una classificazione binaria con un significato fisico preciso: distinguere i segnali prodotti da raggi gamma dal rumore di fondo generato da adroni (raggi cosmici). Il dataset originale contiene 19 020 osservazioni e 11 attributi: dieci feature continue e una variabile target. Le feature codificano la geometria e la distribuzione di intensità dell'immagine dell'evento sul rivelatore. In fase di preparazione è stata applicata una mappatura numerica delle due classi, con $h \rightarrow 0$ per gli adroni (fondo) e $g \rightarrow 1$ per i gamma (segnale). La Tabella 1 riporta la descrizione delle feature.

Tabella 1: Le dieci feature continue del dataset MAGIC e il loro significato.

Feature	Descrizione
fLength	lunghezza dell'asse maggiore dell'ellisse dell'immagine
fWidth	lunghezza dell'asse minore dell'ellisse
fSize	logaritmo della somma delle intensità di tutti i pixel
fConc	rapporto di concentrazione dei due pixel più intensi
fConc1	rapporto di concentrazione del pixel più intenso
fAsym	asimmetria della distribuzione lungo l'asse maggiore
fM3Long	momento terzo (asimmetria) lungo l'asse maggiore
fM3Trans	momento terzo lungo l'asse minore
fAlpha	angolo tra l'asse maggiore e la direzione del centro del campo
fDist	distanza dal centro del campo all'origine dell'ellisse
class	target: 1 = gamma (segnale), 0 = adrone (fondo)

3 Suddivisione in training, validation e test

Il dataset è stato diviso in tre partizioni prima di qualsiasi altra operazione, inclusa l'analisi esplorativa. Questa separazione preventiva è fondamentale per evitare che le statistiche calcolate sull'intero campione influenzino le scelte sui modelli, causando data leakage. Limitando l'analisi esplorativa e il calcolo dei parametri di preprocessing al solo training set, validation e test set si mantengono come stime rigorose e imparziali della capacità di generalizzazione.

La divisione segue le proporzioni 60% / 20% / 20% rispettivamente per training, validation e test. La suddivisione è stratificata sulla variabile target, in modo che ogni sottoinsieme preservi la stessa proporzione tra gamma e adroni presente nel dataset originale. Questo accorgimento è necessario a causa dello sbilanciamento delle classi, perché un campionamento puramente casuale potrebbe produrre insieme con troppo pochi campioni della classe minoritaria. Si ottengono così 11 412 campioni di training, 3 804 di validation e 3 804 di test. Il validation set viene usato per monitorare l'addestramento, mentre il test set resta isolato per la valutazione finale.

4 Analisi esplorativa dei dati

L'analisi esplorativa viene condotta esclusivamente sul training set per mantenere le altre partizioni isolate. Il dataset originale non presenta valori nulli, il che fornisce una base di partenza integra. In questo modo lo studio rimane controllato, perché ogni successiva corruzione viene introdotta in maniera deliberata e quantificabile. In fase esplorativa sono stati trovati 41 record duplicati nel training che sono stati rimossi portando il conteggio da 11 412 a 11 371 osservazioni.

La Figura 1 mostra la distribuzione della variabile target, con un netto sbilanciamento. I gamma rappresentano il 64,8% delle osservazioni, gli adroni il restante 35,2%, con un rapporto di quasi due a uno. Questo squilibrio fissa una soglia operativa: un classificatore che preveda sempre la classe maggioritaria otterrebbe circa il 65% di accuratezza. Qualsiasi modello predittivo deve superare questa soglia per dimostrare un apprendimento reale.




Figura 1: Distribuzione delle due classi nel training set: i gamma (segnale) sono quasi il doppio degli adroni (fondo).

Le distribuzioni delle variabili continue (Figura 2) sono prevalentemente asimmetriche verso destra, con densità concentrate sui valori bassi e code lunghe verso destra. Questa asimmetria rende la mediana uno stimatore di tendenza centrale più robusto rispetto alla media. Si nota anche una notevole eterogeneità nelle scale numeriche, che vanno da unità singole a centinaia, il che rende necessaria una successiva normalizzazione. La Tabella 2 riporta media, deviazione standard, minimo, mediana e massimo di ogni feature e documenta entrambe le caratteristiche.

Tabella 2: Statistiche descrittive delle feature sul training set. Le scale sono molto diverse tra loro e le mediane sono spesso lontane dalle medie, segno di distribuzioni asimmetriche.

Feature	Media	Dev. std	Min	Mediana	Max
fLength	53.25	42.42	7.21	36.98	305.32
fWidth	22.18	18.44	0.00	17.12	256.38
fSize	2.82	0.47	1.99	2.74	5.32
fConc	0.38	0.18	0.01	0.35	0.89
fConc1	0.21	0.11	0.00	0.20	0.64
fAsym	-4.41	59.25	-457.92	3.90	575.24
fM3Long	10.36	51.21	-331.78	15.11	238.32
fM3Trans	0.16	20.99	-205.89	0.00	179.85
fAlpha	27.71	26.09	0.00	17.88	90.00
fDist	193.65	74.42	1.28	191.85	495.56




Figura 2: Istogrammi delle dieci feature continue (training set): distribuzioni asimmetriche, con code lunghe e scale eterogenee.

I boxplot divisi per classe (Figura 3) permettono di valutare il potere discriminante di ciascuna feature. La variabile **fAlpha** mostra la separazione più netta: i valori dei gamma si concentrano in un intervallo ristretto e basso, mentre quelli degli adroni presentano un'elevata dispersione. Seguono **fLength**, **fWidth** e **fSize**, che offrono un buon contributo informativo. Al contrario, **fM3Trans** e **fAsym** mostrano distribuzioni ampiamente sovrapposte tra le due classi. L'informazione utile alla classificazione è quindi concentrata in un sottoinsieme limitato di variabili.




Figura 3: Boxplot di ogni feature per classe (training set): **fAlpha** è la più discriminante, i momenti trasversali separano poco le classi.

La matrice di correlazione di Pearson (Figura 4) mostra forti dipendenze lineari tra alcune feature. Le variabili **fConc** e **fConc1** sono quasi colineari (correlazione di 0,98) e presentano una marcata anticorrelazione con **fSize** ($-0,85$ e $-0,81$). Anche il gruppo formato da **fLength**, **fWidth** e **fSize** mostra correlazioni significative, tra 0,70 e 0,77. Questa ridondanza informativa implica che il degrado o l'assenza di una di queste feature possa essere parzialmente compensato dall'informazione contenuta nelle altre. Al contrario, **fAlpha** è quasi del tutto scorrelata dal resto del dataset: la sua informazione è unica e non recuperabile in caso di corruzione.



Figura 4: Matrice di correlazione tra le feature (training set). Spiccano la quasi-ridondanza `fConc`/`fConc1` e l'anticorrelazione di `fSize` con le concentrazioni; `fAlpha` è quasi scorrelata da tutte.

5 Preprocessing: standardizzazione

L'eterogeneità delle scale numeriche osservata durante l'analisi esplorativa rende indispensabile la standardizzazione delle feature, cioè la traslazione a media nulla e varianza unitaria. Questo passaggio è particolarmente importante per la stabilità e la convergenza delle reti neurali. Senza standardizzazione, le feature con valori molto grandi dominerebbero l'aggiornamento dei gradienti per ragioni di scala e non per il loro effettivo potere predittivo.

Per evitare il data leakage, i parametri di scalatura (media e deviazione standard) sono stati calcolati esclusivamente sul training set. Questi parametri sono stati poi applicati invariati per trasformare il validation e il test set.

6 Modelli

Lo studio confronta tre modelli supervisionati, scelti per rappresentare architetture con livelli differenti di tolleranza intrinseca al rumore. La Tabella 3 ne riassume i parametri strutturali e gli iperparametri.

I tre modelli rappresentano tre strategie diverse di controllo della complessità. La rete Base non ha alcun vincolo ed è libera di adattarsi a qualsiasi pattern, anche a quelli creati dal rumore. La rete Pro ha la stessa capacità, ma quattro meccanismi che ne

limitano l'adattamento. Il Random Forest ottiene la robustezza in modo strutturale, mediando le previsioni di molti alberi decorrelati. Confrontarli sotto rumore significa chiedersi quale strategia protegge meglio e da quali tipi di corruzione.

La rete neurale Base è un Multi-Layer Perceptron volutamente semplice. Prende in ingresso le dieci feature standardizzate, le elabora attraverso due strati nascosti (da 32 e 16 neuroni, entrambi con attivazione ReLU) e produce in uscita un singolo neurone con attivazione sigmoide per stimare la probabilità di classe. L'addestramento usa l'ottimizzatore Adam con tasso di apprendimento 10^{-3} e la funzione di costo binary cross-entropy, per 75 epoche con batch size di 32. Non avendo alcun meccanismo di regolarizzazione, questa rete rappresenta la baseline ingenua, libera di adattarsi anche ai pattern spuri introdotti dal rumore.

La rete neurale Pro mantiene la stessa architettura della rete Base ma aggiunge quattro meccanismi per contrastare l'overfitting. La regolarizzazione L2 (coefficiente 10^{-4} sui pesi degli strati nascosti) penalizza la magnitudo dei pesi, scoraggiando confini decisionali troppo complessi. Il dropout (probabilità 0,2) disabilita casualmente una frazione di neuroni a ogni iterazione, obbligando la rete a distribuire l'apprendimento su più unità. Il class weight bilanciato aumenta la penalizzazione per gli errori sulla classe minoritaria (adroni). Infine, l'early stopping monitora la funzione di costo sul validation set e interrompe l'addestramento se non ci sono miglioramenti per 15 epoche consecutive, entro un massimo di 150 epoche, ripristinando i pesi migliori.

Il Random Forest è un ensemble di 200 alberi decisionali. La sua robustezza viene dal bagging: ogni albero viene addestrato su sottoinsiemi casuali di dati e feature, e le previsioni finali si ottengono per voto maggioritario. Questo meccanismo tende a cancellare la varianza degli errori individuali. Non operando tramite ottimizzazione iterativa, non produce curve di apprendimento; le performance si valutano solo sulle metriche e sulla matrice di confusione finali.

Tabella 3: Parametri principali dei tre modelli confrontati.

Modello	Architettura	Regolarizzazione / iperparametri		
NN Base	Dense(32) → Dense(16) → sigmoide	nessuna; Adam 10^{-3} , 75 epoche, batch 32		
NN Pro	Dense(32) → Dense(16) → sigmoide	L2 10^{-4} , dropout 0,2, class weight bilanciato, early stopping (patience 15), max 150 epoche		
Random Forest	200 alberi decisionali	aggregazione	per	voto, <code>random_state=42</code>

Per la valutazione complessiva vengono usate quattro metriche calcolate sul test set pulito con soglia decisionale di 0,5. L'accuratezza globale dà un'indicazione generale ma risente dello sbilanciamento delle classi. Per compensare vengono usate l'F1 macro e la Recall macro, che mediano le prestazioni su entrambe le classi penalizzando i modelli che tendono a ignorare gli adroni. L'AUC valuta invece la qualità del ranking probabilistico indipendentemente dalla soglia scelta.

7 Baseline su dati puliti

L'addestramento preliminare sui dati originali stabilisce il riferimento di prestazioni a livello 0% di corruzione. Le metriche ottenute servono da punto di paragone per misurare i futuri degradi. La Tabella 4 riassume i risultati sul test set.

Tabella 4: Metriche di test dei tre modelli sui dati puliti (riferimento a 0% di rumore).

Modello	Accuratezza	Recall macro	F1 macro	AUC
NN Base	0,8678	0,8445	0,8517	0,9214
NN Pro	0,8601	0,8470	0,8468	0,9238
Random Forest	0,8785	0,8535	0,8629	0,9300

I tre modelli partono da prestazioni comparabili, con accuratezza tra l'86% e l'88% e AUC tra 0,92 e 0,93. Il Random Forest è il più performante su tutte le metriche. L'accuratezza della rete Pro è leggermente inferiore a quella della rete Base, ma non per colpa di L2 o dropout: il class weight bilanciato, applicato con soglia fissa a 0,5, sposta l'obiettivo verso la classe minoritaria, aumentando la recall sugli adroni (da 0,77 a 0,80) a scapito di una parte della recall sui gamma. L'accuratezza globale scende ma la qualità del ranking probabilistico migliora: la rete Pro ottiene un'AUC leggermente superiore alla Base, a conferma di una maggiore solidità nella stima delle probabilità.

Le matrici di confusione (Figura 5) mostrano che tutti i classificatori riconoscono bene i gamma, ma concentrano la maggior parte degli errori sull'identificazione degli adroni. Le curve di apprendimento delle due reti (Figura 6) indicano una convergenza regolare. Il divario limitato tra training e validation conferma che non c'è overfitting significativo sui dati non alterati per entrambe le architetture.




Figura 5: Matrici di confusione sui dati puliti: rete Base, rete Pro e Random Forest (da sinistra a destra). Tutti riconoscono bene i gamma, gli errori si concentrano sugli adroni.




Figura 6: Curve di accuratezza e loss (train vs validation) sui dati puliti: rete Base (in alto) e rete Pro (in basso).

La feature importance estratta dal Random Forest (Figura 7) conferma quanto emerso nell'analisi esplorativa. La feature **fAlpha** domina con un valore di importanza vicino a 0,24, circa una volta e mezza il secondo parametro più rilevante (**fLength**, $\approx 0,15$). Seguono in ordine decrescente **fLength**, **fWidth** e **fSize**.




Figura 7: Importanza delle feature secondo il Random Forest sui dati puliti. **fAlpha** domina, coerentemente con la separabilità osservata nei boxplot.

8 Metodologia di iniezione del rumore

Il rumore altera esclusivamente il training set, mantenendo intatti validation e test set. In questo modo si valuta correttamente la capacità di generalizzazione di un modello addestrato su dati imperfetti. Per ogni tipo di rumore, i modelli vengono riaddestrati iterativamente a tre livelli di intensità (10%, 25%, 40%) e le performance vengono sempre misurate sullo stesso test set. L'iniezione del rumore avviene sul training set già standardizzato: trattandosi di perturbazioni additive o monotone, l'operazione è matematicamente equivalente a corrompere i dati originali e standardizzarli in un secondo momento.

I sette meccanismi coprono le principali dimensioni della qualità del dato: la precisione delle misure con il feature noise globale e localizzato, la correttezza delle annotazioni con il label noise casuale e borderline, la completezza con i missing values, l'integrità dei record con gli outlier e la disponibilità delle variabili con il missing feature. Sono inoltre presenti due coppie utili al confronto: rumore diffuso contro rumore mirato sulle feature, e rumore casuale contro rumore strutturato sulle etichette. Come si vedrà nei risultati, la gravità del danno dipende più dalla struttura del disturbo che dalla sua quantità.

Si definiscono sette meccanismi di corruzione.

8.1 I sette tipi di rumore

Feature noise (rumore gaussiano). A ogni singola feature del training set viene sommato un rumore gaussiano a media nulla, con deviazione standard proporzionale al livello percentuale scelto. Poiché le variabili sono già state standardizzate, un rumore al livello 40% introduce fluttuazioni pari al 40% della deviazione standard nativa di ciascuna feature.

Feature noise localizzato. Qui l'intensità del rumore è fissa a $\sigma = 0,35$, mentre varia il numero di feature perturbate. La selezione segue la gerarchia di importanza. Al livello 10% viene perturbata solo `fAlpha`; al 25% le prime tre variabili discriminanti; al 40% le prime cinque.

Label noise random. Una percentuale di osservazioni del training set pari al livello scelto subisce l'inversione della variabile target (da 0 a 1 e viceversa). Il campionamento è puramente casuale, simulando errori di annotazione distribuiti uniformemente.

Label noise borderline. L'inversione delle etichette si concentra sulle istanze più ambigue. Dopo aver calcolato i centroidi delle due classi nello spazio standardizzato, si misura la distanza di ogni campione dal centroide della classe opposta. L'inversione colpisce solo i campioni con distanza minima, cioè quelli vicini al confine decisionale.

Missing values. Singole misurazioni vengono eliminate e sostituite con un valore nullo (NaN), trattando ogni cella come evento indipendente con probabilità pari al livello di corruzione. Non potendo i modelli elaborare dati incompleti, si ricorre all'imputazione. In questa analisi vengono confrontate l'imputazione per media e per mediana della rispettiva feature.

Outlier. Un numero di campioni proporzionale al livello scelto subisce una corruzione massiva: tutti i valori delle feature per la riga selezionata vengono sostituiti con valori estremi pari a ± 5 deviazioni standard, con segno attribuito casualmente. Le strategie di mitigazione esaminate sono tre: lasciare le istanze invariate; applicare la winsorizzazione (troncamento dei valori ai percentili 5% e 95%) per limitare la magnitudo estrema; imputare i dati marcando come mancanti le istanze con z-score assoluto maggiore di 4 e sostituendole con la mediana. Come riferimento principale viene usata la winsorizzazione, per il suo buon equilibrio tra robustezza e conservazione dei dati.

Missing feature (sensore guasto). Intere colonne di feature vengono azzerate su tutti i sottoinsiemi (training, validation e test), simulando il guasto totale di un sensore. Anche qui la rimozione segue la gerarchia di importanza decrescente. Al 10% viene inibita `fAlpha`, al 25% le prime tre variabili predittive, al 40% le prime cinque. Questa configurazione è volutamente pessimistica, perché sopprime le fonti informative principali.

La Figura 8 mostra l'effetto di tre dei disturbi descritti su una singola feature. Il rumore gaussiano allarga la distribuzione senza cambiarne la forma, gli outlier creano due picchi agli estremi della scala, l'imputazione dei valori mancanti concentra molti campioni su un unico valore.




Figura 8: La feature `fAlpha` standardizzata sui dati puliti e sotto tre disturbi al 40%: rumore gaussiano, outlier a ± 5 deviazioni standard e valori mancanti imputati con la mediana.

9 Risultati per tipo di rumore

L'impatto dei sette disturbi viene analizzato singolarmente, quantificando il degrado prestazionale al crescere della corruzione. Per ciascun test vengono riportate le metriche misurate ai vari livelli e le comparazioni grafiche su accuratezza globale e F1 macro. L'analisi è completata, dove necessario, dalle curve di apprendimento e dalle matrici di confusione nel caso estremo.

9.1 Feature noise

L'aggiunta di rumore gaussiano sulle feature produce un degrado graduale. Come mostra la Tabella 5, anche al livello massimo di corruzione (40%) l'accuratezza di tutti i modelli rimane sopra l'83%, con una flessione limitata a tre o quattro punti percentuali rispetto alla baseline. I grafici prestazionali (Figura 9) mostrano curve con pendenza lieve e uniforme sia in accuratezza sia in F1 macro.

Tabella 5: Feature noise: metriche al variare del livello di rumore (test set). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8657	0.84	0.85	0.9187	0.8636	0.85	0.85	0.9204	0.8646	0.83	0.84	0.9222
25%	0.8520	0.81	0.83	0.9074	0.8465	0.83	0.83	0.9071	0.8494	0.81	0.82	0.9041
40%	0.8328	0.78	0.80	0.8941	0.8417	0.82	0.82	0.8940	0.8318	0.78	0.80	0.8913




Figura 9: Feature noise: accuratezza (in alto) e F1 macro (in basso) dei tre modelli al crescere del rumore.

Al livello 40%, la rete Pro raggiunge il valore più alto (0,8417), distaccando sia la rete Base (0,8328) sia il Random Forest (0,8318). Questo risultato conferma l'efficacia della regolarizzazione di fronte a input instabili: la combinazione di L2 e dropout impedisce al modello di apprendere le fluttuazioni casuali introdotte. La rete Base, priva

di vincoli strutturali, tende invece ad adattarsi al rumore, peggiorando la classificazione su campioni nuovi. Nelle curve di apprendimento dello scenario estremo (Figura 10) si nota come sia la rete Base che la rete Pro mantengano un gap sostanziale e costante tra training e validation loss, senza che le due curve arrivino mai ad appaiarsi. In generale, la forte ridondanza tra le feature attenua l'impatto del rumore, perché i modelli possono recuperare parzialmente l'informazione corrotta dalle variabili correlate.

Questo comportamento ha anche una spiegazione teorica nota. Addestrare una rete con rumore gaussiano sugli input equivale ad aggiungere un termine di regolarizzazione alla funzione di costo, come mostrato da Bishop (1995). Lo stesso principio viene usato di proposito come data augmentation. A livelli bassi il rumore non distrugge l'informazione, la rende solo meno precisa. Il danno diventa evidente quando l'ampiezza delle fluttuazioni si avvicina alla distanza tra le classi nello spazio standardizzato.




Figura 10: Feature noise al 40%: curve di addestramento della rete Base (in alto) e della rete Pro (in basso). Nella rete Pro train e validation restano sovrapposte: la regolarizzazione evita l'adattamento al rumore.

Il degrado non è però simmetrico tra le classi. Con lo sbilanciamento presente, i modelli tendono a preservare l'accuratezza globale sacrificando il potere predittivo sulla classe rara. Al 40% di rumore, la recall per la classe minoritaria (adroni) della rete Base scende da 0,77 a 0,59, mentre la recall dei gamma sale da 0,92 a 0,97. Questo evidenzia la tendenza a classificare come gamma gli adroni incerti. Il class weight nella rete Pro argina questo fenomeno, mantenendo la recall degli adroni a 0,73. Le matrici di confusione della rete Base (Figura 11) quantificano chiaramente questo fatto.

Il meccanismo alla base dell'asimmetria è la combinazione di soglia fissa e classi sbilanciate. Il rumore sugli input rende le probabilità stimate meno nette e le avvicina alla frequenza di base delle classi. Con la soglia a 0,5, un campione incerto viene quindi

assegnato alla classe più frequente, cioè ai gamma. Per questo la recall degli adroni scende mentre quella dei gamma sale. Lo stesso meccanismo si ripresenta in quasi tutti gli scenari successivi. La Figura 12 confronta le matrici di confusione della rete Pro e del Random Forest al 40%: il class weight della rete Pro contiene la perdita sugli adroni, mentre il Random Forest mostra lo stesso squilibrio della rete Base.




Figura 11: Feature noise, rete Base: matrici di confusione al 10%, 25% e 40% (da sinistra a destra). Gli adroni (riga 0) vengono classificati come gamma con frequenza crescente.




Figura 12: Feature noise al 40%: matrici di confusione della rete Pro (sinistra) e del Random Forest (destra). Il class weight della rete Pro contiene la perdita di recall sugli adroni; il Random Forest mostra lo stesso squilibrio della rete Base.

9.2 Feature noise localizzato

Concentrare il rumore sulle feature più importanti invece di distribuirlo uniformemente produce un degrado contenuto (Tabella 6). L'intensità della perturbazione è costante a $\sigma = 0,35$.

Tabella 6: Feature noise localizzato ($\sigma = 0,35$) sulle sole feature più importanti: il livello indica quante feature sono colpite (10%→top-1, 25%→top-3, 40%→top-5). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8651	0.84	0.85	0.9211	0.8651	0.85	0.85	0.9243	0.8743	0.85	0.86	0.9274
25%	0.8523	0.82	0.83	0.9043	0.8478	0.83	0.83	0.9058	0.8533	0.82	0.83	0.9056
40%	0.8452	0.81	0.82	0.8991	0.8386	0.82	0.82	0.8973	0.8389	0.79	0.81	0.8931




Figura 13: Feature noise localizzato: accuratezza (in alto) e F1 macro (in basso). Le curve restano vicine e quasi piatte.

Il degrado rimane lieve anche perturbando le cinque feature principali. Al livello 40%, tutti i classificatori restano sopra l'83% di accuratezza. L'analisi per classe (Figura 15)

conferma le dinamiche già osservate: anche al livello massimo la recall degli adroni della rete Base si ferma a 0,67, mentre i pesi bilanciati della rete Pro la tengono a 0,75.

La progressione dei livelli segue la gerarchia di importanza: al 10% viene perturbata solo **fAlpha**, al 25% si aggiungono **fLength** e **fWidth**, al 40% anche **fSize** e **fM3Long**. Il confronto con lo scenario del sensore guasto è utile: degradare **fAlpha** con $\sigma = 0,35$ costa meno di mezzo punto di accuratezza, mentre azzerarla del tutto ne costa quattro o cinque. Un'informazione rumorosa ma presente resta utilizzabile, un'informazione assente no. Il calo maggiore avviene tra il 10% e il 25%, quando il rumore raggiunge insieme **fLength** e **fWidth**: le variabili del gruppo correlato non possono più compensarsi a vicenda e l'AUC scende da circa 0,92 a 0,90. Il passaggio dal 25% al 40% aggiunge invece poco, perché tocca variabili meno discriminanti. Il modello più colpito è il Random Forest, la cui recall sugli adroni scende a 0,64: è il modello che dipende di più da **fAlpha** nelle divisioni dei nodi, come indica la feature importance della Figura 7.




Figura 14: Feature noise localizzato al 40%: curve di addestramento. L'andamento ricalca il feature noise globale, senza overfitting.




Figura 15: Feature noise localizzato al 40%: matrici di confusione della rete Base (sinistra) e del Random Forest (destra).

9.3 Label noise random

Alterare casualmente la variabile target produce dinamiche molto diverse da quelle viste sulle feature. Fino al 25% i classificatori mantengono metriche adeguate, ma al 40% il calo diventa drammatico. Come mostra la Tabella 7, l'accuratezza della rete Base crolla a 0,7419 e quella del Random Forest a 0,7179. La rete Pro mostra invece una resilienza notevole, mantenendosi a 0,8044 (Figura 16).

La tenuta fino al 25% ha una ragione precisa. L'inversione casuale delle etichette è un rumore simmetrico: finché la percentuale di inversioni resta sotto il 50%, in ogni zona dello spazio delle feature la classe corretta rimane maggioritaria tra le etichette osservate. Il confine di separazione ottimale quindi non si sposta; il rumore riduce solo la quantità di segnale utile. Il danno cresce perciò in modo non lineare man mano che ci si avvicina alla soglia critica, e al 40% il margine residuo è ormai piccolo.

Tabella 7: Label noise random: metriche al variare del livello di rumore (test set). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8623	0.83	0.84	0.9128	0.8570	0.84	0.84	0.9200	0.8767	0.85	0.86	0.9214
25%	0.8410	0.82	0.82	0.8882	0.8378	0.83	0.83	0.9081	0.8399	0.81	0.82	0.8884
40%	0.7419	0.68	0.69	0.7513	0.8044	0.79	0.79	0.8677	0.7179	0.70	0.70	0.7673




Figura 16: Label noise random: accuratezza e F1 macro. Al 40% la rete Pro si stacca verso l'alto, mentre Base e Random Forest crollano.

La causa di questa divergenza è visibile nelle curve di apprendimento (Figura 17). La rete Base memorizza le annotazioni errate, portando la curva di training vicino all'88% mentre la validation loss peggiora costantemente sulle etichette originali e pulite. Al contrario, l'early stopping della rete Pro, che monitora la loss sul validation set non corrotto, interrompe in tempo l'addestramento. Fermando i pesi a uno stadio prematuro ma ottimale, protegge il modello dalla memorizzazione del rumore e mantiene la validation accuracy vicina all'82%.

La differenza tra le due reti si vede anche sull'AUC (Figura 18). Già al 25% la rete Pro conserva un'AUC di 0,908, contro 0,888 della rete Base e del Random Forest. Al 40% il divario diventa ampio: 0,868 contro 0,751. La qualità del ranking probabilistico si separa quindi prima dell'accuratezza. Le matrici di confusione delle due reti al 40% (Figura 19) mostrano lo stesso fatto sulle classi: la recall degli adroni della rete Base scende a 0,47, quella della rete Pro resta a 0,73.




Figura 17: Label noise random al 40%: la Base memorizza le etichette corrotte (train sale, validation scende); la Pro, fermata dall'early stopping, mantiene alta la validation.




Figura 18: Label noise random: AUC dei tre modelli al crescere del rumore. La rete Pro mantiene un ranking probabilistico migliore già dal 25%.




Figura 19: Label noise random al 40%: matrici di confusione della rete Base (sinistra) e della rete Pro (destra). La recall sugli adroni della Base scende a 0,47, quella della Pro resta a 0,73.

Non avendo meccanismi iterativi vincolati a set di validazione puliti, il Random Forest assorbe i target errati nei nodi di divisione. La distribuzione uniforme dell'errore (Figura 20) lo conferma, producendo decrementi simili sulle metriche di entrambe le classi.

C'è anche una ragione strutturale. Gli alberi del Random Forest crescono fino a foglie pure, quindi ogni etichetta invertita finisce in una foglia che la memorizza. Il voto di maggioranza media gli errori scorrelati tra gli alberi, ma con il 40% di etichette invertite gli errori sono presenti in tutti gli alberi allo stesso modo e la media non li elimina. Limitare la profondità degli alberi ridurrebbe questa memorizzazione; il punto viene ripreso nelle conclusioni.




Figura 20: Label noise random al 40%: matrice di confusione del Random Forest. Gli errori aumentano su entrambe le classi.

9.4 Label noise borderline

Corrompere selettivamente le istanze vicine ai confini decisionali è il tipo di disturbo più distruttivo tra quelli testati. Le metriche calano in modo marcato già al 25%. Al 40%,

l'accuratezza di tutti i modelli converge intorno al 60%, scendendo sotto la soglia di un classificatore che prevede sempre la classe maggioritaria ($\approx 65\%$): il rumore borderline rende i modelli attivamente fuorvianti (Tabella 8 e Figura 21).

I campioni invertiti si concentrano nella zona di contatto tra le due classi, e qui sta la differenza con il label noise random. Quel rumore è simmetrico e non sposta il confine ottimale. Questo invece inverte in modo sistematico i campioni vicini al confine, quindi sposta il confine stesso nella distribuzione di training. L'errore introdotto non è varianza che si può mediare, è una distorsione sistematica: il minimo della funzione di costo sul training corrotto corrisponde a un confine sbagliato, e il modello lo impara subito, non per overfitting.

Tabella 8: Label noise borderline: metriche al variare del livello di rumore (test set). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8252	0.79	0.80	0.8680	0.8352	0.82	0.82	0.8915	0.8383	0.80	0.81	0.8886
25%	0.7326	0.71	0.71	0.7879	0.7403	0.73	0.72	0.8265	0.7387	0.72	0.72	0.8043
40%	0.6002	0.61	0.59	0.6656	0.6354	0.63	0.62	0.7084	0.6094	0.62	0.60	0.6774




Figura 21: Label noise borderline: al 40% tutti i modelli convergono attorno al 60%, indicando il collasso predittivo.

A parità di percentuale, il disturbo borderline è molto più dannoso del label noise random. Invertire sistematicamente le etichette dei campioni vicini al confine tra le classi sposta il confine decisionale in modo macroscopico. Le curve di apprendimento della rete Pro (Figura 22) non mostrano alcun vantaggio dalla regolarizzazione né dall'early stopping: quando il confine decisionale è corrotto in modo massiccio, nessun meccanismo di regolarizzazione riesce a recuperare la separazione tra le classi.

La Tabella 9 confronta la log loss sul test set delle due reti sotto i due tipi di label noise. Al 40% borderline la loss della rete Base arriva a 1,06, mentre quella della rete Pro si ferma a 0,61. La rete Base quindi non solo sbaglia di più: assegna probabilità alte a previsioni sbagliate. L'early stopping non salva l'accuratezza in questo scenario, ma contiene almeno il danno sulla calibrazione delle probabilità.

Tabella 9: Log loss sul test set per le due reti sotto label noise. La loss della rete Base cresce molto più in fretta di quella della rete Pro: oltre a sbagliare di più, la Base assegna probabilità alte alle previsioni sbagliate.

Rumore	Label noise random		Label noise borderline	
	NN Base	NN Pro	NN Base	NN Pro
Pulito	0.3236	0.3321	0.3236	0.3321
10%	0.3551	0.3908	0.4809	0.3913
25%	0.4752	0.4969	0.7025	0.4931
40%	0.5968	0.6137	1.0570	0.6111




Figura 22: Label noise borderline al 40%: anche la validation della rete Pro crolla, perché il confine decisionale appreso dai dati corrotti è sbagliato.

A differenza del rumore sulle feature, in questo scenario il danno si distribuisce in modo sostanzialmente bilanciato tra le due classi. Pur essendo i flip più numerosi sulla classe maggioritaria (gamma), l'effetto sul test porta a un aumento degli errori su entrambe le classi (Figura 23). La progressione del collasso ai tre livelli è mostrata nella Figura 24.




Figura 23: Label noise borderline al 40%: matrici di confusione della rete Pro (sinistra) e del Random Forest (destra). Errori diffusi in modo simmetrico.




Figura 24: Label noise borderline, rete Base: matrici di confusione al 10%, 25% e 40% (da sinistra a destra). Gli errori crescono su entrambe le classi fino al collasso.

9.5 Missing values

La sostituzione di singoli attributi con valori nulli produce un peggioramento proporzionale al livello di corruzione, a patto di usare un'imputazione adeguata. Con l'imputazione per mediana (variante canonica), le metriche globali si mantengono tra l'82% e l'85% (Tabella 10). In questo scenario il Random Forest mostra il minor calo, con accuratezza massima pari a 0,8528 (Figura 25).

Tabella 10: Missing values (imputazione con mediana): metriche al variare del tasso di valori mancanti. R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8617	0.83	0.84	0.9172	0.8570	0.84	0.84	0.9190	0.8720	0.84	0.85	0.9208
25%	0.8425	0.82	0.83	0.9057	0.8328	0.83	0.82	0.9046	0.8578	0.83	0.84	0.9129
40%	0.8328	0.79	0.81	0.8915	0.8226	0.81	0.81	0.8937	0.8528	0.82	0.83	0.9039




Figura 25: Missing values con imputazione mediana. Il Random Forest mantiene un vantaggio costante a tutti i livelli.

Il confronto tra media e mediana (Figura 26) mostra che l’asimmetria delle distribuzioni conta poco: il divario tra le due strategie è marginale e senza una direzione univoca. La mediana porta un lieve vantaggio solo sulla rete Base ai livelli di corruzione più alti; sulla rete Pro è invece la media a risultare leggermente migliore; sul Random Forest le due imputazioni si equivalgono. La mediana viene mantenuta come variante canonica per la sua maggiore robustezza teorica alle code, ma sul piano empirico la scelta tra le due incide poco sui risultati finali. Il Random Forest gestisce meglio le istanze imputate perché i suoi alberi lavorano per divisioni del campione, non con pesi distribuiti su tutta la rete.

La Tabella 11 riporta il confronto numerico completo tra le due imputazioni. La loro somiglianza ha una spiegazione semplice: l’iniezione avviene sui dati già standardizzati, dove la media di ogni feature è zero per costruzione, e per le feature poco asimmetriche anche la mediana è vicina a zero. I valori imputati dalle due strategie sono quindi simili. Anche il vantaggio del Random Forest si può spiegare in modo più preciso. L’imputazione concentra molti campioni su un unico valore, come mostrato nella Figura 8. Un albero

può isolare quel valore con una singola divisione del nodo e usare le altre feature per i campioni imputati, mentre una rete densa propaga il valore imputato a tutti i neuroni insieme ai valori genuini.

Tabella 11: Missing values: accuratezza con imputazione per media e per mediana. Le due strategie danno risultati molto vicini e nessuna delle due prevale su tutti i modelli.

Rumore	NN Base		NN Pro		Random Forest	
	media	mediana	media	mediana	media	mediana
10%	0.8596	0.8617	0.8588	0.8570	0.8720	0.8720
25%	0.8417	0.8425	0.8467	0.8328	0.8609	0.8578
40%	0.8218	0.8328	0.8320	0.8226	0.8538	0.8528




Figura 26: Missing values: confronto tra imputazione con media e con mediana per i tre modelli. Le due strategie producono prestazioni pressoché equivalenti; la mediana prevale lievemente solo sulla rete Base ad alta corruzione, mentre sulla rete Pro è la media a risultare marginalmente migliore.




Figura 27: Missing values (mediana) al 40%: curve della rete Base e matrici di confusione. L'addestramento è regolare; gli errori pesano sugli adroni.

9.6 Outlier

Contrariamente alle aspettative, gli outlier rappresentano il disturbo meno impattante tra quelli analizzati (Tabella 12). L'accuratezza resta attorno all'85%-87%, senza un degrado significativo (Figura 28). La ragione non sta tanto nel trattamento applicato quanto nella natura stessa del disturbo: le righe corrotte assumono valori a ± 5 deviazioni standard con segno casuale, del tutto scorrelato dall'etichetta. Il loro contributo al gradiente si media verso zero e i modelli, valutati su un test set pulito, ne risentono poco.

Tabella 12: Outlier (winsorizzazione): metriche al variare della frazione di campioni anomali. R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8657	0.84	0.85	0.9196	0.8583	0.85	0.84	0.9220	0.8788	0.85	0.86	0.9295
25%	0.8628	0.84	0.84	0.9160	0.8441	0.84	0.83	0.9173	0.8751	0.85	0.86	0.9267
40%	0.8615	0.84	0.84	0.9116	0.8541	0.84	0.84	0.9201	0.8736	0.85	0.86	0.9250




Figura 28: Outlier con winsorizzazione. Curve prestazionali pressoché inalterate.

Le differenze tra le tre strategie di mitigazione (Figura 30) rimangono esigue. Lasciare gli outlier invariati, winsorizzare o imputare produce risultati quasi sovrapponibili. Questa equivalenza conferma che a tassi di corruzione elevati la winsorizzazione al 5% è in larga parte inefficace: quando una frazione consistente di valori è collassata su ± 5 , i percentili stessi risultano saturi e il troncamento non rimuove gli estremi. La robustezza osservata va quindi attribuita alla natura poco dannosa del disturbo più che alla strategia di mitigazione. La winsorizzazione viene comunque mantenuta come variante canonica per prudenza, perché non ha effetti negativi (Figura 31).

La Tabella 13 riporta l'accuratezza delle tre strategie a ogni livello. Le differenze restano entro pochi millesimi e in alcuni casi il disturbo non produce alcun danno: al 10% con gli outlier lasciati il Random Forest ottiene 0,8796, un valore perfino superiore alla baseline. Le curve di addestramento (Figura 29) confermano che l'apprendimento resta indistinguibile dal caso pulito.

Tabella 13: Outlier: accuratezza con le tre strategie di trattamento (L = lasciati, W = winsorizzazione, I = imputazione). Le differenze sono minime a ogni livello.

Rumore	NN Base			NN Pro			Random Forest		
	L	W	I	L	W	I	L	W	I
10%	0.8638	0.8657	0.8670	0.8533	0.8583	0.8591	0.8796	0.8788	0.8783
25%	0.8609	0.8628	0.8665	0.8591	0.8441	0.8604	0.8783	0.8751	0.8738
40%	0.8573	0.8615	0.8633	0.8509	0.8541	0.8630	0.8725	0.8736	0.8738




Figura 29: Outlier con winsorizzazione al 40%: curve di addestramento della rete Base. L'andamento è indistinguibile da quello sui dati puliti.




Figura 30: Outlier: confronto tra le strategie. Le differenze sono minime a tutti i livelli.




Figura 31: Outlier (winsorizzazione) al 40%: matrici di confusione. Prestazioni indistinguibili dal caso pulito.

9.7 Missing feature (sensore guasto)

La rimozione completa di intere feature produce effetti molto gravi, simili al label noise. Azzerando solo `fAlpha` (Tabella 14) si registra già una caduta immediata di 4 o 5 punti; arrivando a coprire le cinque feature principali, tutti i modelli testati crollano tra il 70% e il 74% di accuratezza (Figura 32).

Tabella 14: Missing feature: metriche rimuovendo le feature più importanti (10%→top-1, 25%→top-3, 40%→top-5). R_m = recall macro.

Rumore	NN Base				NN Pro				Random Forest			
	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC	Acc	R_m	$F1_m$	AUC
Pulito	0.8678	0.84	0.85	0.9214	0.8601	0.85	0.85	0.9238	0.8785	0.85	0.86	0.9300
10%	0.8215	0.78	0.79	0.8675	0.8052	0.79	0.79	0.8716	0.8294	0.79	0.80	0.8788
25%	0.7773	0.72	0.74	0.8007	0.7574	0.73	0.73	0.7991	0.7836	0.74	0.75	0.8195
40%	0.7303	0.66	0.67	0.7413	0.6995	0.67	0.67	0.7347	0.7363	0.67	0.68	0.7494




Figura 32: Missing feature: accuratezza (in alto) e F1 macro (in basso). Rimuovere **fAlpha** produce già al primo livello il calo più marcato.

Questo scenario evidenzia l'importanza reale di **fAlpha**. Essendo quasi scorrelata dalle altre feature, la sua rimozione provoca una perdita insostituibile. In contrasto con il rumore sulle feature, qui la totale assenza di informazione rende inutili anche i meccanismi di regolarizzazione, e la rete Pro risulta il modello peggiore (0,6995 al 40%). La rigidità dei meccanismi anti-overfitting, che in altri scenari aiutano, qui diventa un limite. La rimozione delle feature danneggia soprattutto la capacità di riconoscere gli adroni, riducendo drasticamente il potere discriminante sulla classe minoritaria (Figure 33 e 35).

Vanno aggiunte due osservazioni. La prima: questo è l'unico scenario in cui anche validation e test set vengono corrotti, perché le feature azzerate non esistono più in nessuna partizione. Non è solo il modello a peggiorare, è il problema a diventare più difficile: l'errore minimo raggiungibile aumenta, perché una parte dell'informazione non esiste più. La seconda riguarda la rete Pro. È ultima in accuratezza, ma la sua recall sugli adroni al 40% è la migliore dei tre modelli: 0,55 contro 0,43 della rete Base e 0,46 del Random Forest. Il class weight continua a fare il suo lavoro e distribuisce il poco potere predittivo rimasto in modo bilanciato tra le classi, al costo di una parte dell'accuratezza

globale. Le curve e la matrice di confusione della rete Pro (Figura 34) mostrano questo comportamento.




Figura 33: Missing feature al 40%. Senza le feature più informative i modelli perdono potere discriminante intrinseco, pur mantenendo learning curves stabili e vicine.




Figura 34: Missing feature al 40%, rete Pro: curve di addestramento e matrice di confusione. L'accuratezza è la più bassa dei tre modelli, ma gli errori sono distribuiti tra le classi in modo più bilanciato.




Figura 35: Missing feature, rete Base: matrici di confusione. Rimuovendo le feature, la capacità di discriminazione sugli adroni svanisce progressivamente.

10 Sintesi trasversale

Dopo aver analizzato i singoli scenari, la visione d'insieme (Figura 36) mostra su un unico asse i livelli di degrado subiti da ciascun modello per ogni tipo di rumore.




Figura 36: Robustezza per tipo di rumore. L'outlier è sempre il disturbo meno dannoso, il label noise borderline il più dannoso.

I risultati delineano una gerarchia di vulnerabilità condivisa tra tutti i modelli. Gli outlier sono i meno dannosi, seguiti da feature noise e valori mancanti, che producono cali moderati e gestibili. All'estremo opposto, il label noise borderline è la perturbazione più severa, portando tutti i modelli al collasso. La heatmap (Figura 37) riassume il caso peggiore al 40% di corruzione: mostra il crollo delle prestazioni con il label noise borderline e il danno quasi nullo con gli outlier.




Figura 37: Accuratezza nel caso peggiore (40%) per ogni combinazione. Il rosso intenso sul label noise borderline indica il collasso predittivo.

Le Tabelle 15 e 16 riassumono il quadro in forma numerica. La prima mostra che il calo di F1 macro è quasi sempre maggiore del calo di accuratezza: il degrado non è neutro, si scarica sulla classe minoritaria. La seconda lo mostra direttamente con le recall per classe nel caso peggiore. Sotto quasi tutti i disturbi la recall sui gamma resta sopra 0,85, mentre quella sugli adroni scende anche sotto 0,50. Il label noise borderline è l'eccezione: abbassa entrambe le classi, perché non toglie informazione a una classe sola ma sposta il confine che le separa.

Tabella 15: Calo delle metriche tra dati puliti e caso peggiore (40%), per tipo di rumore e modello. Il calo di F1 macro è quasi sempre maggiore del calo di accuratezza: il danno si concentra sulla classe minoritaria.

Rumore	NN Base		NN Pro		Random Forest	
	ΔAcc	ΔF1_m	ΔAcc	ΔF1_m	ΔAcc	ΔF1_m
Feature noise	-0.035	-0.054	-0.018	-0.024	-0.047	-0.066
Feature noise localizzato	-0.023	-0.032	-0.022	-0.026	-0.040	-0.053
Label noise random	-0.126	-0.162	-0.056	-0.061	-0.161	-0.165
Label noise borderline	-0.268	-0.262	-0.225	-0.227	-0.269	-0.262
Missing values	-0.035	-0.045	-0.038	-0.039	-0.026	-0.030
Outlier	-0.006	-0.008	-0.006	-0.007	-0.005	-0.006
Missing feature	-0.138	-0.182	-0.161	-0.180	-0.142	-0.181

Tabella 16: Recall per classe al livello massimo di corruzione (40%). R_0 = recall sugli adroni, R_1 = recall sui gamma. In quasi tutti gli scenari il danno colpisce gli adroni; il label noise borderline abbassa entrambe le classi.

Rumore (40%)	NN Base		NN Pro		Random Forest	
	R_0	R_1	R_0	R_1	R_0	R_1
Nessuno (baseline)	0.77	0.92	0.80	0.89	0.77	0.94
Feature noise	0.59	0.97	0.73	0.90	0.60	0.96
Feature noise localizzato	0.67	0.94	0.75	0.89	0.64	0.95
Label noise random	0.47	0.89	0.73	0.85	0.66	0.75
Label noise borderline	0.62	0.59	0.62	0.64	0.66	0.58
Missing values	0.66	0.93	0.78	0.85	0.72	0.92
Outlier	0.75	0.92	0.79	0.89	0.75	0.94
Missing feature	0.43	0.89	0.55	0.78	0.46	0.89

Riguardo alla tenuta (Figura 38), la rete Pro mostra la maggiore tolleranza ai disturbi continui sulle feature, ma soffre di più quando una feature viene completamente rimossa. In quello scenario, il Random Forest domina per flessibilità strutturale.




Figura 38: Calo di accuratezza rispetto alla baseline per ogni tipo di rumore. Barre più corte indicano maggiore robustezza.

Mediando su tutti i tipi di rumore (Figura 39), le differenze tra i modelli diventano minime. La rete Pro si posiziona in testa (0,785), seguita dal Random Forest (0,780) e dalla rete Base (0,778). Le distanze sono però talmente ridotte che la scelta del modello non può basarsi su questo numero medio: dipende dal tipo di errore atteso nel dominio applicativo reale.




Figura 39: Robustezza complessiva (accuratezza media). Le differenze tra i tre modelli sono trascurabili.

Le curve ROC sul feature noise gaussiano (Figura 40) confermano che il rumore erode solo limitatamente la capacità di ranking dei modelli, con la rete Pro che si posiziona in modo coerente rispetto alla rete Base anche in presenza di disturbo.




Figura 40: Curve ROC dei tre modelli su dati puliti (continue) e con 40% di feature noise (tratteggiate). Il feature noise riduce solo in parte la qualità del ranking.

10.1 Controllo multi-seed

Tutti i risultati discussi finora derivano da un singolo seme casuale (`seed = 42`). Per escludere che il degrado osservato dipenda da una partizione dei dati o da un'inizializzazione dei pesi particolarmente favorevole o sfavorevole, l'esperimento di feature noise è stato ripetuto identicamente su cinque semi distinti: $\{42, 7, 123, 2024, 99\}$. Ogni seme governa contemporaneamente il rumore gaussiano, lo split train/validation/test e l'inizializzazione dei tre modelli. Per ciascun livello di corruzione si riportano media e deviazione standard delle metriche (Tabella 17).

Tabella 17: Controllo multi-seed sul feature noise: media $\pm$ deviazione standard delle metriche sui cinque semi {42, 7, 123, 2024, 99}. Le deviazioni standard restano dell'ordine del millesimo, ampiamente inferiori al divario tra livelli di rumore.

Modello	Rumore	Accuracy	F1 _m	AUC
NN Base	Pulito	0.8685 ± 0.0027	0.8514 ± 0.0029	0.9220 ± 0.0015
	10%	0.8672 ± 0.0018	0.8487 ± 0.0025	0.9198 ± 0.0014
	25%	0.8526 ± 0.0020	0.8270 ± 0.0024	0.9068 ± 0.0016
	40%	0.8342 ± 0.0031	0.7997 ± 0.0040	0.8924 ± 0.0027
NN Pro	Pulito	0.8638 ± 0.0035	0.8497 ± 0.0032	0.9241 ± 0.0010
	10%	0.8631 ± 0.0036	0.8479 ± 0.0030	0.9204 ± 0.0012
	25%	0.8464 ± 0.0045	0.8293 ± 0.0036	0.9056 ± 0.0016
	40%	0.8328 ± 0.0068	0.8130 ± 0.0070	0.8924 ± 0.0012
Random Forest	Pulito	0.8800 ± 0.0013	0.8645 ± 0.0014	0.9308 ± 0.0009
	10%	0.8646 ± 0.0024	0.8442 ± 0.0026	0.9198 ± 0.0015
	25%	0.8492 ± 0.0016	0.8228 ± 0.0016	0.9042 ± 0.0018
	40%	0.8285 ± 0.0037	0.7934 ± 0.0055	0.8881 ± 0.0028

L'esito è netto: le deviazioni standard restano nell'ordine del millesimo per ogni combinazione modello–livello, con un valore massimo di appena 0,0068 (rete Pro al 40%). Questa dispersione è di un ordine di grandezza inferiore al calo prodotto dal rumore: la sola rete Base perde circa 3,4 punti percentuali di accuratezza passando dai dati puliti al 40%. Il degrado è quindi un segnale reale indotto dai dati, non semplice varianza procedurale. Le barre d'errore nelle Figure 41 e 42 sono appena percettibili attorno ai marcatori, a conferma visiva di questa stabilità.




Figura 41: Controllo multi-seed (feature noise): accuratezza media sui cinque semi al variare del livello di rumore. Le barre d'errore (± 1 deviazione standard) sono quasi impercettibili, a conferma della riproducibilità del trend.




Figura 42: Controllo multi-seed (feature noise): F1 macro media sui cinque semi. Anche sulla metrica bilanciata l’ordinamento dei modelli e l’entità del degrado restano stabili tra i semi.

La verifica conferma anche la gerarchia di robustezza emersa con il seme singolo. Il Random Forest parte dal livello più alto sui dati puliti (0,8800) ma cede terreno più rapidamente, allineandosi alle reti neurali al 40%. La rete Pro mostra il degrado più graduale grazie alla regolarizzazione, pur partendo da una base leggermente inferiore. Queste differenze, coerenti tra i cinque semi, escludono che l’ordinamento osservato dipenda da fluttuazioni casuali.

11 Analisi non supervisionata (K-Means)

L’analisi include anche un esperimento di clustering non supervisionato. Il numero di cluster è stato fissato a due, sulla base dell’andamento dell’inerzia (metodo del gomito) e del valore della silhouette, che risulta massimo proprio in corrispondenza di $k = 2$ (Figura 43). Va notato che la silhouette tende strutturalmente a premiare valori di k bassi, quindi costituisce un indizio più che una prova definitiva. Il risultato rispecchia comunque quanto emerso dai modelli supervisionati. Il label noise è del tutto influente sull’orientamento dei centroidi, perché il clustering si basa esclusivamente sulla distanza euclidea, senza accedere alle etichette.




Figura 43: Scelta del numero di cluster. Inerzia e silhouette indicano $k = 2$ come numero di cluster adeguato.

Le distanze geometriche non riescono però a mappare le differenze fisiche tra gamma e adroni. L'assegnazione spaziale produce un Adjusted Rand Index di 0,006, quasi nullo, e una purezza pari alla frequenza della classe maggioritaria. In sintesi, l'algoritmo separa i punti in base alla geometria, senza alcun legame con la classe fisica (Figura 44). Le differenze tra gamma e adroni non corrispondono a una separazione geometrica nello spazio delle feature.

Il risultato ha una ragione geometrica precisa. Dopo la standardizzazione ogni feature contribuisce alla distanza euclidea con lo stesso peso. Le feature del gruppo correlato `fLength`, `fWidth` e `fSize` misurano quasi la stessa quantità, quindi quella direzione conta di fatto tre volte. `fAlpha`, che contiene quasi tutta l'informazione discriminante ed è scorrelata dal resto, conta una volta su dieci. Il K-Means separa quindi gli eventi in base alla dimensione complessiva dell'immagine, non in base alla classe fisica. Le altre metriche confermano il risultato: AMI e NMI restano sotto 0,002, e la purezza dei cluster è 0,648, cioè esattamente la frequenza della classe maggioritaria.




Figura 44: Proiezione PCA: i cluster geometrici non corrispondono alle classi fisiche gamma e adrone ($ARI \approx 0$).

Introducendo crescente rumore sulle feature (Figure 45 e 46), la qualità del clustering peggiora proporzionalmente. Il label noise invece non ha alcun effetto, perché i centroidi non dipendono dalle etichette. Il rumore sulle feature allarga le nuvole di punti proiettate:

i confini tra i cluster diventano meno netti e la silhouette scende fino a circa 0,10. La vulnerabilità a un tipo di rumore dipende quindi strettamente da quali informazioni il modello utilizza.

La Tabella 18 riporta i valori numerici. La purezza resta fissa a 0,648 a ogni livello di rumore: i cluster non catturano le classi né sui dati puliti né su quelli corrotti. L'invarianza al label noise è stata verificata anche in modo diretto. Il clustering calcolato con le etichette originali e quello calcolato dopo l'inversione del 40% delle etichette coincidono, con un ARI tra le due partizioni pari a 1,0: il K-Means non usa le etichette in alcun passaggio, quindi il label noise non può influenzarlo.

Tabella 18: Qualità del clustering K-Means ($k=2$) al crescere del feature noise. La silhouette cala, mentre ARI e AMI restano vicini a zero e la purezza resta fissa alla quota della classe maggioritaria (0.648): i cluster non catturano le classi a nessun livello di rumore.

σ	ARI	AMI	Silhouette	Purezza
0.00	0.006	0.001	0.290	0.648
0.25	0.008	0.002	0.272	0.648
0.50	0.009	0.002	0.234	0.648
1.00	0.006	0.002	0.164	0.648
1.50	0.005	0.002	0.125	0.648
2.00	0.003	0.001	0.102	0.648




Figura 45: K-Means sotto feature noise: ARI e silhouette dei cluster. La silhouette cala, mentre l'ARI resta vicino a zero.




Figura 46: Cluster K-Means ($k=2$) proiettati sulle prime due componenti (PCA). Al crescere del rumore (σ) i cluster diventano meno densi e i loro confini meno netti.

12 Conclusioni

Questo studio sposta l'attenzione dalla ricerca del modello migliore in assoluto alla valutazione di quale algoritmo resiste meglio a specifiche tipologie di corruzione dei dati. I risultati delineano un quadro coerente in cui nessuna soluzione è priva di compromessi.

Tra i disturbi analizzati emerge una gerarchia di pericolosità chiara. Gli outlier sono i meno dannosi, con un impatto quasi trascurabile anche senza trattamenti specifici. Feature noise e valori mancanti generano un calo moderato e gestibile, mitigato rispettivamente dalla ridondanza informativa tra le feature e dalle strategie di imputazione. Al contrario, la rimozione delle feature e il label noise sono le anomalie più critiche, per ragioni opposte. Rimuovere una feature elimina informazione predittiva insostituibile: azzerare solo `fAlpha` risulta più impattante del livello massimo di feature noise. Il label noise, invece, forza i modelli a memorizzare pattern errati. Il caso più estremo è il label noise borderline, che corrompendo le istanze vicine al confine decisionale riduce le prestazioni fino ai livelli di un classificatore banale.

Confrontando i modelli, nessuno prevale in ogni scenario. La rete Pro dimostra l'efficacia della regolarizzazione: l'early stopping la rende particolarmente resistente al label noise random, bloccando la memorizzazione del rumore che penalizza la rete Base. Tuttavia questa stessa propensione a non adattarsi troppo ai dati la penalizza quando una feature viene rimossa del tutto. Il Random Forest si conferma il più solido su dati puliti, valori mancanti e outlier, ma mostra una fragilità notevole di fronte all'inversione casuale delle etichette. La rete Base, pur competitiva su dati puliti, è la più esposta all'aumentare del rumore. La scelta del modello non può prescindere da un'analisi preventiva sui tipi di errore attesi nel dominio applicativo.

L'analisi per classe aggiunge un punto importante. Sotto la maggior parte dei disturbi, il degrado colpisce quasi esclusivamente la classe minoritaria (adroni), mentre il

segnale (gamma) continua a essere identificato correttamente. Usare solo l'accuratezza globale avrebbe nascosto questa dinamica. I class weight nella rete Pro si rivelano fondamentali per preservare la capacità di riconoscere la classe rara. Fa eccezione il label noise borderline, che degrada le metriche in modo uniforme su entrambe le classi perché distorce direttamente il confine spaziale.

L'evidenza più significativa riguarda però l'importanza del preprocessing rispetto alla complessità algoritmica. Strategie mirate come l'imputazione dei valori mancanti, la winsorizzazione degli outlier e l'interruzione dell'addestramento basata sulla validation loss permettono di arginare gran parte del degrado. Nessun modello, per quanto sofisticato, può recuperare un'informazione cancellata o falsificata nei punti più sensibili. La robustezza di un sistema predittivo si costruisce nella cura del dato tanto quanto nella scelta dell'algoritmo. L'esperimento non supervisionato lo conferma: ciò che è critico per un task supervisionato può essere del tutto ininfluenza per un approccio basato sulla distanza spaziale.

12.1 Limiti e sviluppi futuri

Lo studio ha alcuni limiti, che indicano direzioni di lavoro future. Il controllo multi-seed copre solo il feature noise; estenderlo agli altri disturbi renderebbe più solide le conclusioni, in particolare per il label noise, dove i divari tra i modelli sono ampi. La soglia di decisione è fissa a 0,5: sotto rumore le probabilità stimate cambiano, e una parte del calo di recall sulla classe minoritaria potrebbe essere recuperata ritardando la soglia sul validation set. Gli iperparametri sono stati scelti sui dati puliti e mai ricalibrati sotto rumore. Gli alberi del Random Forest crescono senza limite di profondità: limitarla dovrebbe ridurre la memorizzazione delle etichette invertite, e sarebbe una verifica diretta dell'ipotesi avanzata nella Sezione 9. Infine, i risultati riguardano un solo dataset. La gerarchia di pericolosità osservata dipende anche dalle caratteristiche di MAGIC, in particolare dalla ridondanza tra le feature e dal ruolo dominante di `fAlpha`, e andrebbe confermata su dataset con struttura diversa.